ЦЕНТРАЛЬНЫЙ УНИВЕРСИТЕТ

Сегментация, SAM

COMPUTER VISION

НЕДЕЛЯ 7

Анастасия Белозёрова,
Deputy Chief Research
Officer @ VisionLabs

План

01 Введение, датасеты и метрики

02 UNet

03 Кто, если не UNet

04 Трансформерные модели

05 Segment Anything Model (SAM)

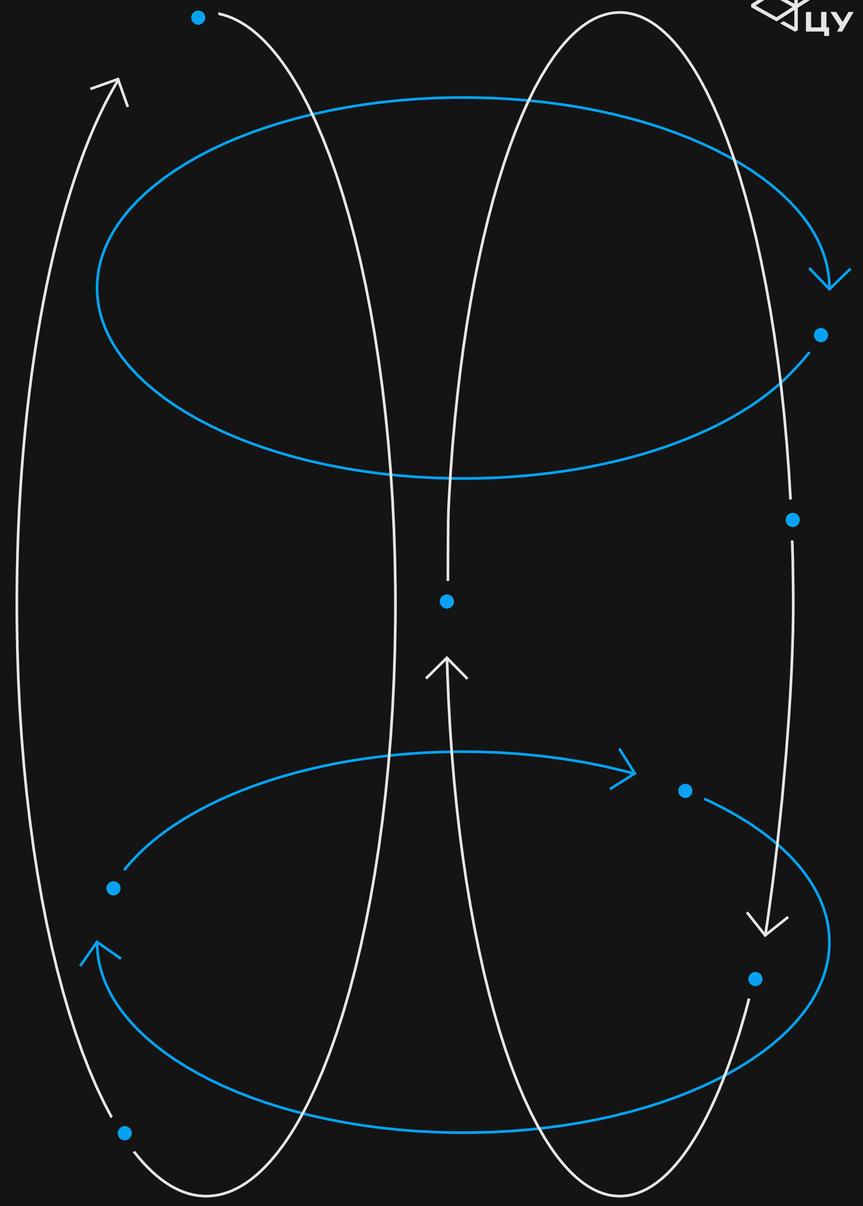

Что такое сегментация

Сегментация — это задача попиксельной классификации изображения.

predict

Person
Bicycle
Background

Источник

Какая бывает сегментация

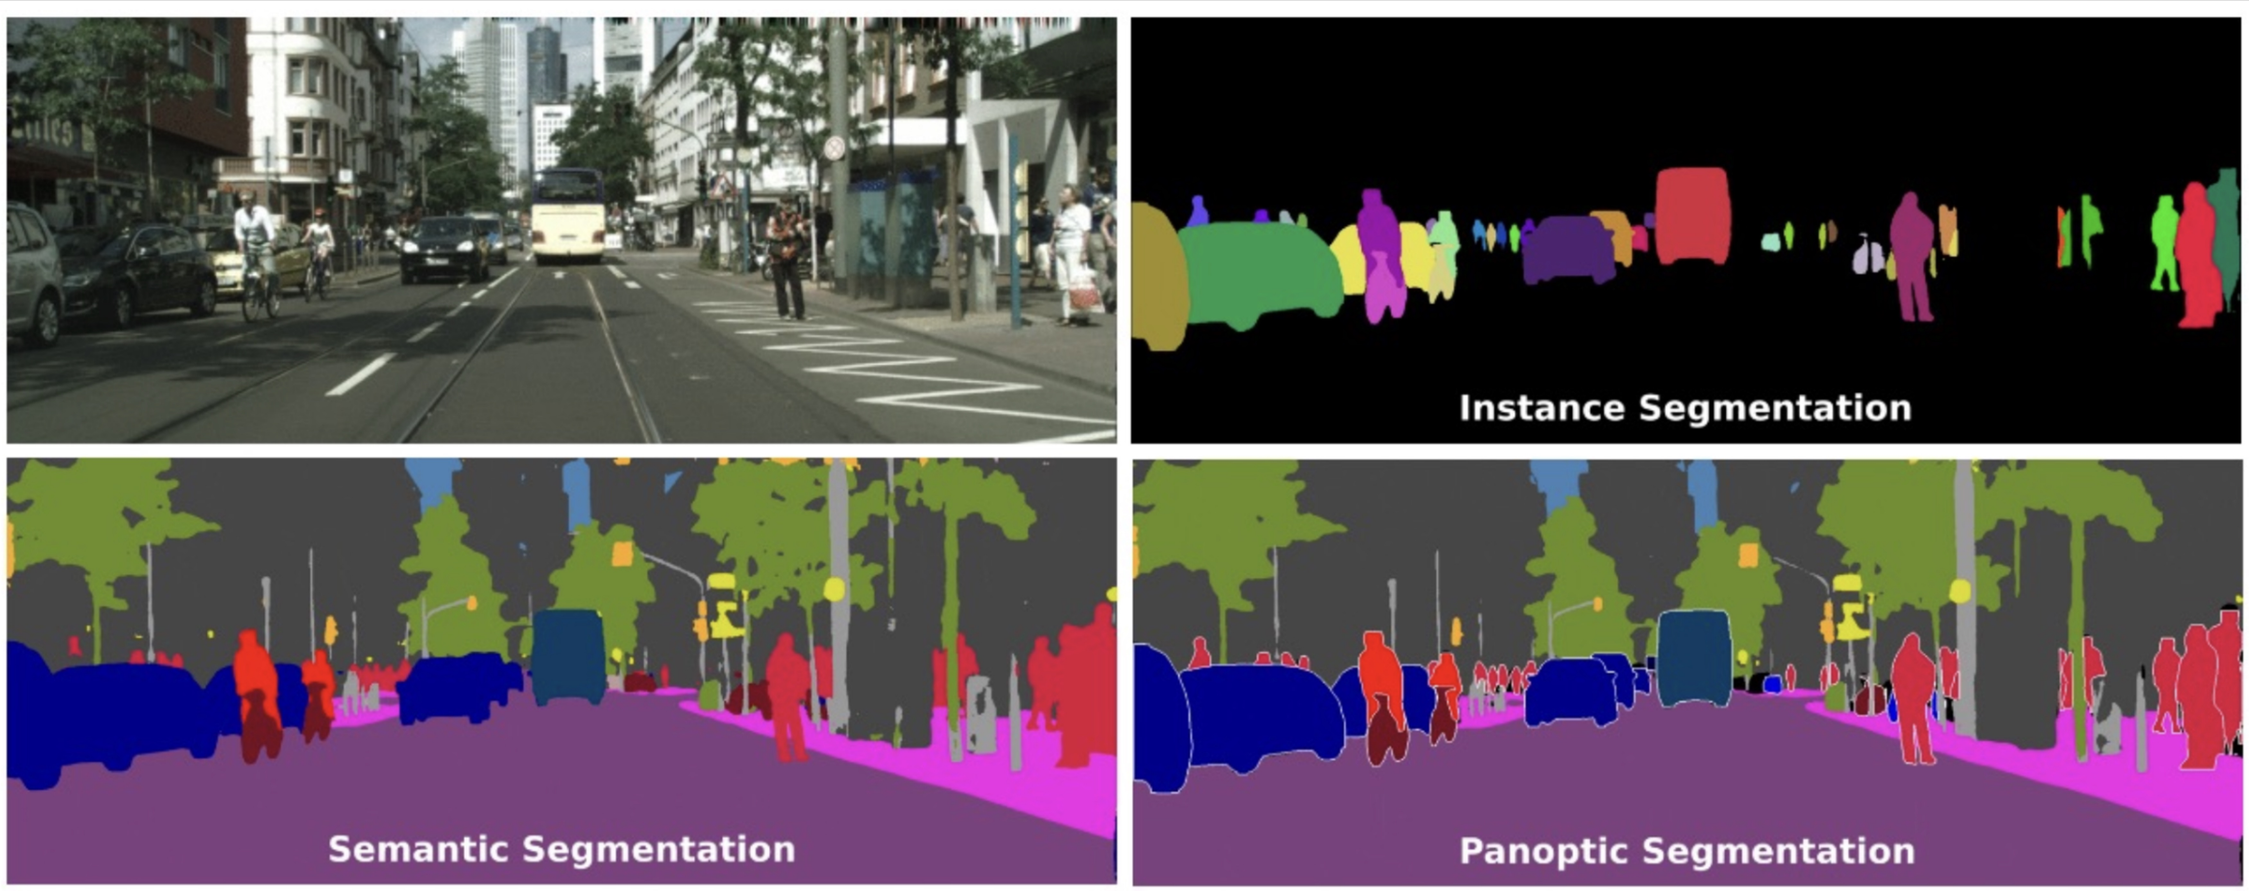

Мы будем говорить про подходы для **семантической сегментации**

Источник

Постановка задачи

Input

segmented

3	3	3	3	3	3	3	3	3	3	3	3	5	5	5	5	5	5
3	3	3	3	3	3	3	3	3	3	3	3	5	5	5	5	5	5
3	3	3	3	3	3	1	1	3	3	3	3	5	5	5	5	5	5
3	3	3	3	3	1	1	1	1	3	3	3	5	5	5	5	5	5
3	3	3	3	3	3	1	1	3	3	3	5	5	5	5	5	5	5
5	5	3	3	3	3	1	1	3	3	5	5	5	5	5	5	5	5
4	4	3	4	1	1	1	1	1	1	4	4	4	5	5	5	5	5
4	4	3	4	1	1	1	1	1	1	4	4	4	4	4	5	5	5
4	4	4	1	1	1	1	1	1	1	1	4	4	4	4	4	4	4
3	3	3	1	1	1	1	1	1	1	4	4	4	4	4	4	4	4
3	3	3	1	2	2	1	1	1	1	4	4	4	4	4	4	4	4
3	3	3	1	2	2	1	1	1	1	4	4	4	4	4	4	4	4

Semantic Labels

1. Person
2. Purse
3. Plants/Grass
4. Sidewalk
5. Building/Structures

Источник

Как выглядит результат предсказания

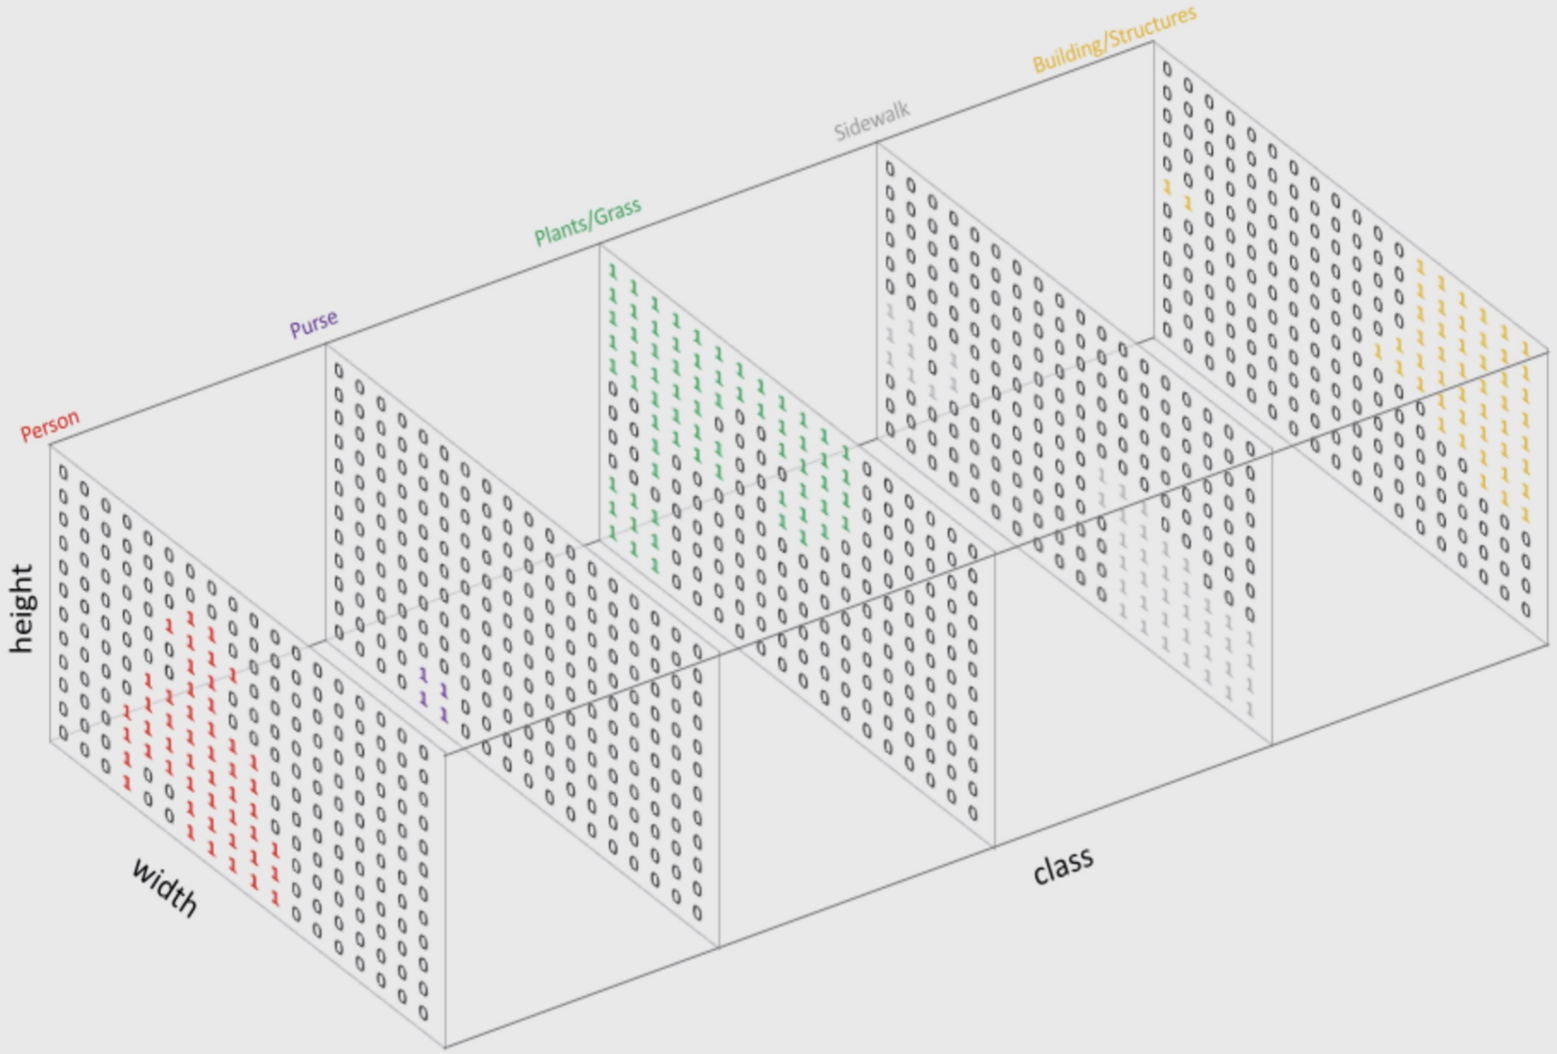

Источник

Как обучаем и получаем маску

Пример: один класс человек

Одна фичемапа на выходе: вероятность «человека» для каждого пикселя

Изображение

→ **Сеть** → sigmoid →

Предсказание

0,1	0,2	0,1	0,1
0,2	0,8	0,9	0,1
0,1	0,7	0,4	0,2
0,2	0,9	0,8	0,1

B×1×H×W

Обучение

LOSS

При обучении порог не применяем

GT-маска

0	0	0	0
0	1	1	0
0	1	1	0
0	1	1	0

Инференс

Порог 0,5 →

pred-маска

0	0	0	0
0	1	1	0
0	1	0	0
0	1	1	0

1 — человек, 0 — фон

Если классов несколько

Сеть выдаёт по фичемапе на класс, в том числе на класс фон.

Softmax

фон	человек	здание
0,05	0,80	0,15

Значения с разных фичемап в одном пикселе

argmax → **человек**

При обучении: CrossEntropy для каждого вектора для каждого пикселя

Где нужна сегментация

- Сегментация нужна там, где точности локализации боксами недостаточно.
- Самые частые кейсы — в беспилотном транспорте и в медицинских задачах.

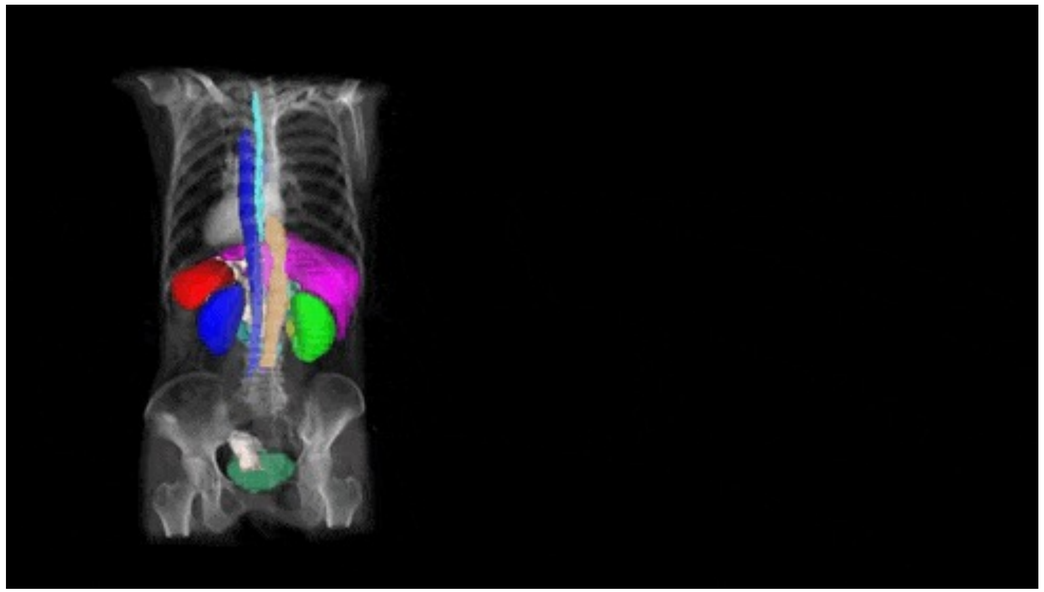

Источник

Бенчмарки

Table 1: A list of various datasets in the image segmentation domain

Category	Dataset
Natural Scenes	Berkeley Segmentation Dataset [140]
	PASCAL VOC [54]
	Stanford Background Dataset [72]
	Microsoft COCO [122]
	MIT Scene parsing data(ADE20K) [222, 223]
	Semantic Boundaries Dataset [75]
	Microsoft Research Cambridge Object Recognition Image Database (MSRC) [188]
Video Segmentation Dataset	Densely Annotated Video Segmentation(DAVIS) [168]
	Video Segmentation Benchmark(VSB100) [64]
	YouTube-Video object Segmentation [209]
Autonomous Driving	Cambridge-driving Labeled Video Database (CamVid) [23]
	Cityscapes: Semantic Urban Scene Understanding [41]
	Mapillary Vistas Dataset [155]
	SYNTHIA: Synthetic collection of Imagery and Annotations [178]
	KITTI Vision Benchmark Suite [67]
	Berkeley Deep Drive [212]
	India Driving Dataset(IDD) [202]
Aerial Imaging	Inria Aerial Image Labeling Dataset [134]
	Aerial Image Segmentation Dataset [213]
	ISPRS Dataset collection [57]
	Google Open Street Map [8]
	DeepGlobe [49]
Medical Imaging	DRIVE:Digital Retinal Images for Vessel Extraction [191]
	Sunnybrook Cardiac Data [171]
	Multiple Sclerosis Database [129, 25]
	IMT: Intima Media Thickness Segmentation Dataset [148]
	SCR: Segmentation in Chest Radiographs [201]
	BRATS: Brain Tumor Segmentation [146]
	LITS: Liver Tumour Segmentation [74]
	BACH: Breast Cancer Histology [6]
	IDRiD: Indian Diabetic Retinopathy Image Dataset [169]
	ISLES: Ischemic Stroke Lesion Segmentation [135]
Saliency Detection	MSRA Salient Object Database [37]
	ECSSD: Extended Complex Scene Saliency Dataset [187]
	PASCAL-S DATASET [117]
	THUR15K: Group Saliency in Image [36]
	JuddDB: MIT saliency benchmark [18]
	DUT-OMRON Image Dataset [210]
Scene Text Segmentation	KAIST Scene Text Database [112]
	COCO-Text [203]
	SVT: Street View Text Dataset [205]

По количеству бенчмарков по доменам тоже явно видно, где в основном нужна сегментация

Источник

Бенчмарки

Ключевой датасет для сегментации — ADE20k
(Как ImageNet для классификации и COCO для детекции/ключевых точек)

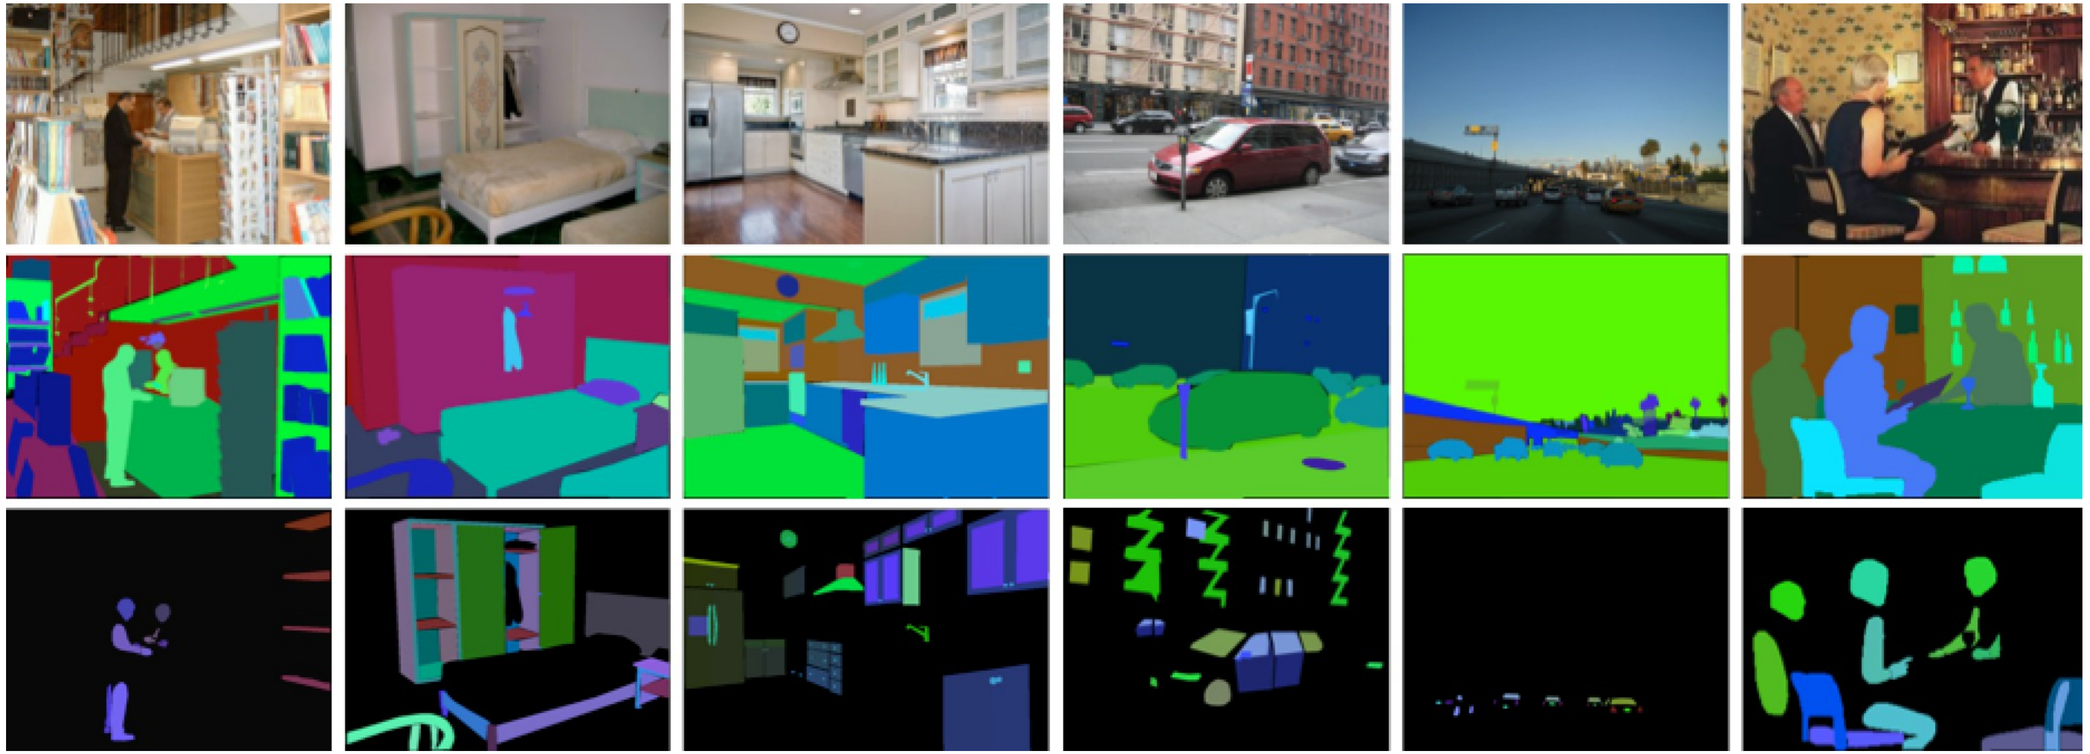

Источник

Метрики для семантической сегментации

01

Классификационные для всех пикселей:

- Pixel accuracy / mean Pixel Accuracy (MPA);
- Precision, Recall, F1-score.

Mean — везде имеется в виду усреднение по классам.

02

Метрики на множествах:

- mIoU — стандарт

$$\mathrm{IoU} = \frac{|A \cap B|}{|A \cup B|} \geq \alpha$$

Intersection Over Union

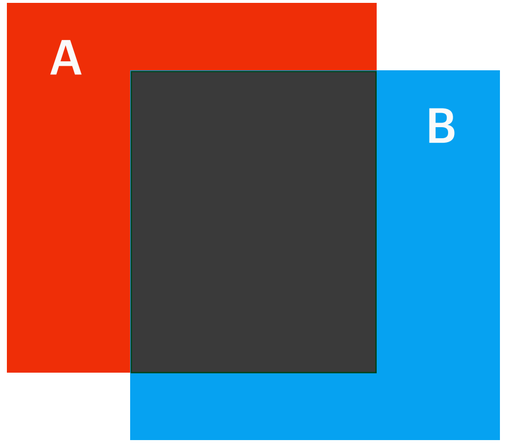

- mDice — лучше для мелких объектов

$$\text{Dice coefficient} = \frac{\text{2x area of overlapped (green)}}{\text{total area (green)}} = \frac{2 \times}{}$$

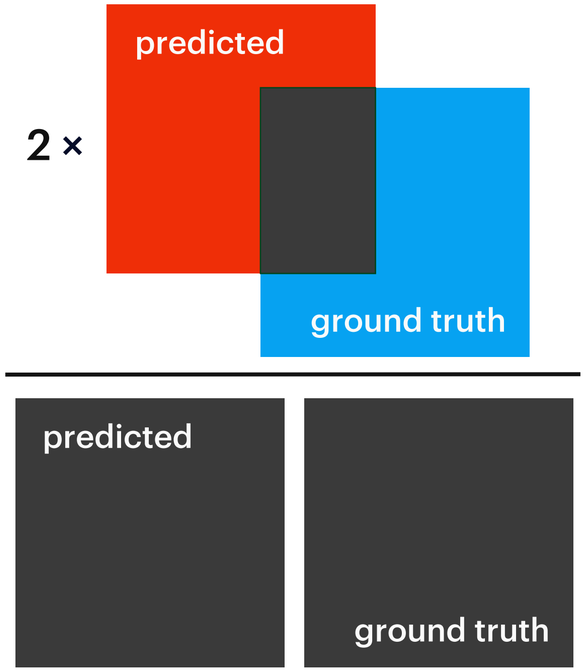

Источник

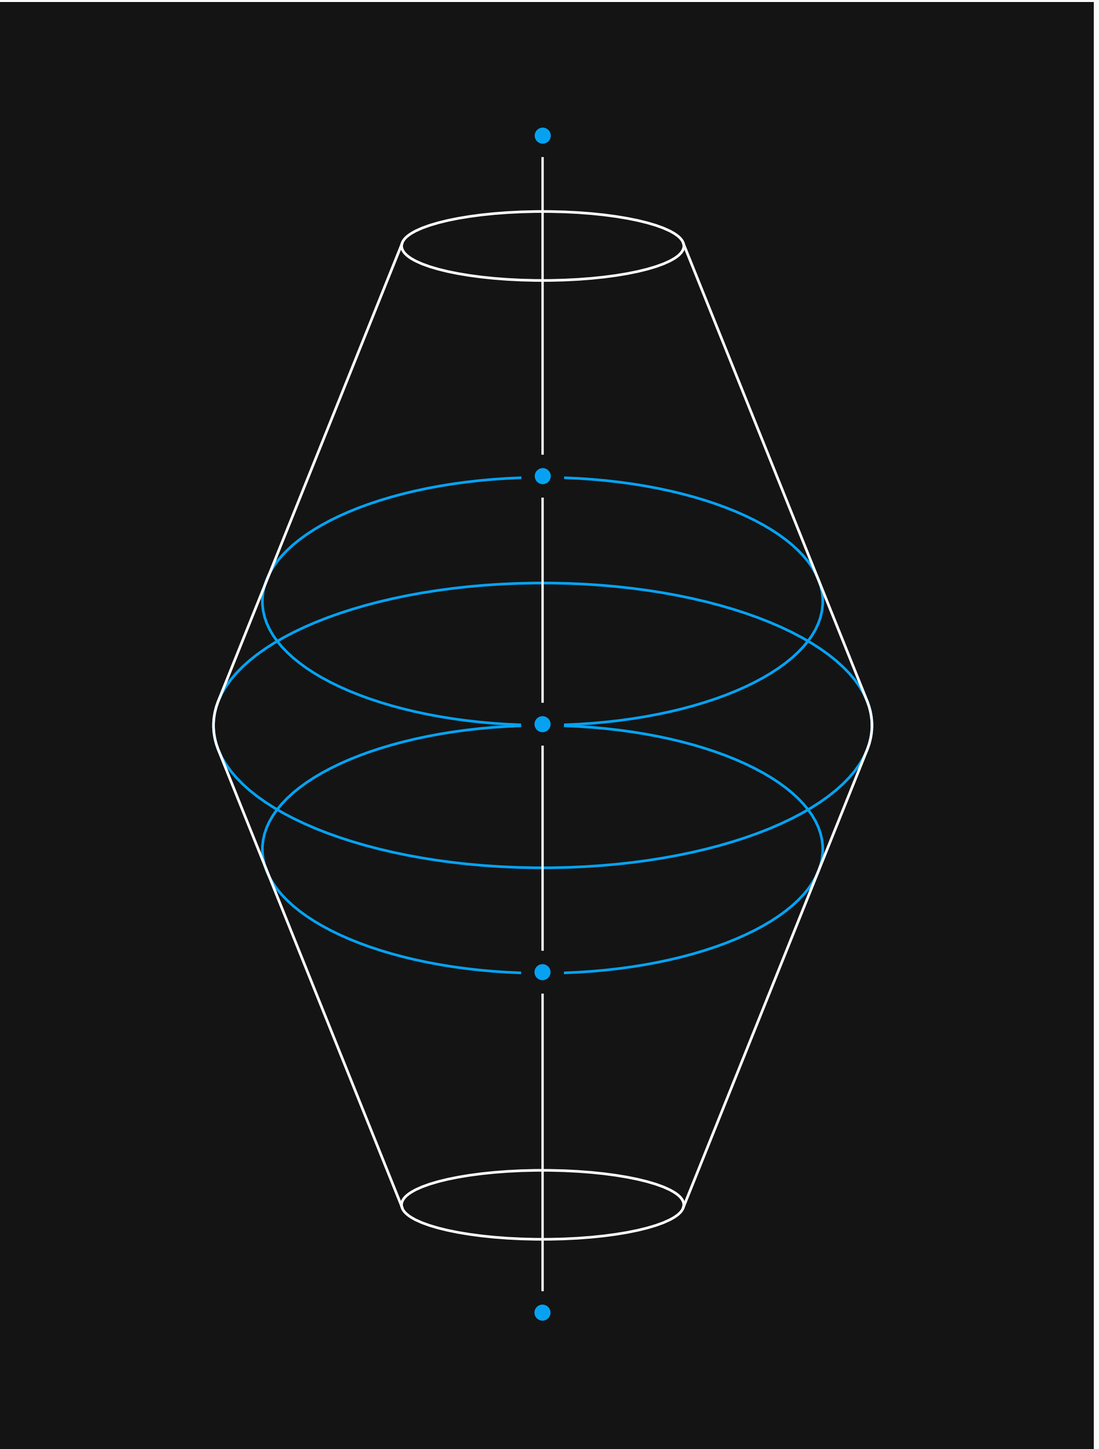

Loss-ы для сегментации

01 **Классификационные функции потерь для пикселей**

- Cross-Entropy Loss, Focal loss

02 **Функции потерь для множества**

- Dice loss, IoU loss

03 **Их комбинация**

Источник

Loss-ы для сегментации

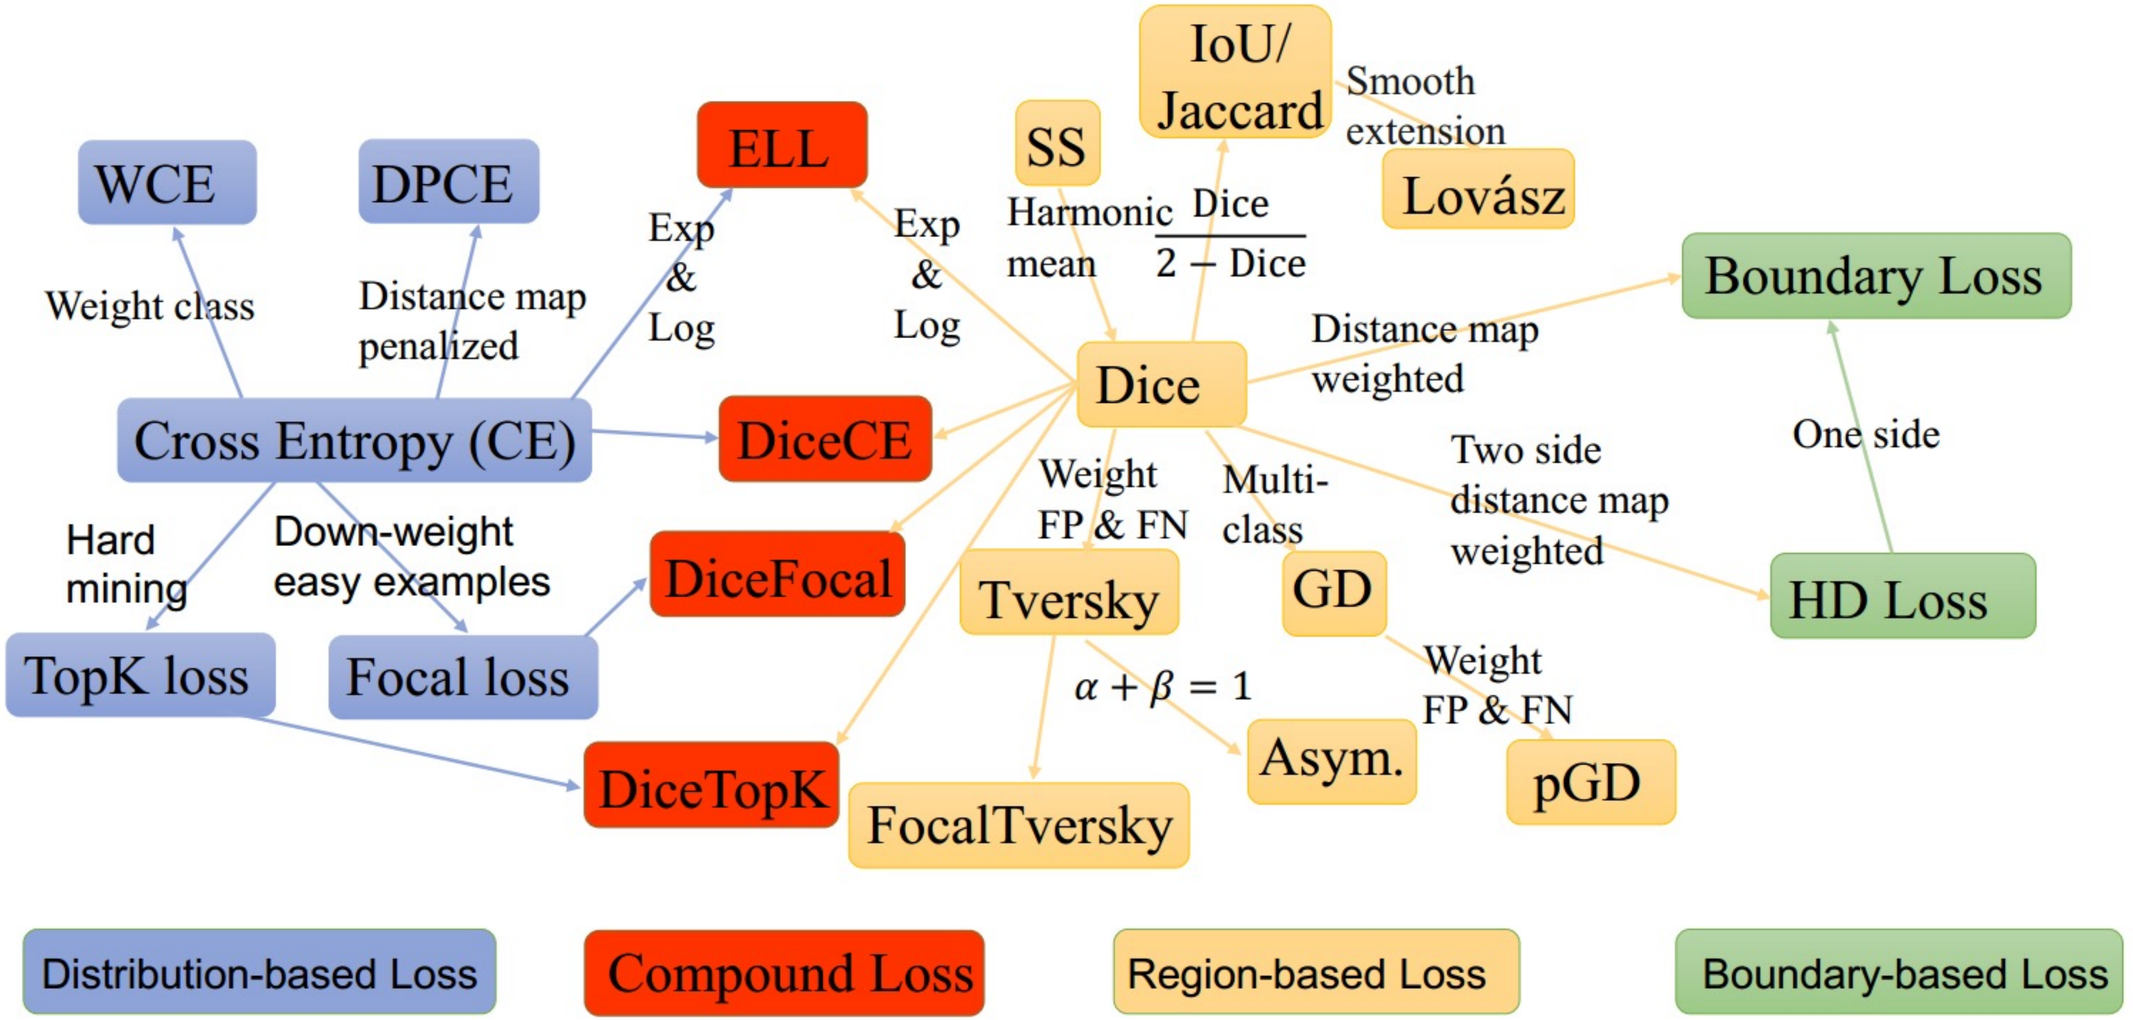

Источник: https://github.com/JunMa11/SegLossOdyssey

Резюме

01 Сегментация — это тоже классификация, но на уровне пикселей, а не целого изображения.

02 Сегментация бывает разных видов: семантическая, инстанс, паноптик.

03 Области применения сегментации самые разные, но наиболее популярные — медицинские изображения и беспилотное вождение.

04 Метрики и лоссы для сегментации могут быть попиксельные — такие же, как у классификации, а могут быть на множествах — рассматривающие маски в целом.

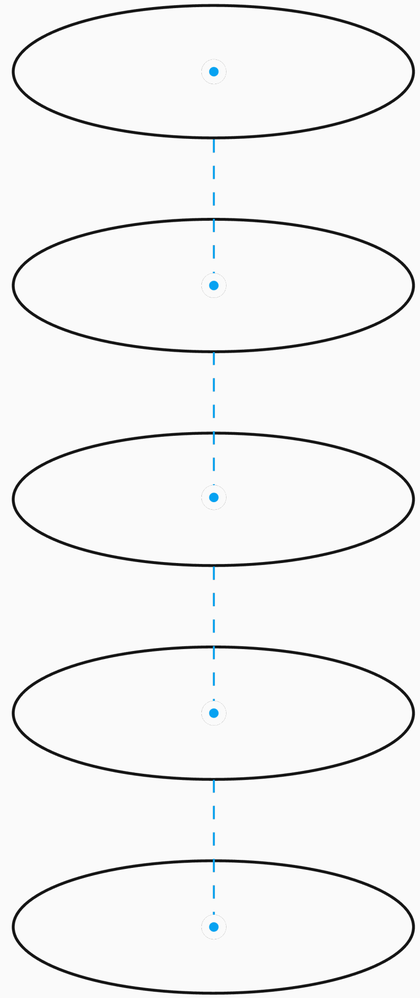

План

01 Введение, датасеты и метрики

02 UNet

03 Кто, если не UNet

04 Трансформерные модели

05 Segment Anything Model (SAM)

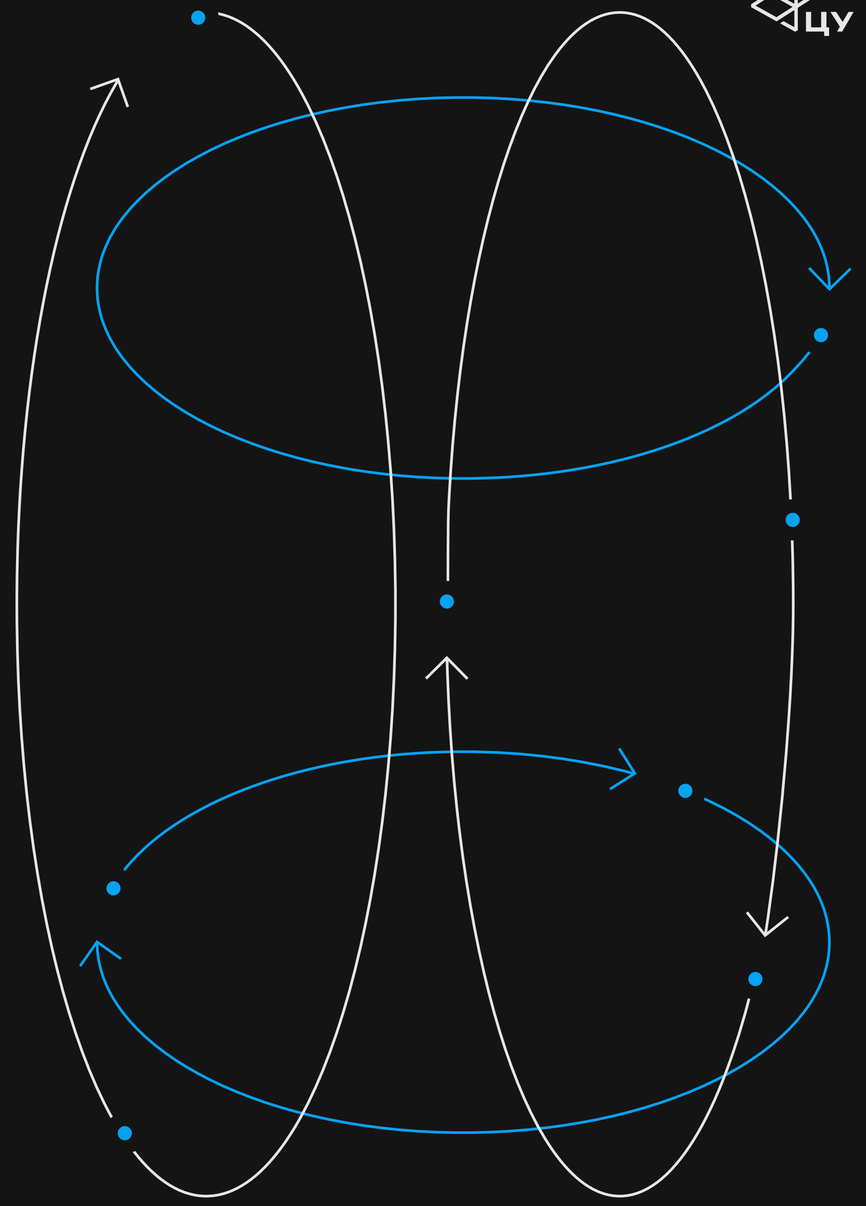

Как можно решить задачу, но не стоит

Возьмём просто CNN, которая будет работать на входном разрешении.

Получится и **неточно** (контекст очень маленький), и по вычислительной сложности это будет **просто жесть**.

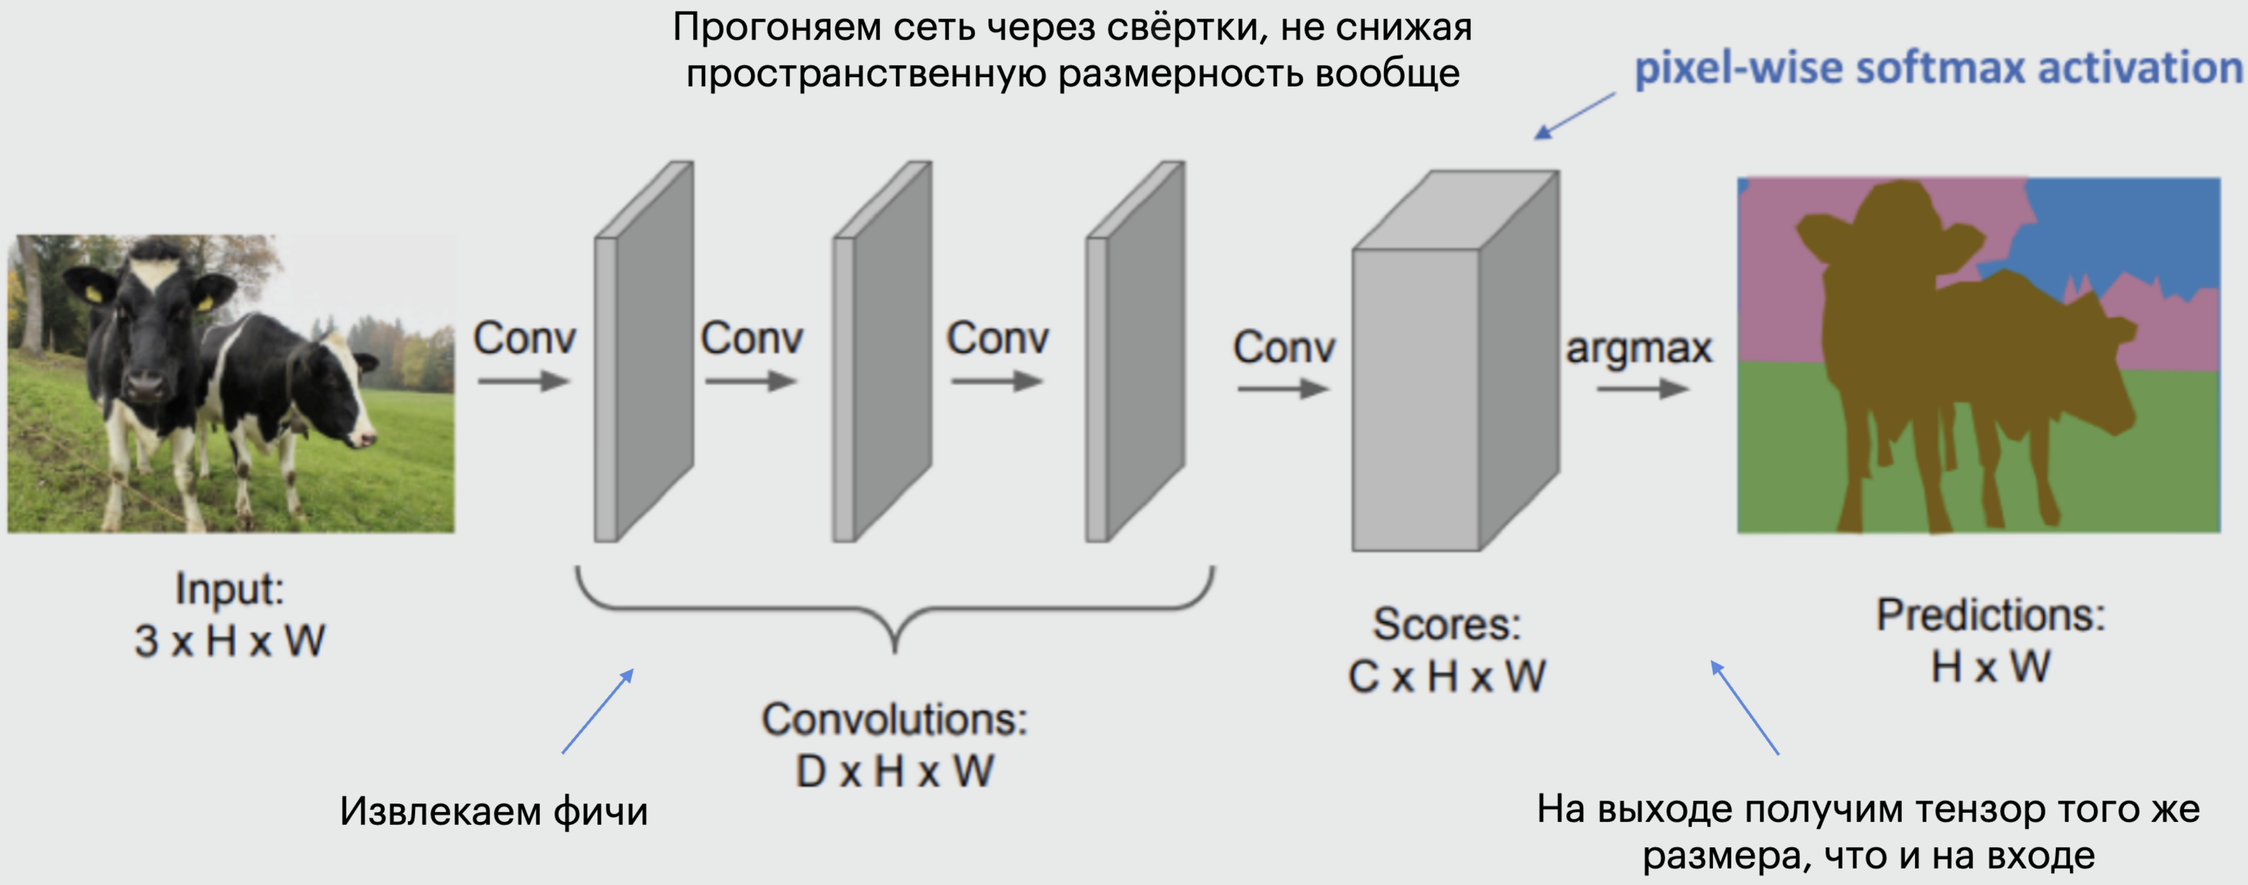

Источник

Как можно решить задачу, но не стоит

Это **Fully-Convolutional Network (FCN).**

Получится вычислительно несложно, по контексту уже немного лучше, по точности локализации это будет **просто жесть.**

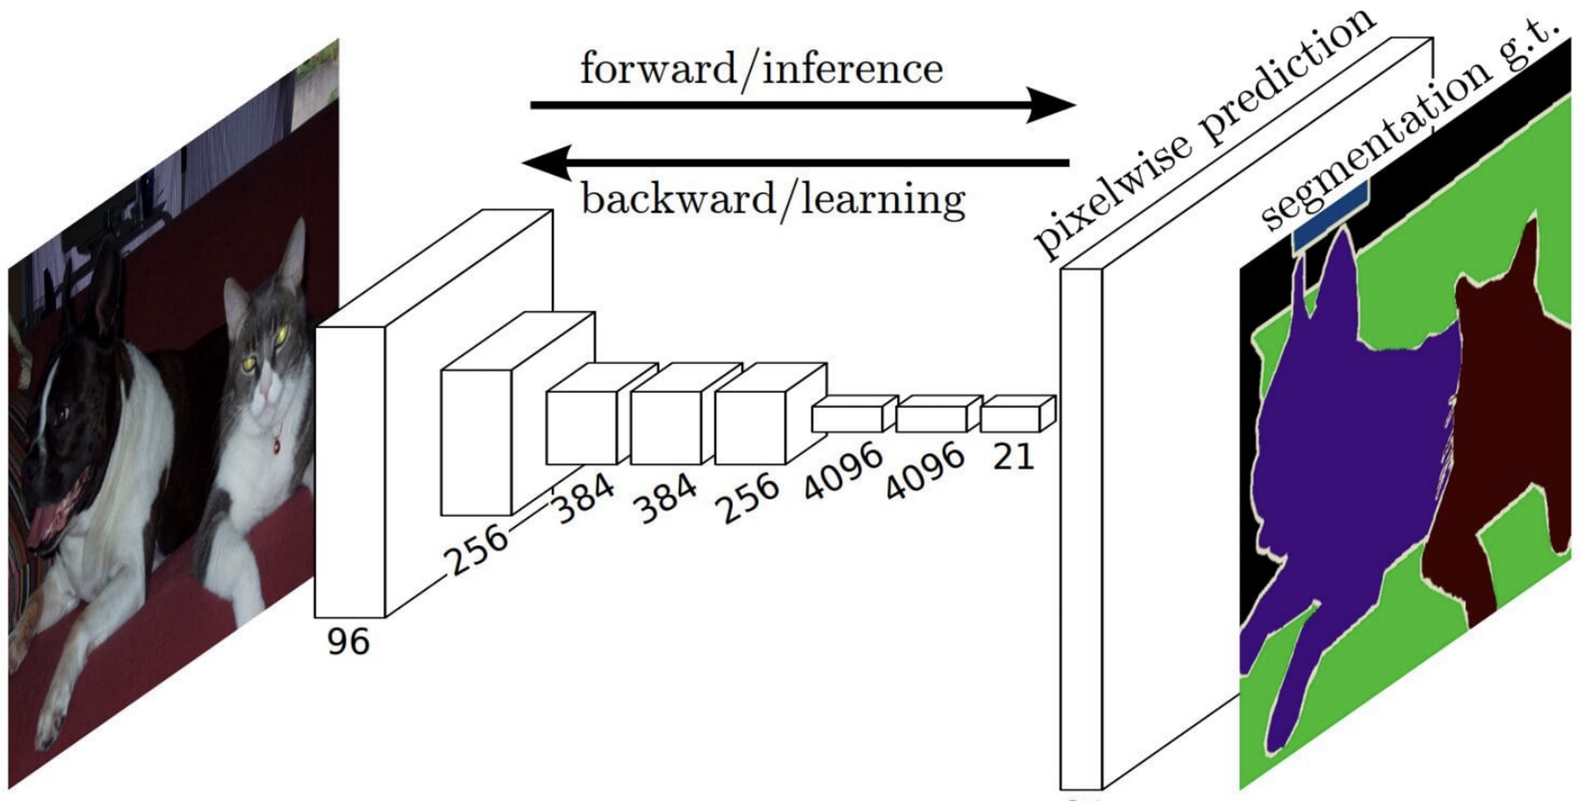

Источник

Как стоит решить задачу: UNet (MICCAI 2015)

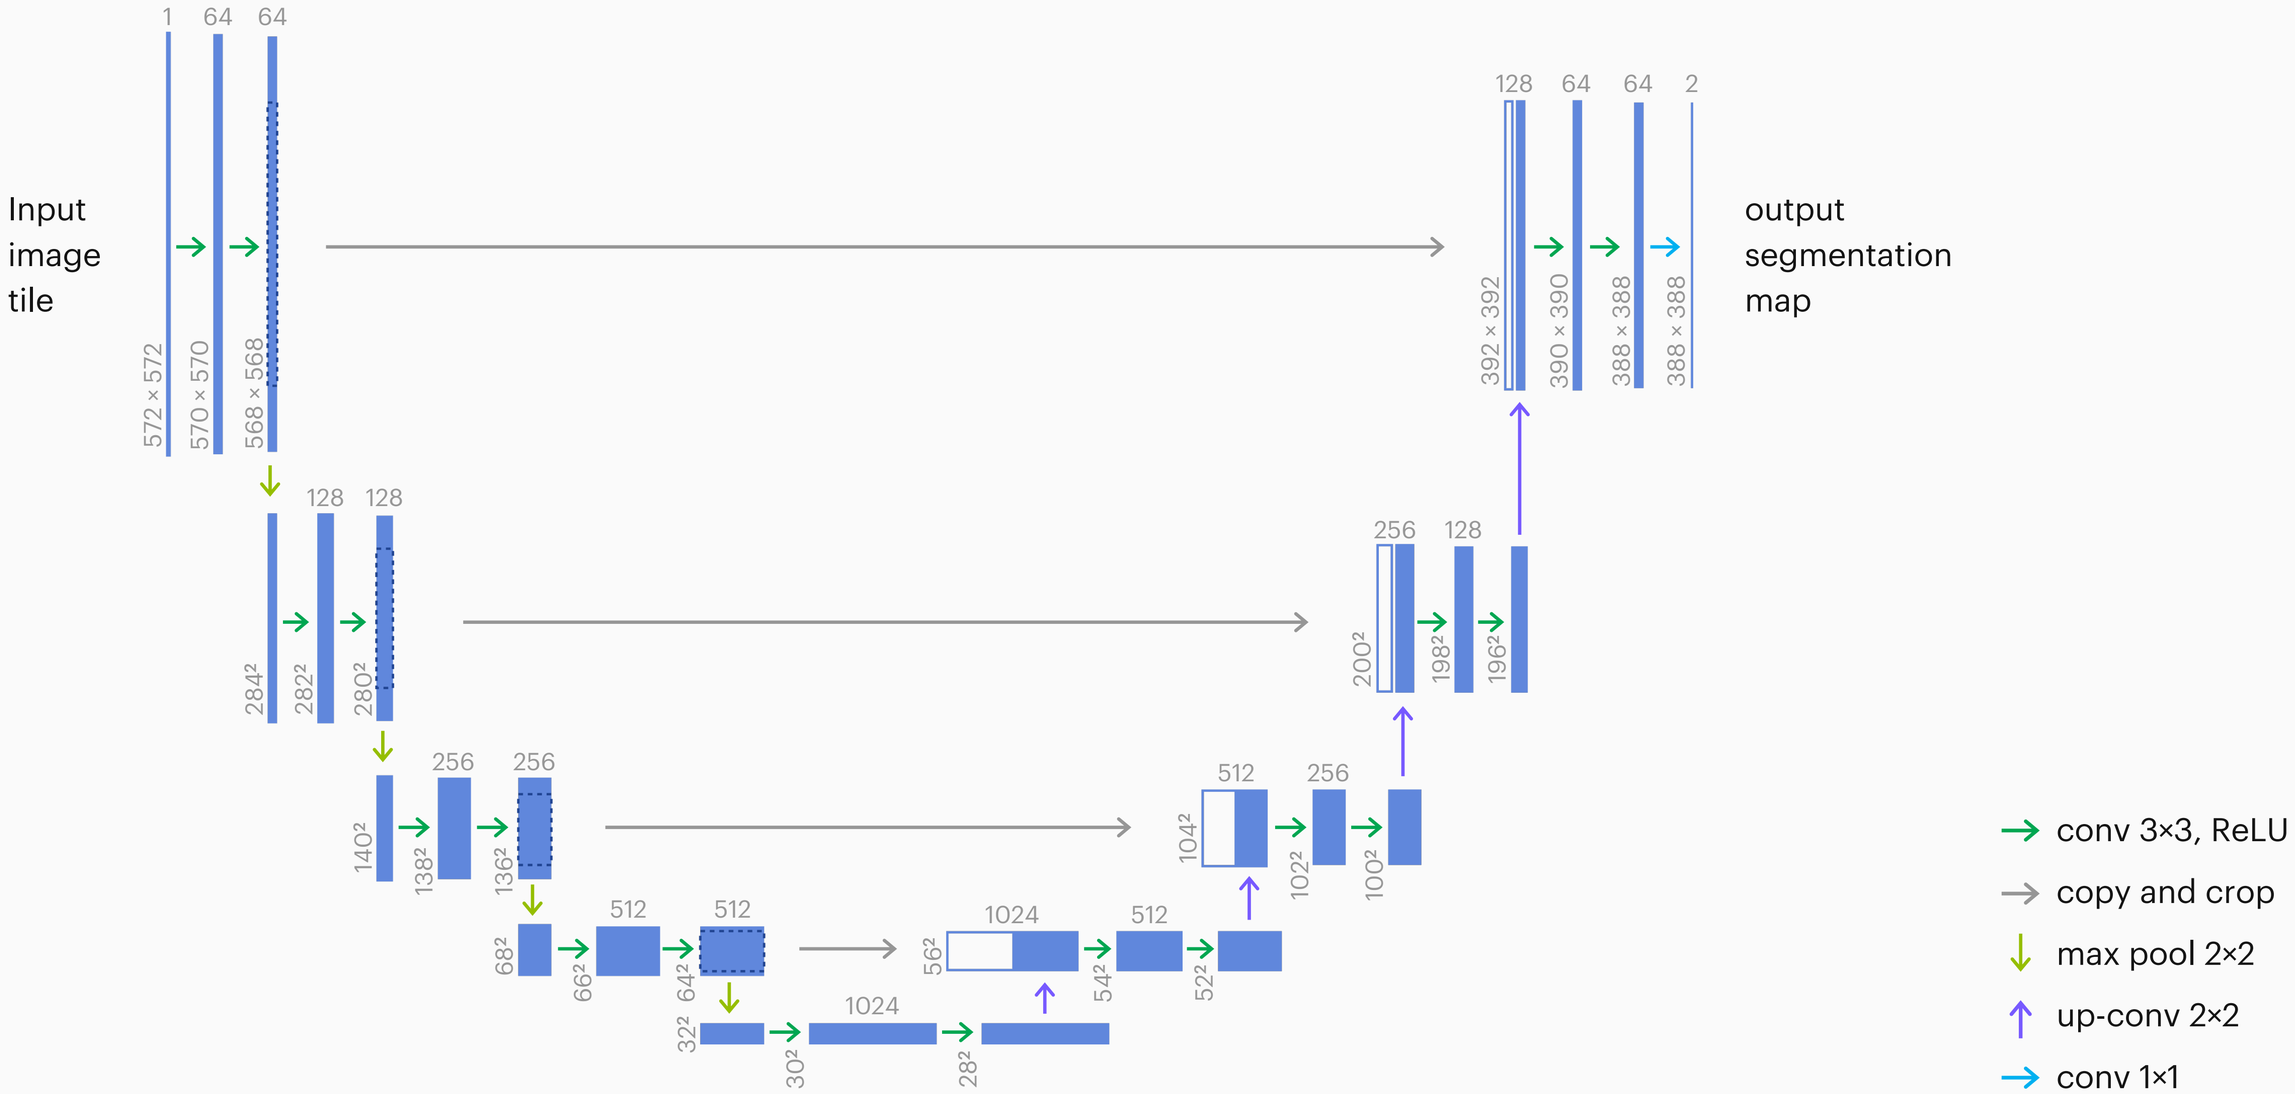

Источник

Как стоит решить задачу: UNet

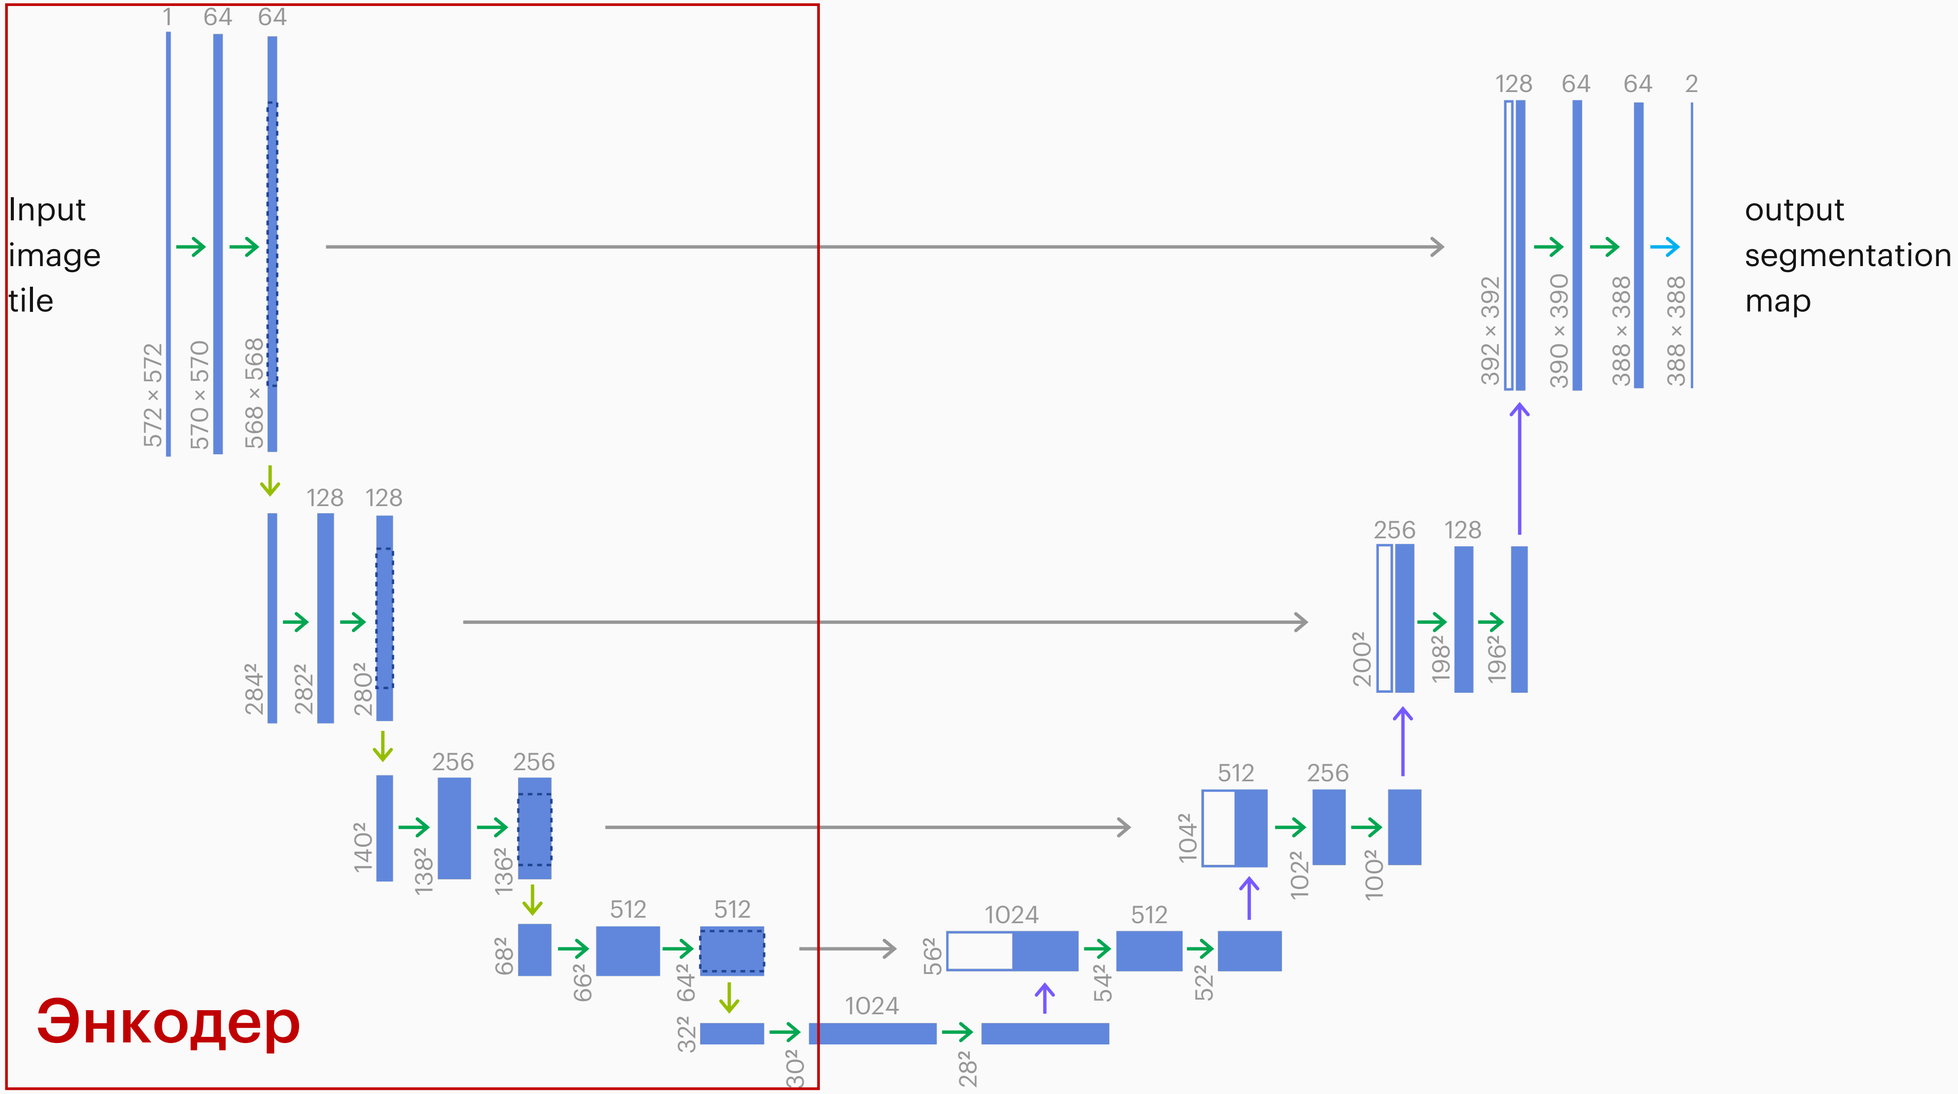

Источник

Как стоит решить задачу: UNet

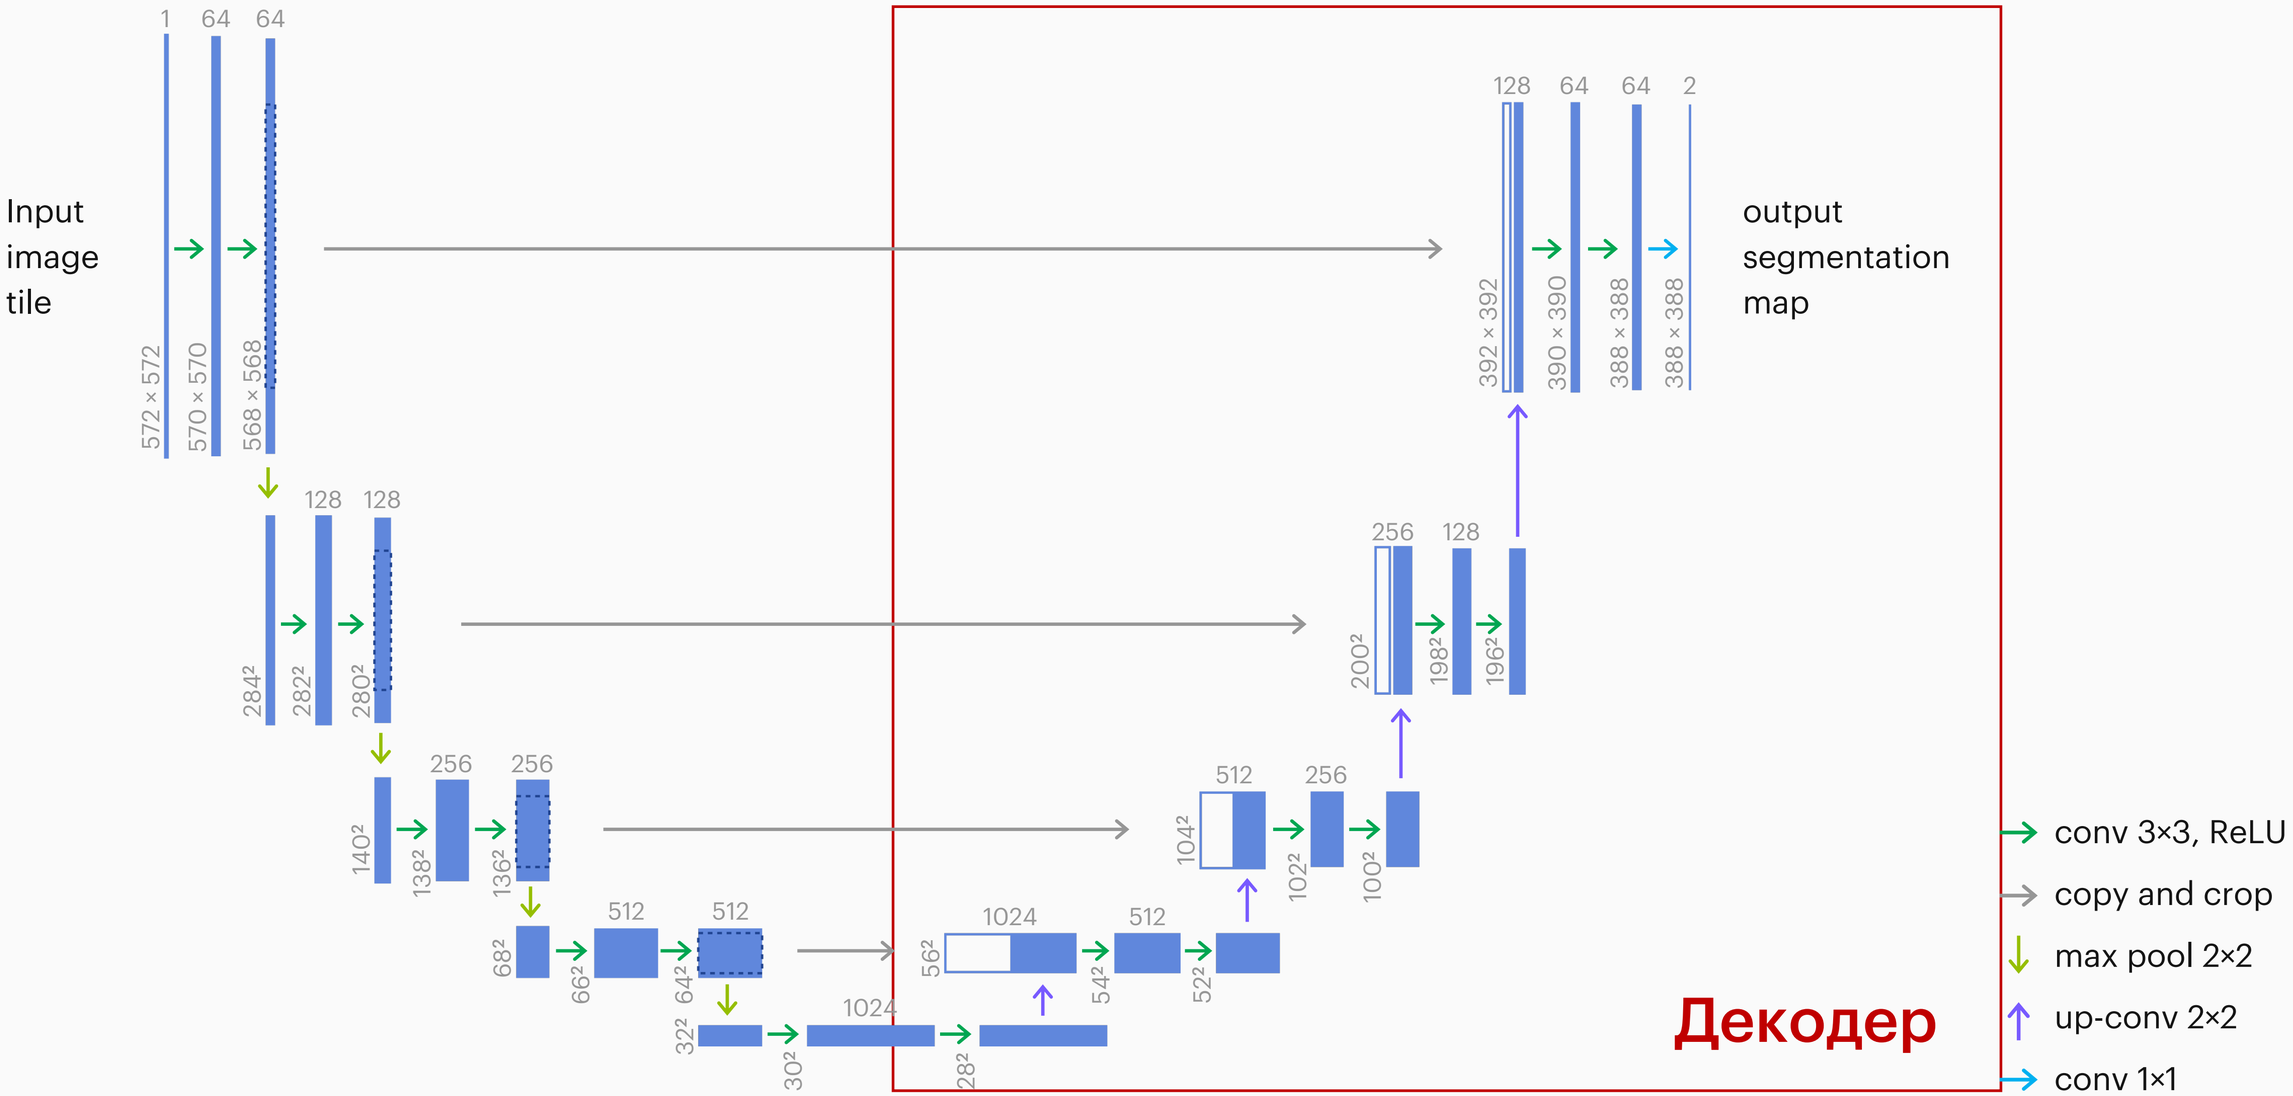

Источник

Как стоит решить задачу: UNet

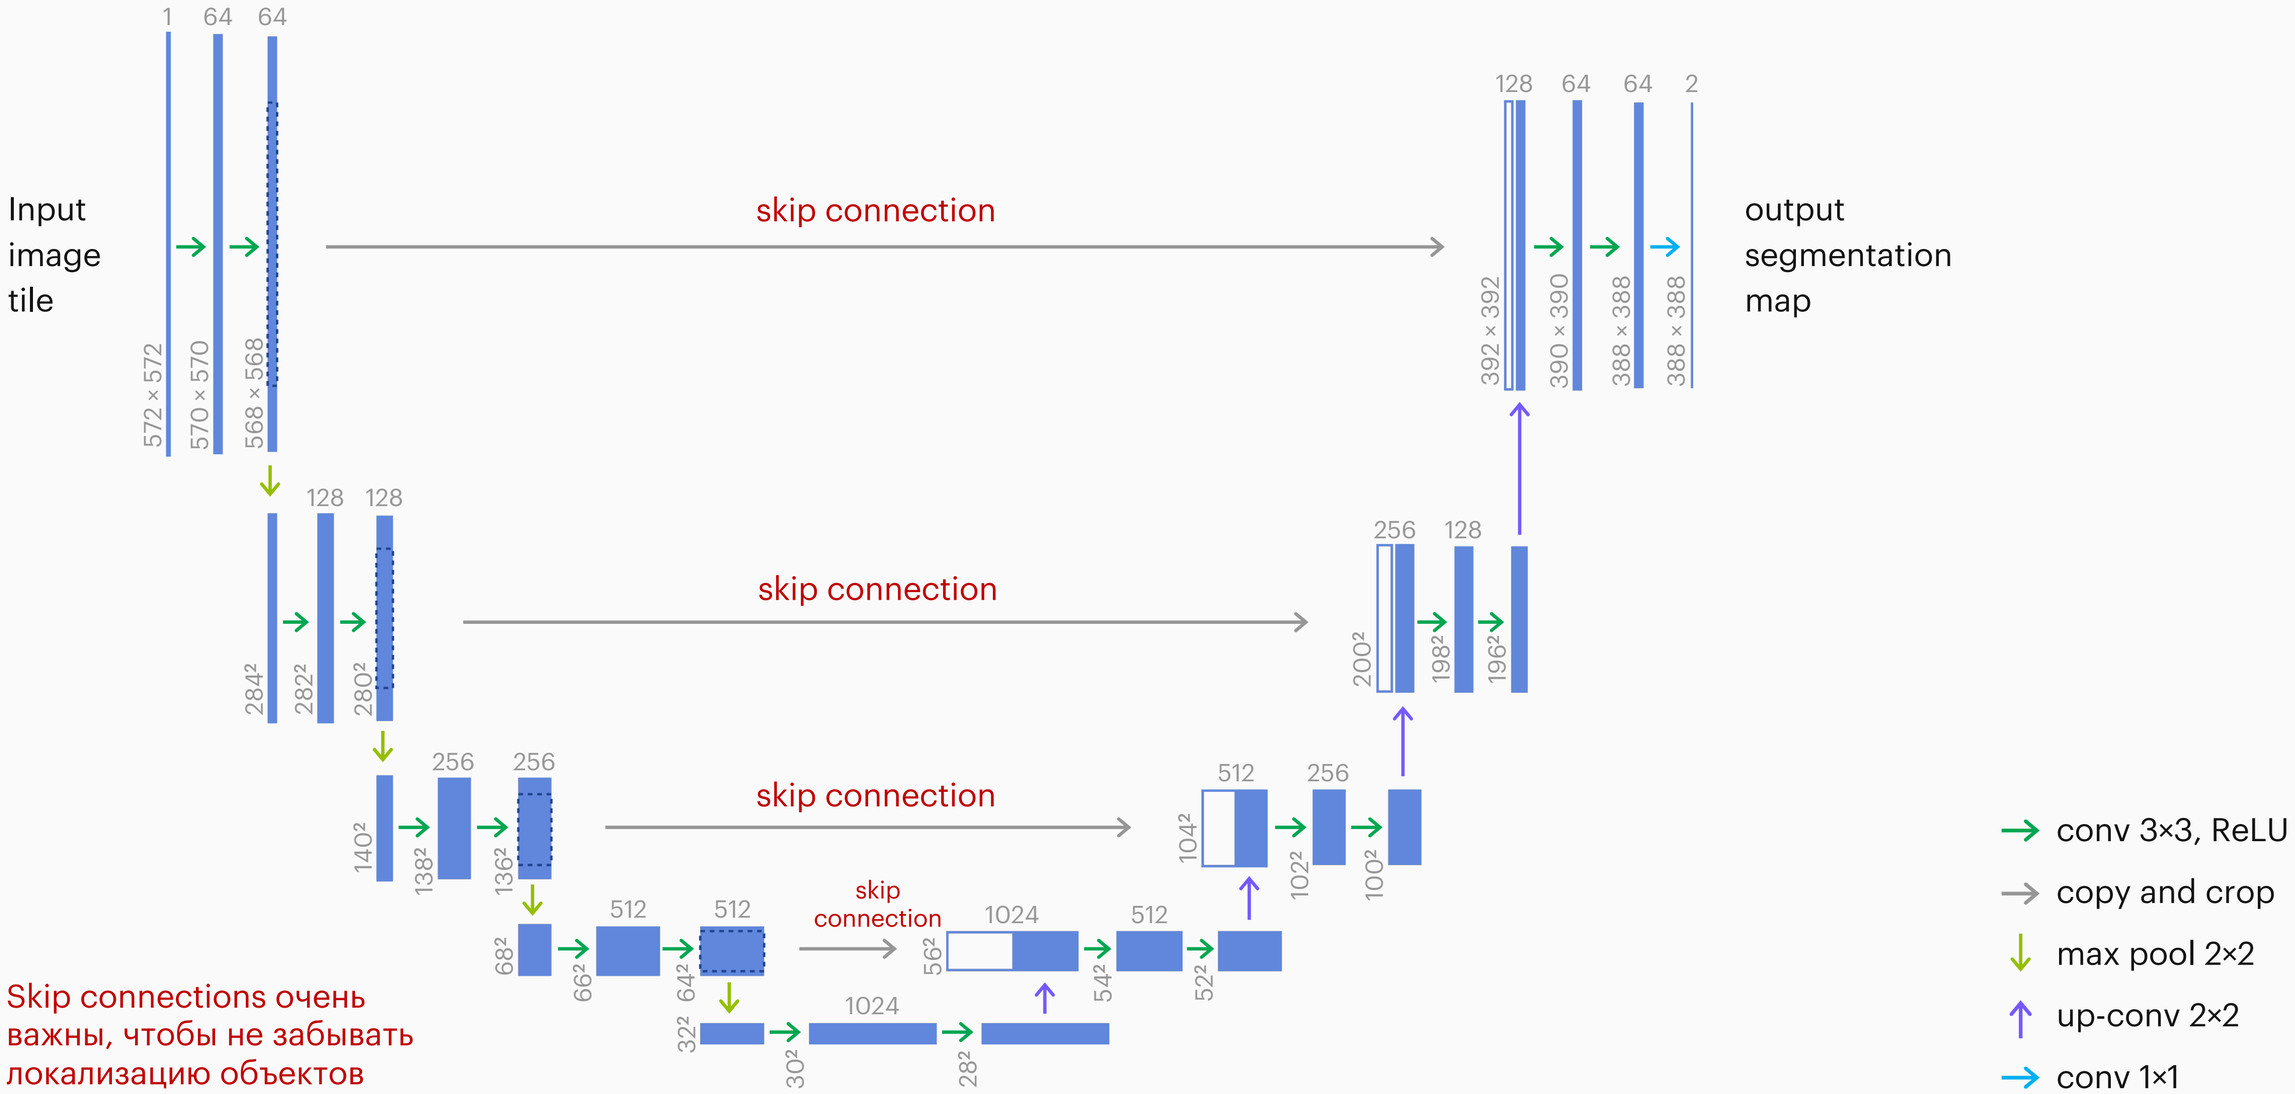

Skip connections очень важны, чтобы не забывать локализацию объектов

Источник

Как стоит решить задачу: UNet

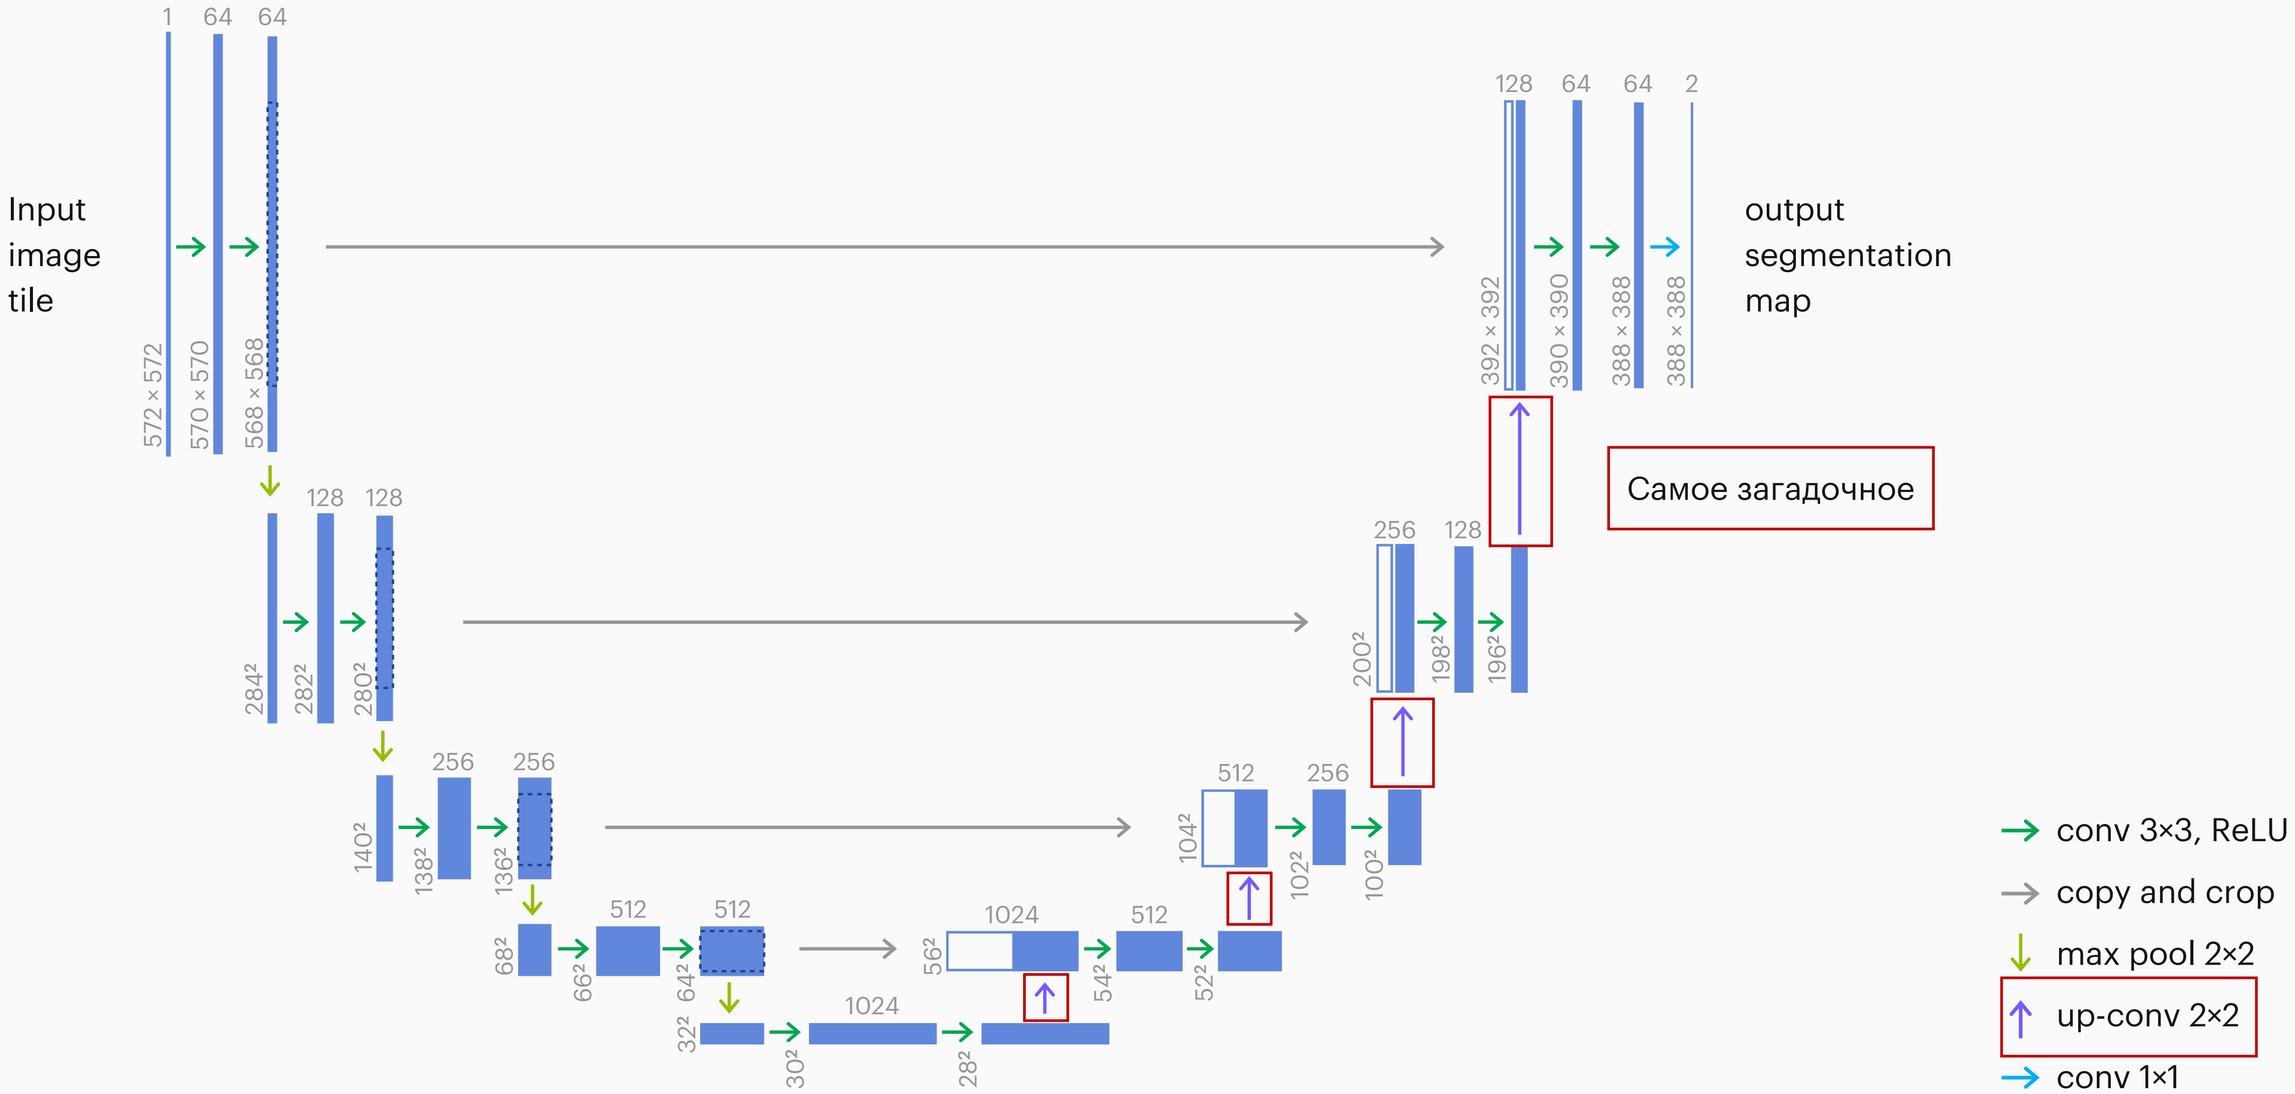

Источник

Как делать Upscaling: с Transposed convolution

Можно сделать апскейлинг за одну операцию: Transposed conv.

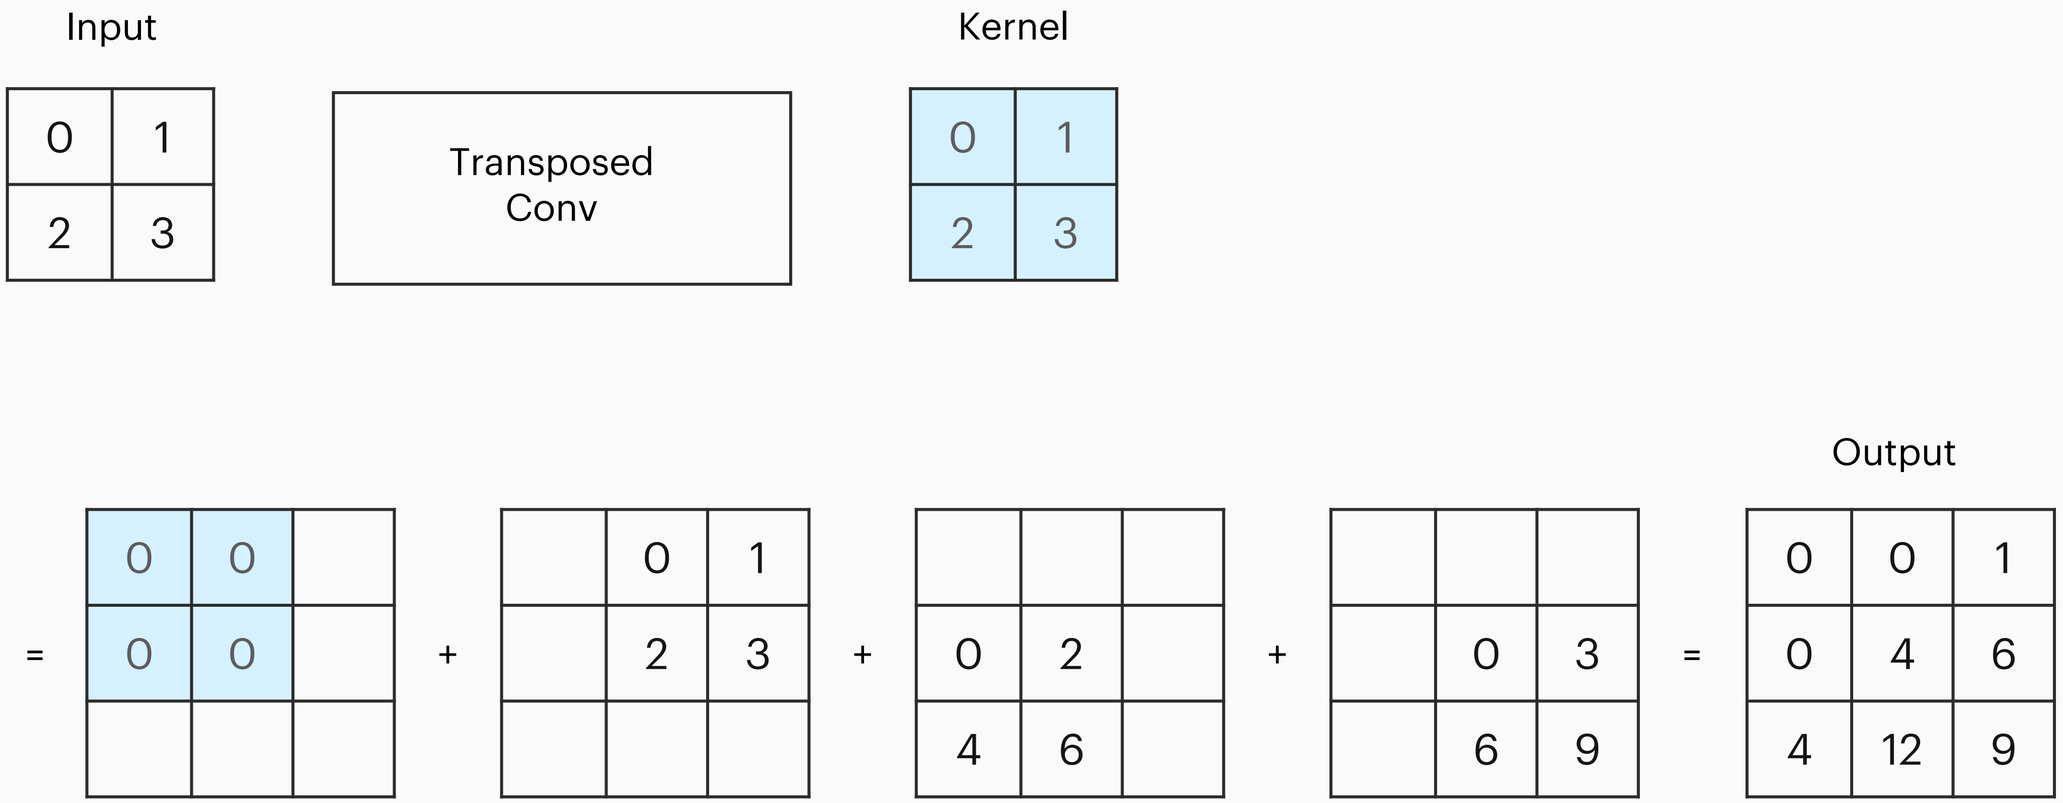

Источник

Проблемы с Transposed convolution

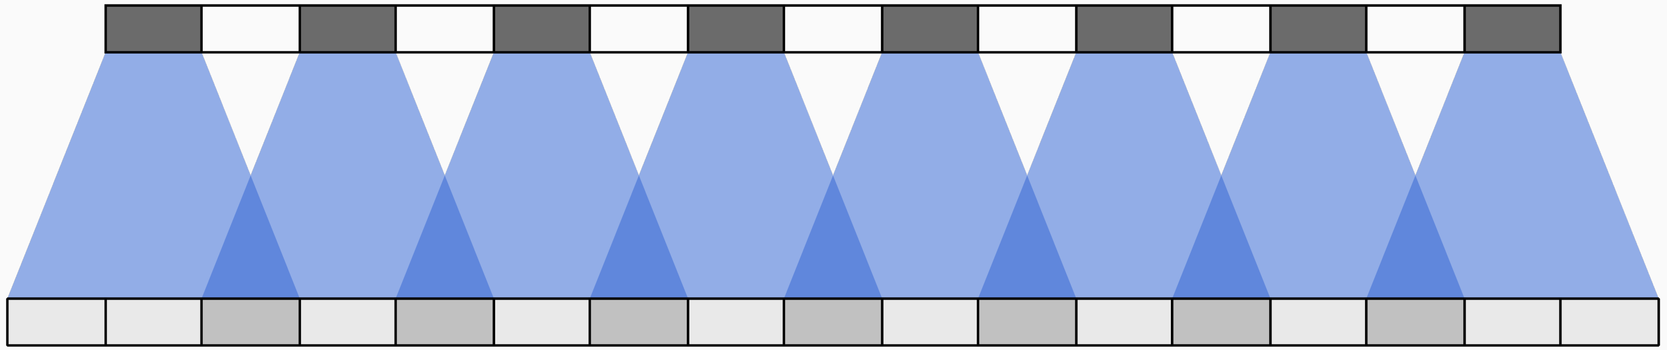

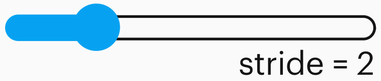

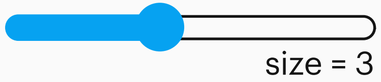

Некоторые элементы новой матрицы получаются из сложения нескольких старых элементов,
и там накапливаются большие значения

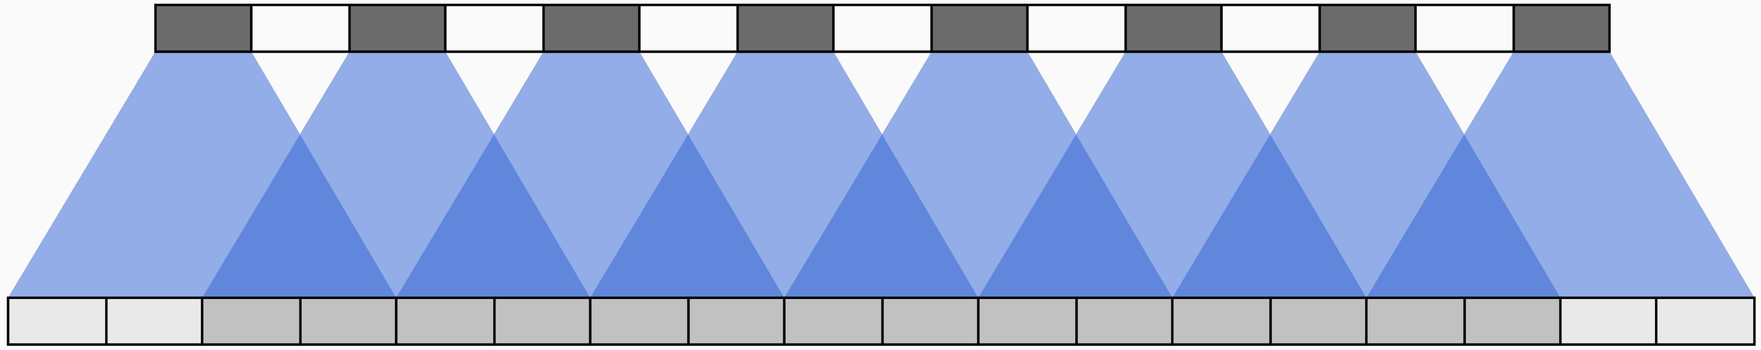

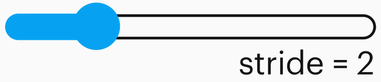

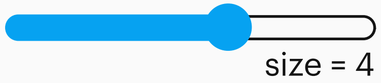

Ситуация выравнивается, если размер ядра свёртки будет кратен stride

Источник

Проблемы с Transposed convolution

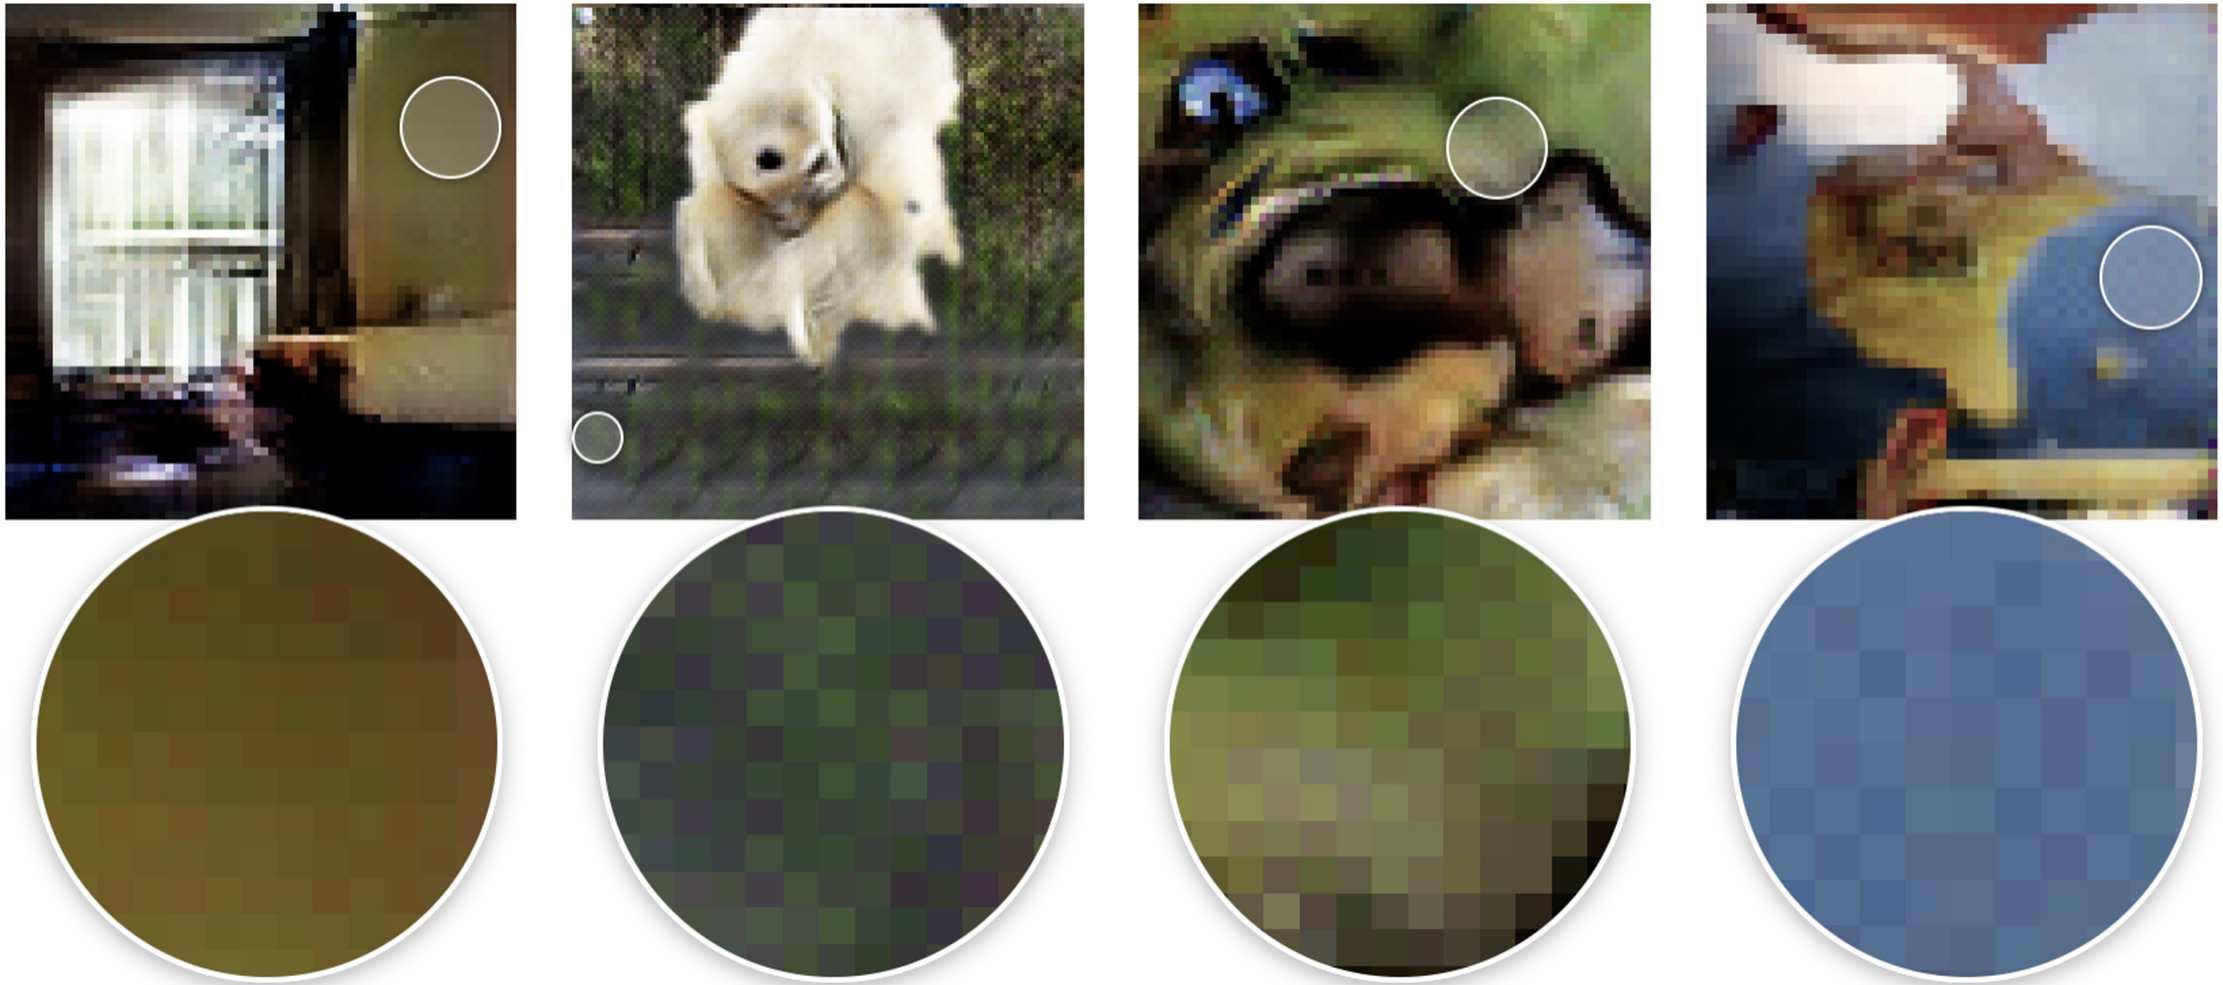

Источник

Как делать Upscaling: с интерполяцией

Апскейлинг фичемап можно сделать за две операции: Upsample + Conv2d и никаких проблем с артефактами.

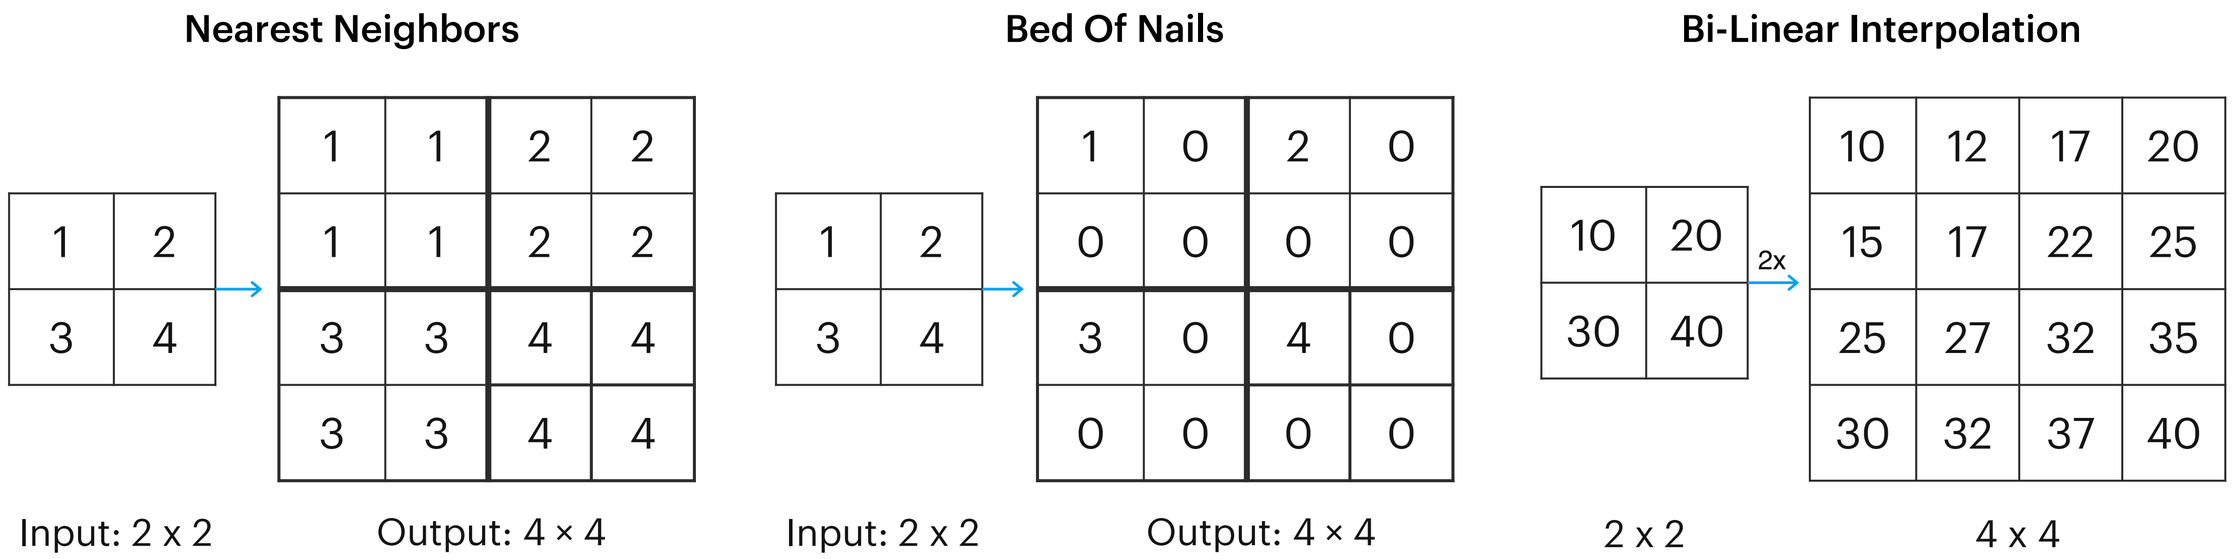

Источник

Резюме

01 Чтобы решить задачу сегментации, важно учесть глобальный контекст и точно выдавать предсказания для конкретного пикселя.

02 UNet — это архитектура, которая соответствует обоим требованиям. На стадии энкодинга сеть понимает глобальный контекст, на стадии декодинга возвращается к первоначальному разрешению и может предсказывать лейблы с хорошей локализацией.

03 Стадия энкодинга в UNet — это обычная CNN, а может быть и ViT.

04 Декодинг в UNet может осуществляться через Интерполяцию + Conv2d или с помощью Transposed convs. Нужно учитывать кратность ядер, чтобы не получить шахматные артефакты.

05 Очень важно, что в UNet есть skip connections, которые позволяют при декодировании не забывать контекст разных уровней.

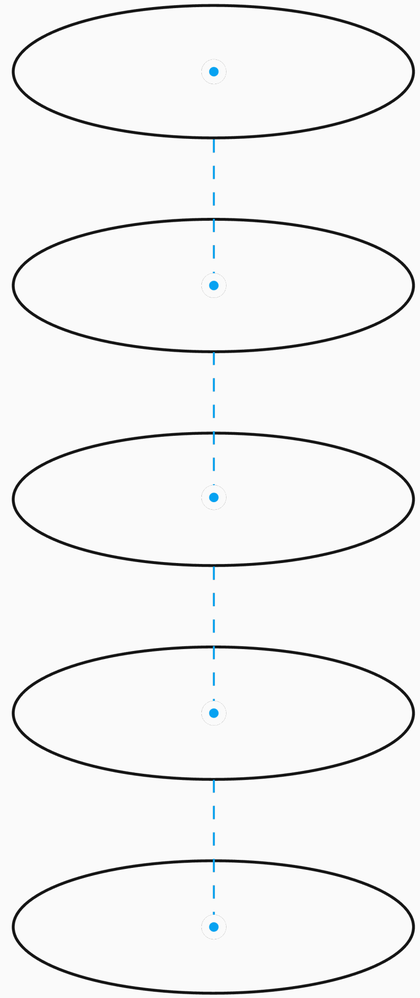

План

01 Введение, датасеты и метрики

02 UNet

03 Кто, если не UNet

04 Трансформерные модели

05 Segment Anything Model (SAM)

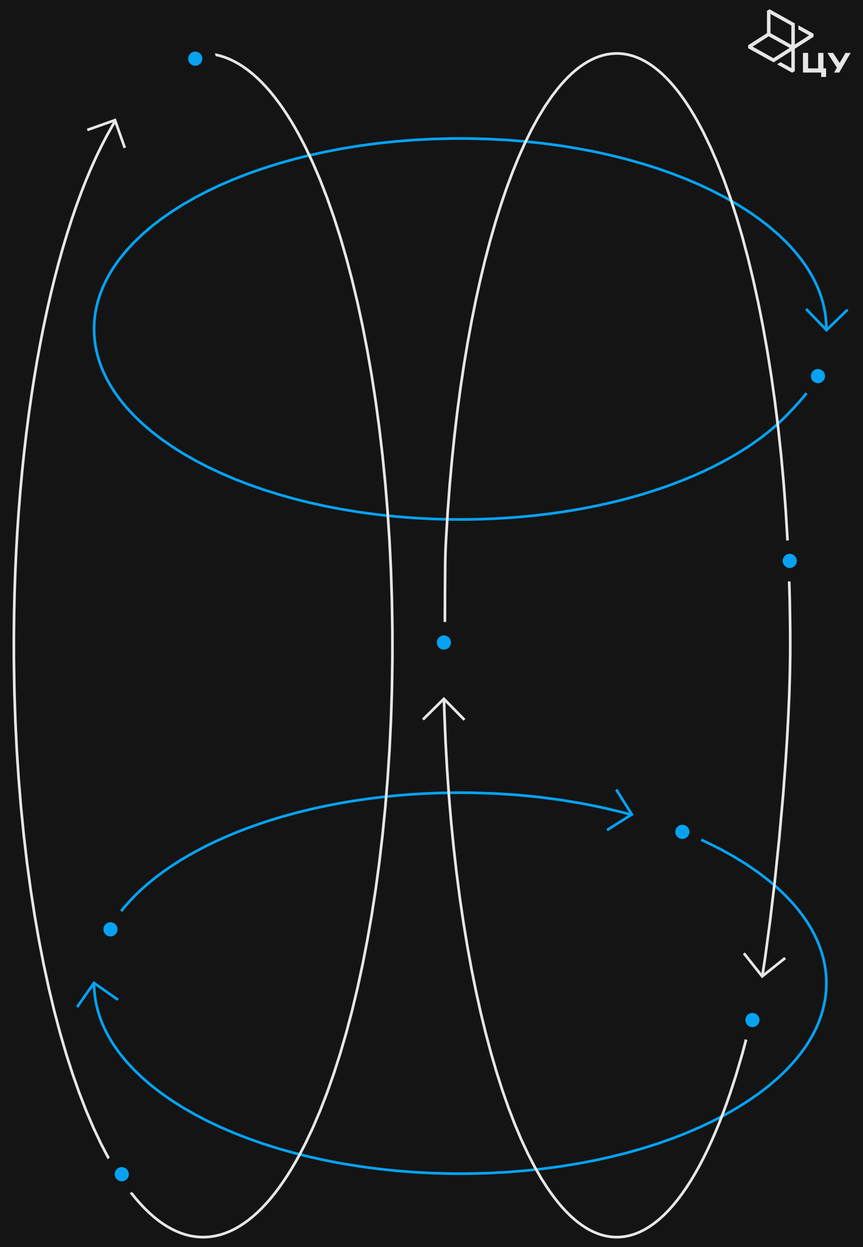

Кто, если не UNet

📦 Models

Architectures

- Unet [paper] [docs]
- Unet++ [paper] [docs]
- MAnet [paper] [docs]
- Linknet [paper] [docs]
- FPN [paper] [docs]
- PSPNet [paper] [docs]
- PAN [paper] [docs]
- DeepLabV3 [paper] [docs]
- DeepLabV3+ [paper] [docs]
- UPerNet [paper] [docs]

Encoders

The following is a list of supported encoders in the SMP. Select the appropriate family of encoders and click to expand the table and select a specific encoder and its pre-trained weights (`encoder_name` and `encoder_weights` parameters).

▶ ResNet

▶ ResNeXt

▶ ResNeSt

▶ Res2Ne(X)t

▶ RegNet(x/y)

▶ GERNet

▶ SE-Net

▶ SK-ResNe(X)t

▶ DenseNet

▶ Inception

▶ EfficientNet

▶ MobileNet

Источник

LinkNet (VCIP 2017)

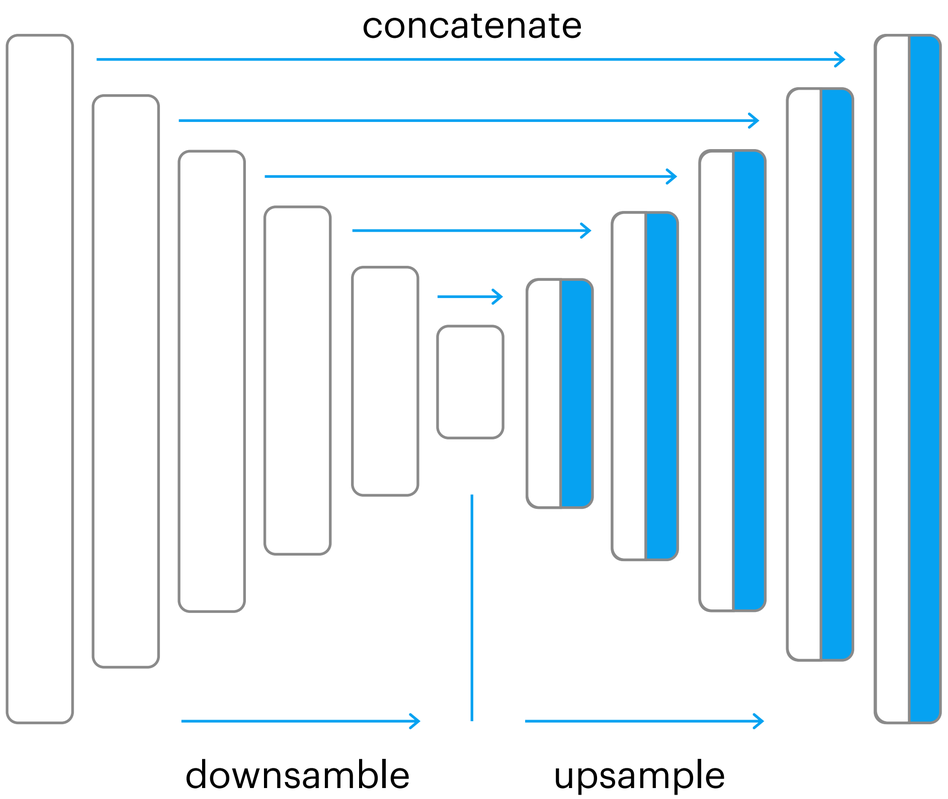

UNet

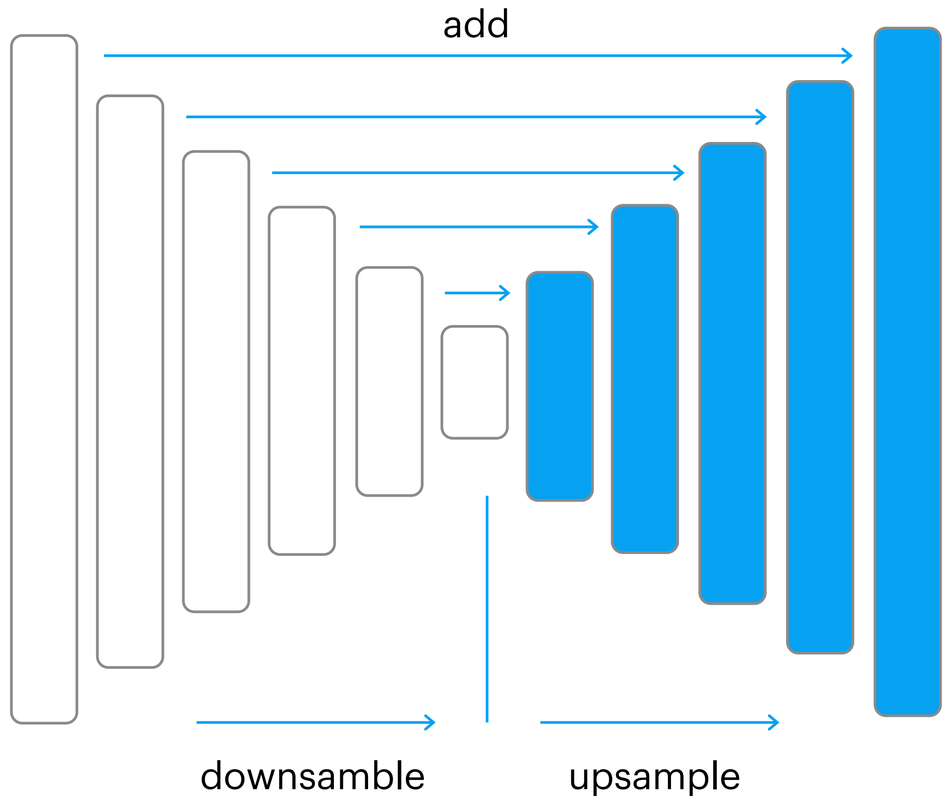

LinkNet

Источник

UNet++ (MICCAI 2018)

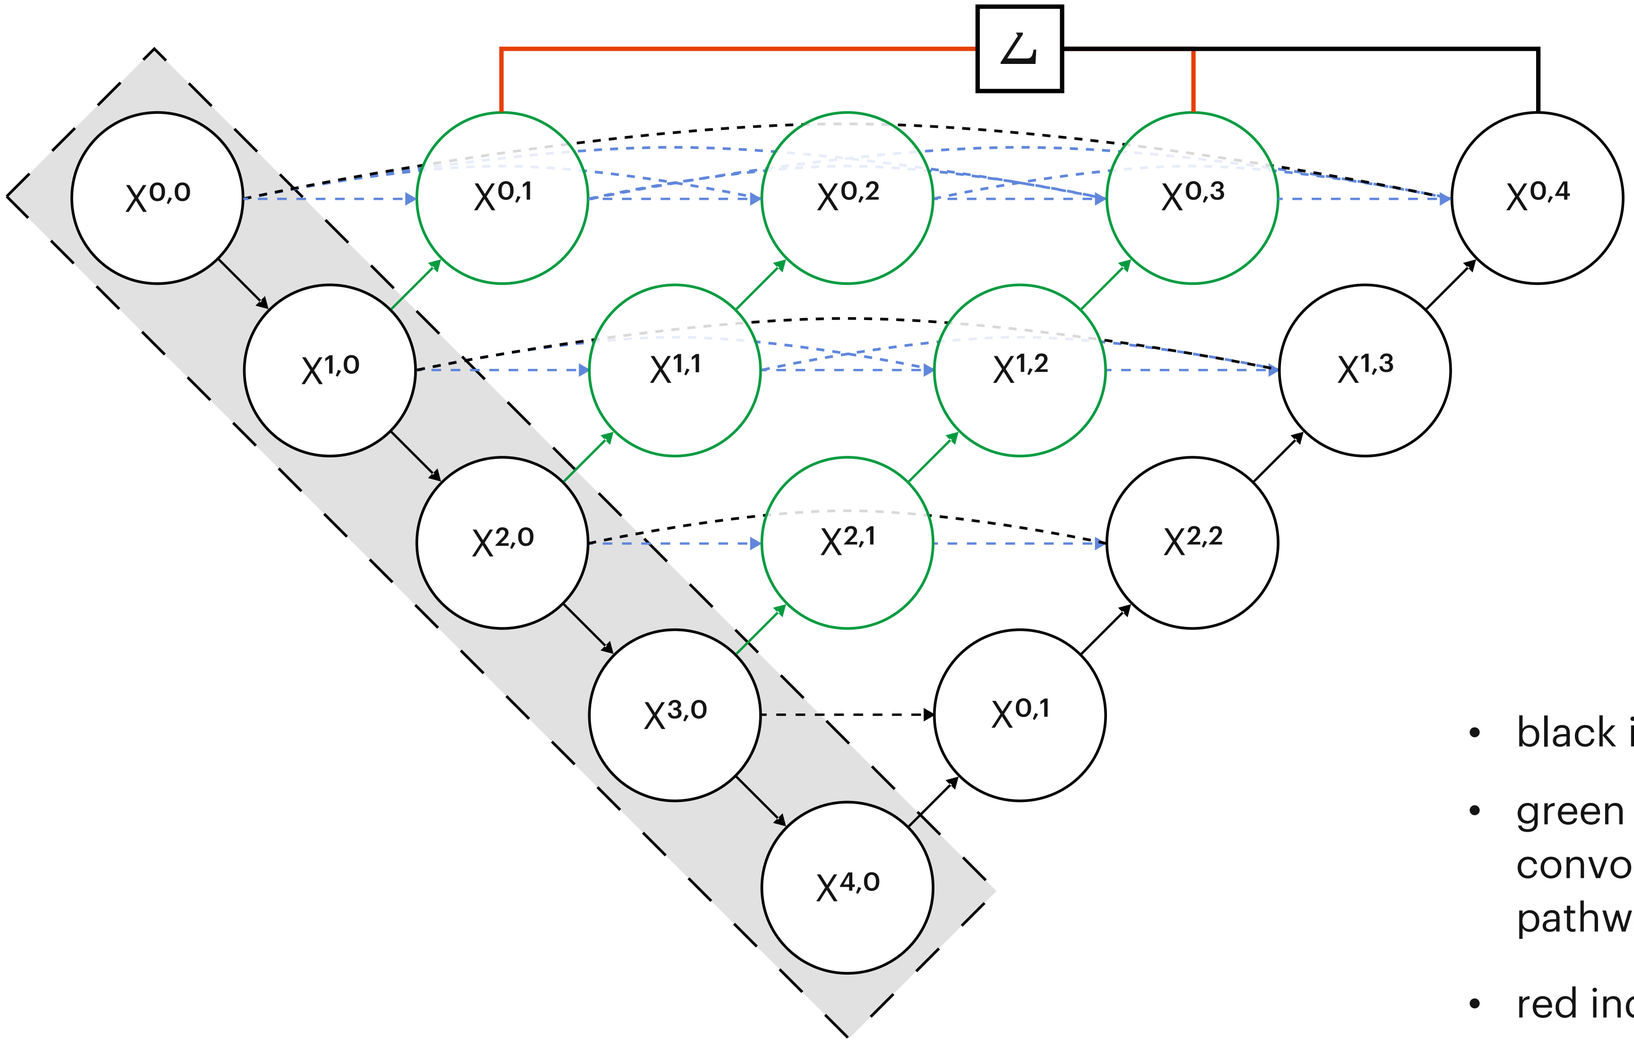

↘ Down-sampling

↗ Up-sampling

--> Skip connection

$X^{i,j}$ Convolution

- black indicates the original U-Net;
- green and blue show dense convolution blocks on the skip pathways;
- red indicates deep supervision.

Источник

Dilated / Atrous convolutions

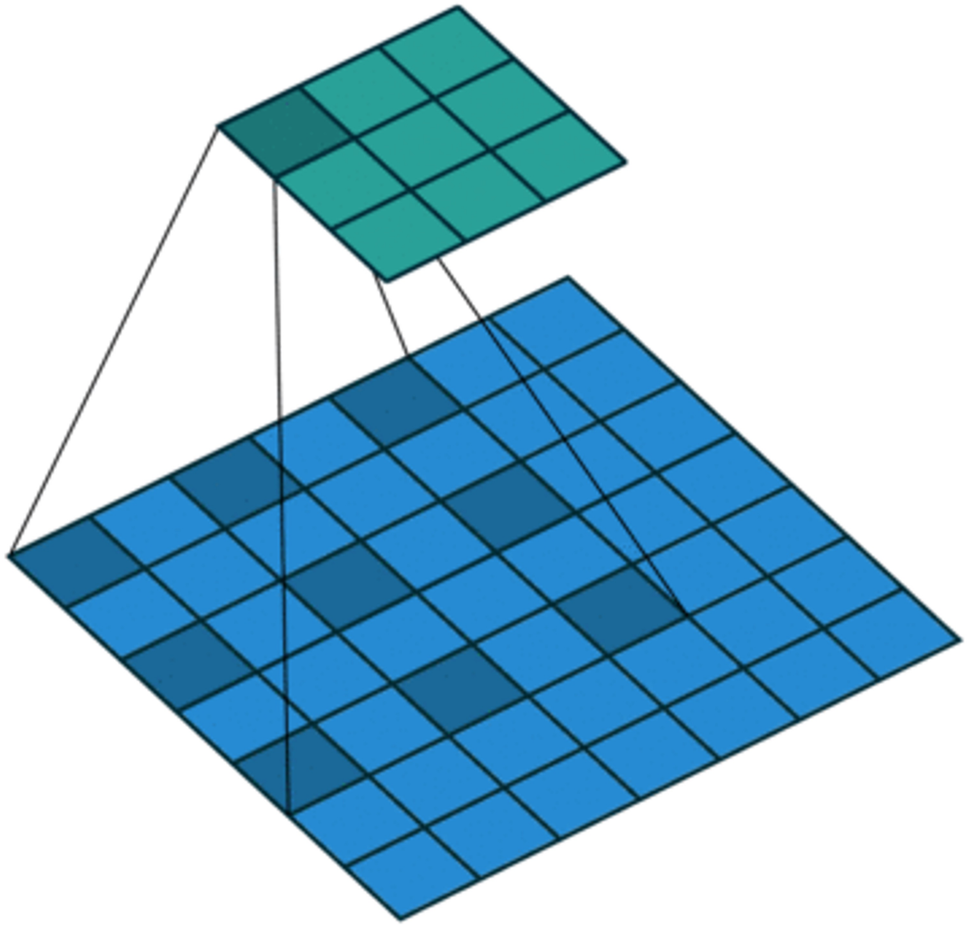

Зачем расширять свёртку

Для увеличения рецептивного поля (receptive field) — зоны, которая участвует в сворачивании и анализируется свёрткой.

Источник

Модели DeepLabV1/V2 (ICLR 2014/2016)

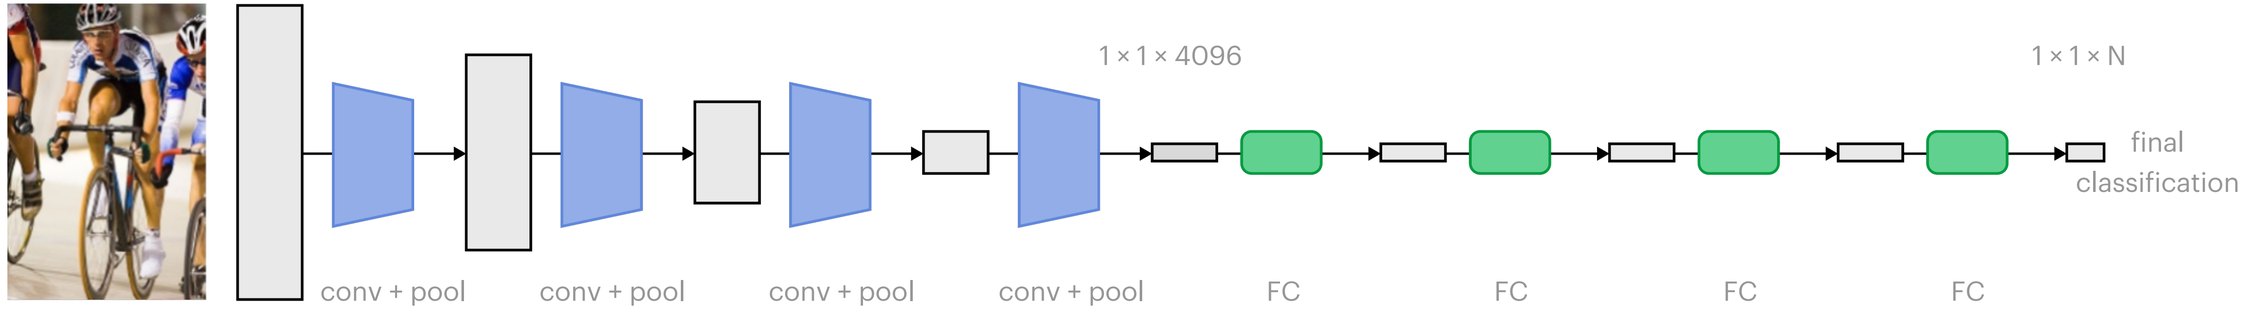

Источник

Модели DeepLabV1/V2

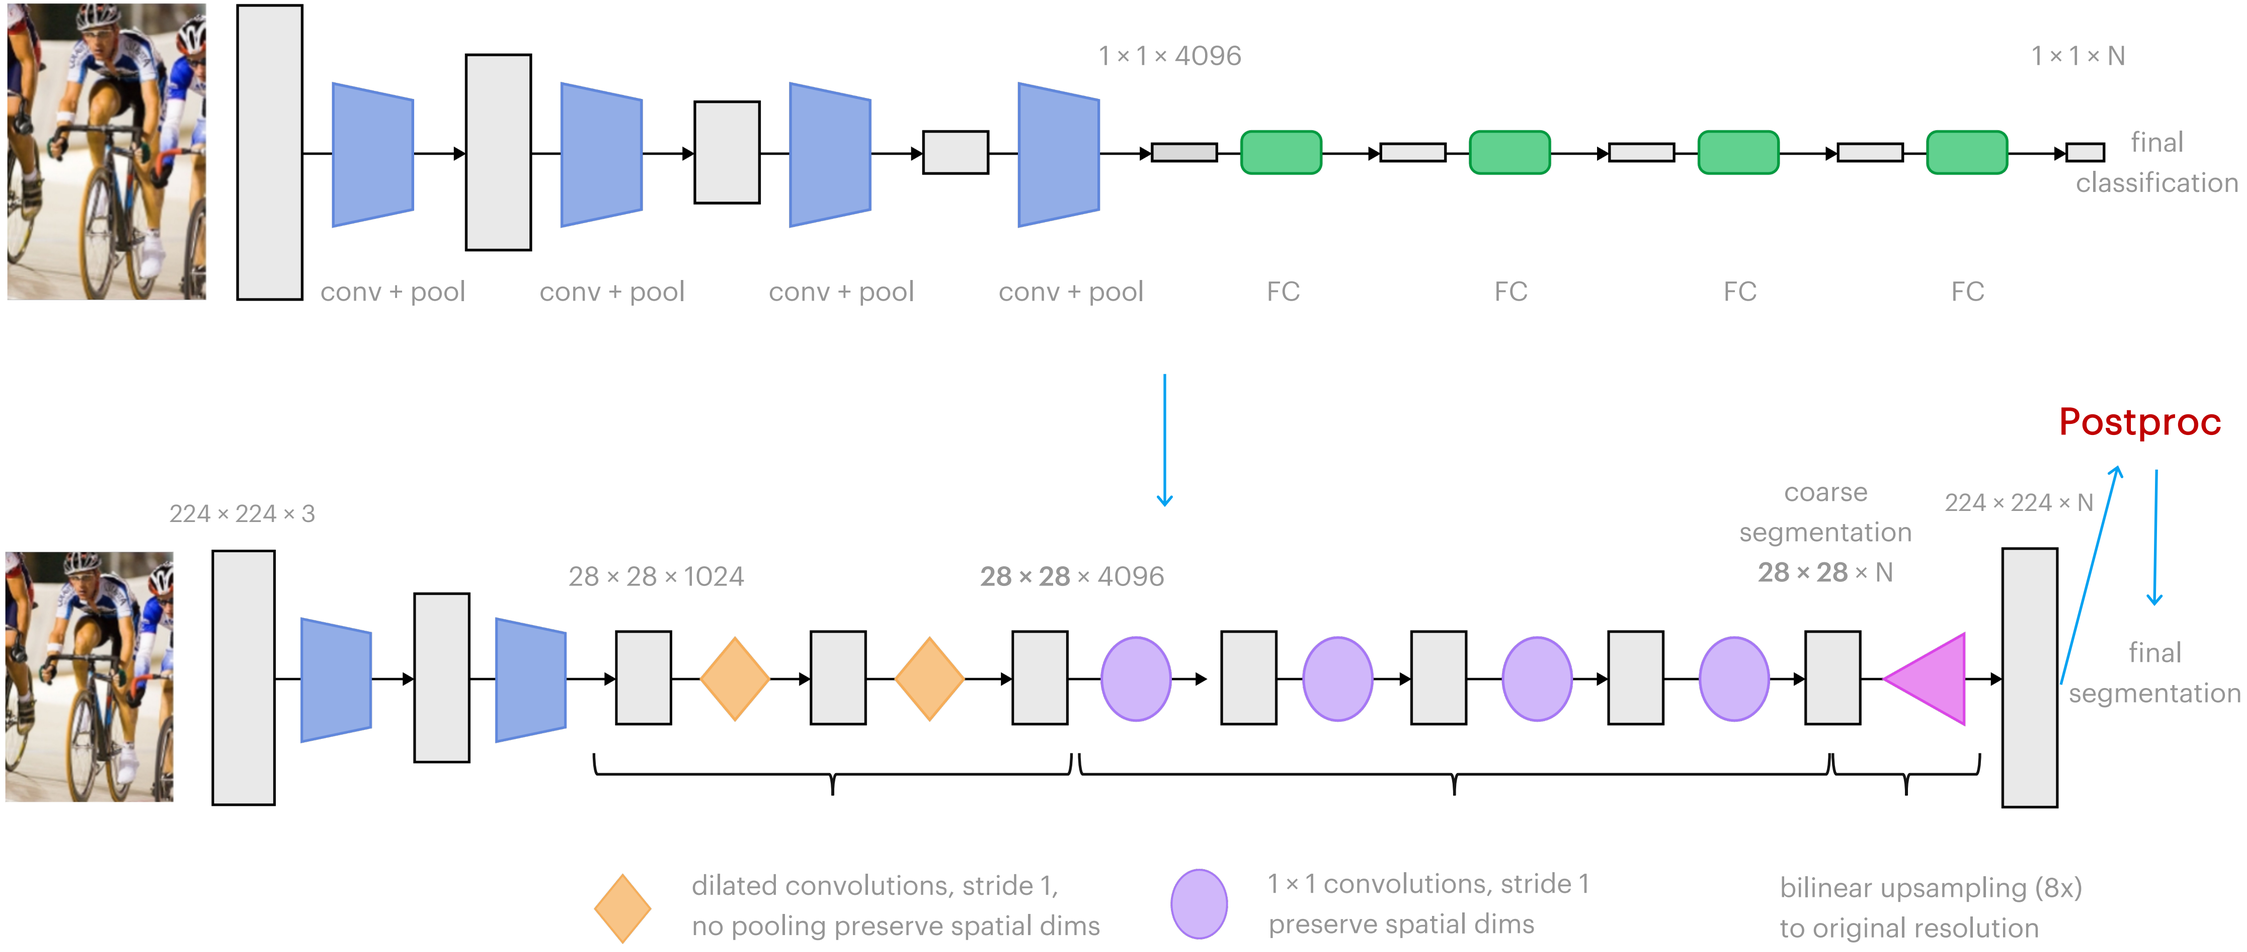

Источник

Модель DeepLabV3 (2017)

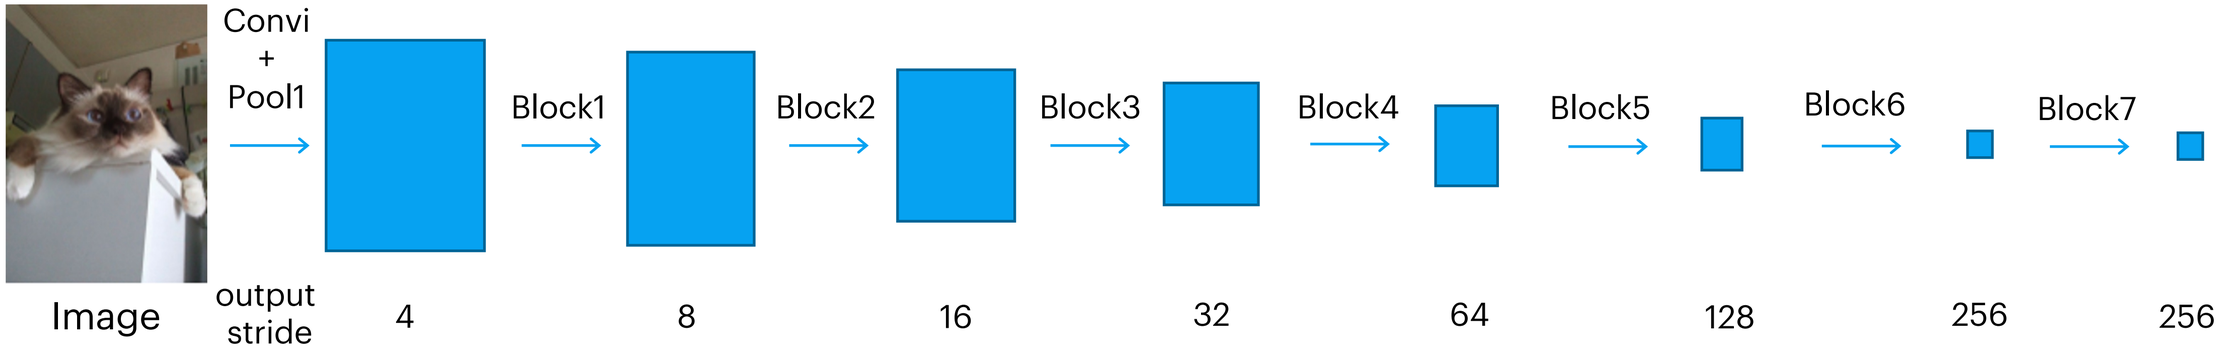

(a) Как мы углубляемся в сетях без Dilated Conv.

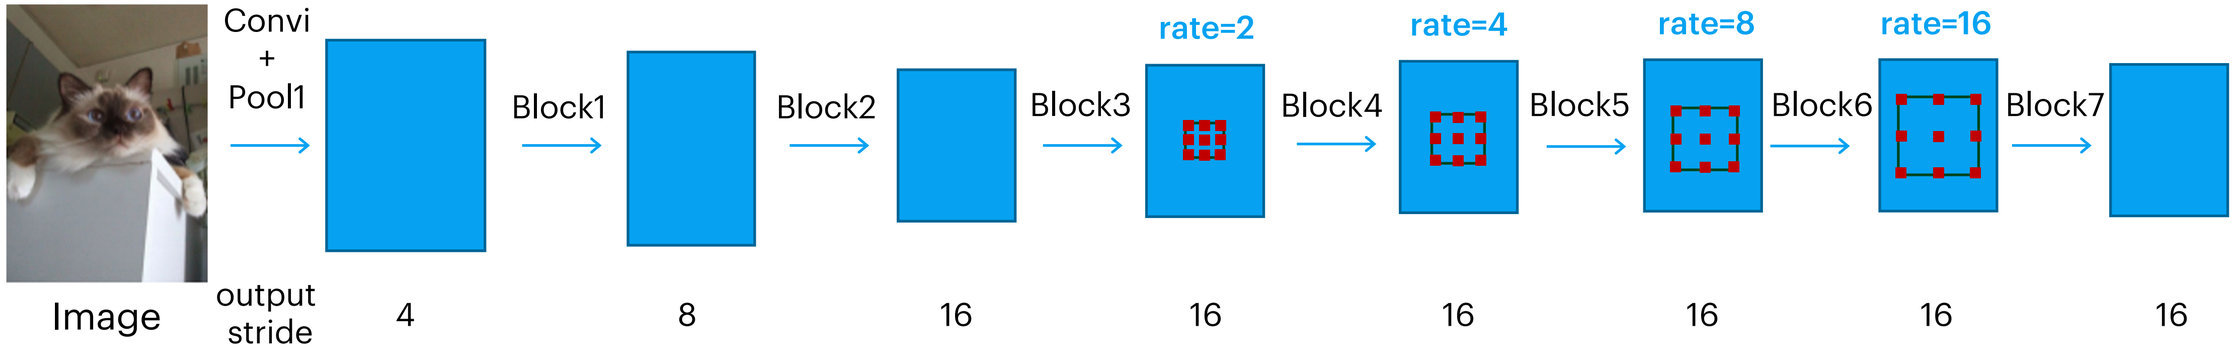

(b) Как мы углубляемся в сетях с Dilated Conv.

Output stride 16 означает, что карта признаков в 16 раз меньше входа по каждой стороне.

Источник

Модель DeepLabV3

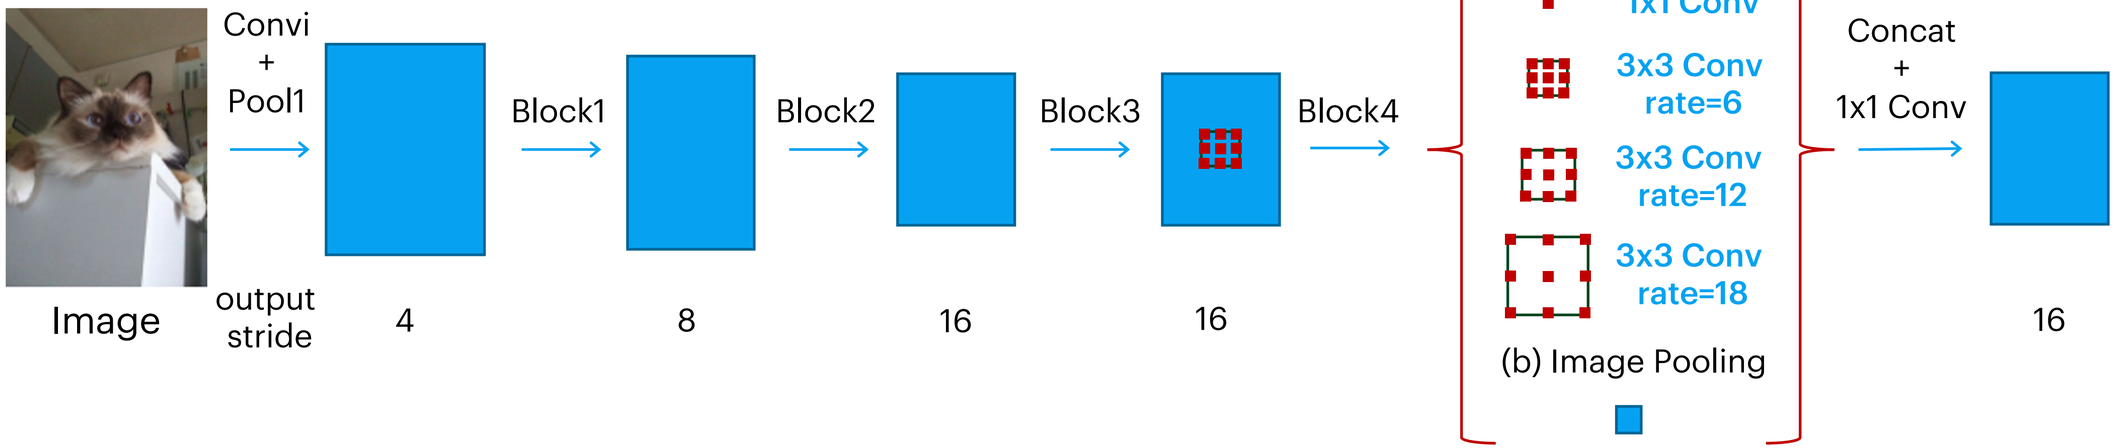

Источник

Модель DeepLabV3+ (ECCV 2018)

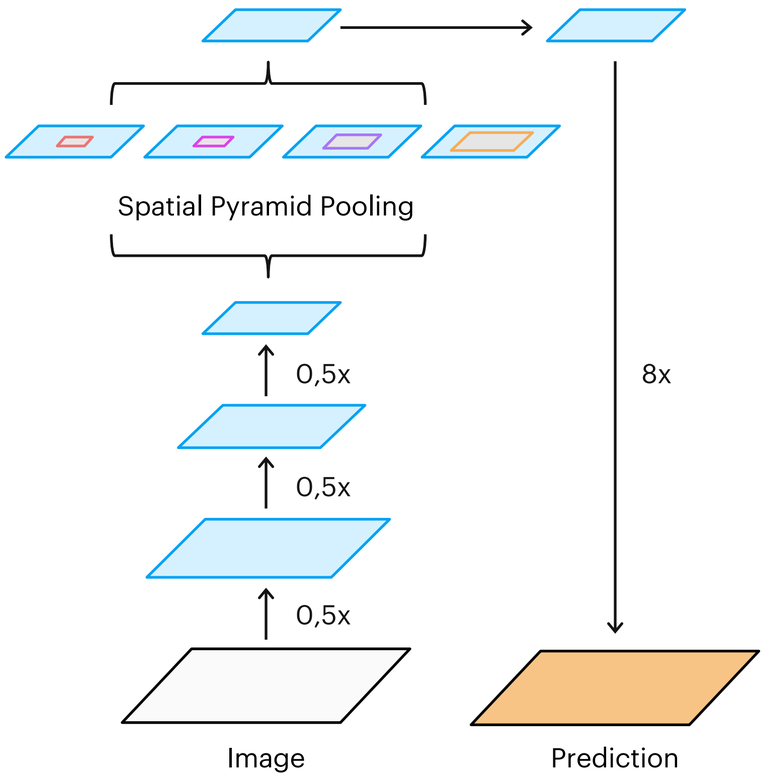

(a) Spatial Pyramid Predictions

Вот это DeepLab'ы

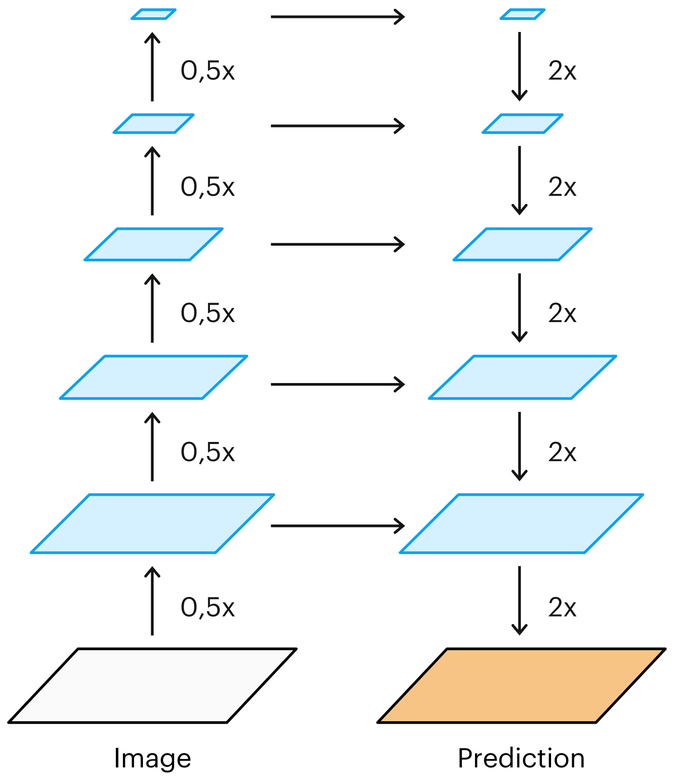

(b) Encoder-Decoder

Вот это UNet'ы

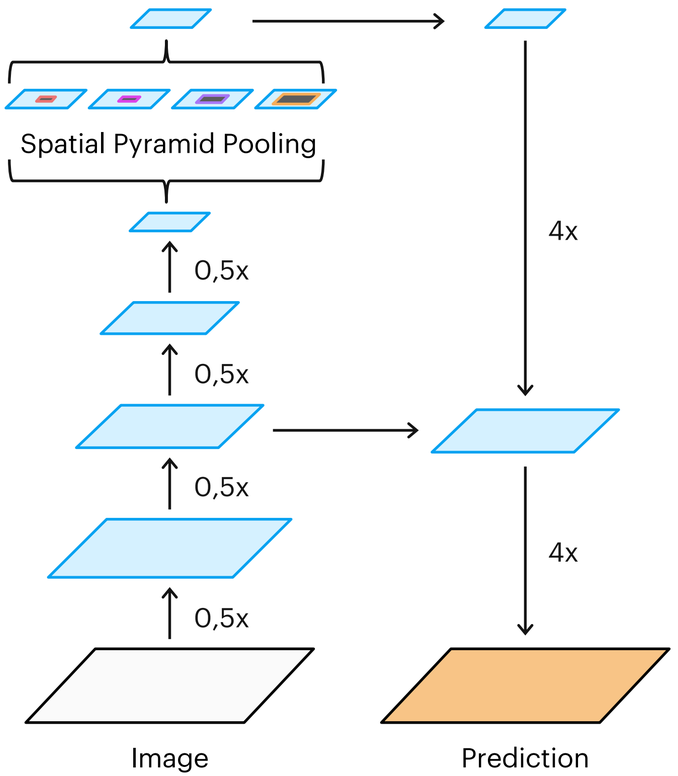

(b) Encoder-Decoder
with Atrous Conv

Вот это DeepLabV3+

Источник

Модель DeepLabV3+

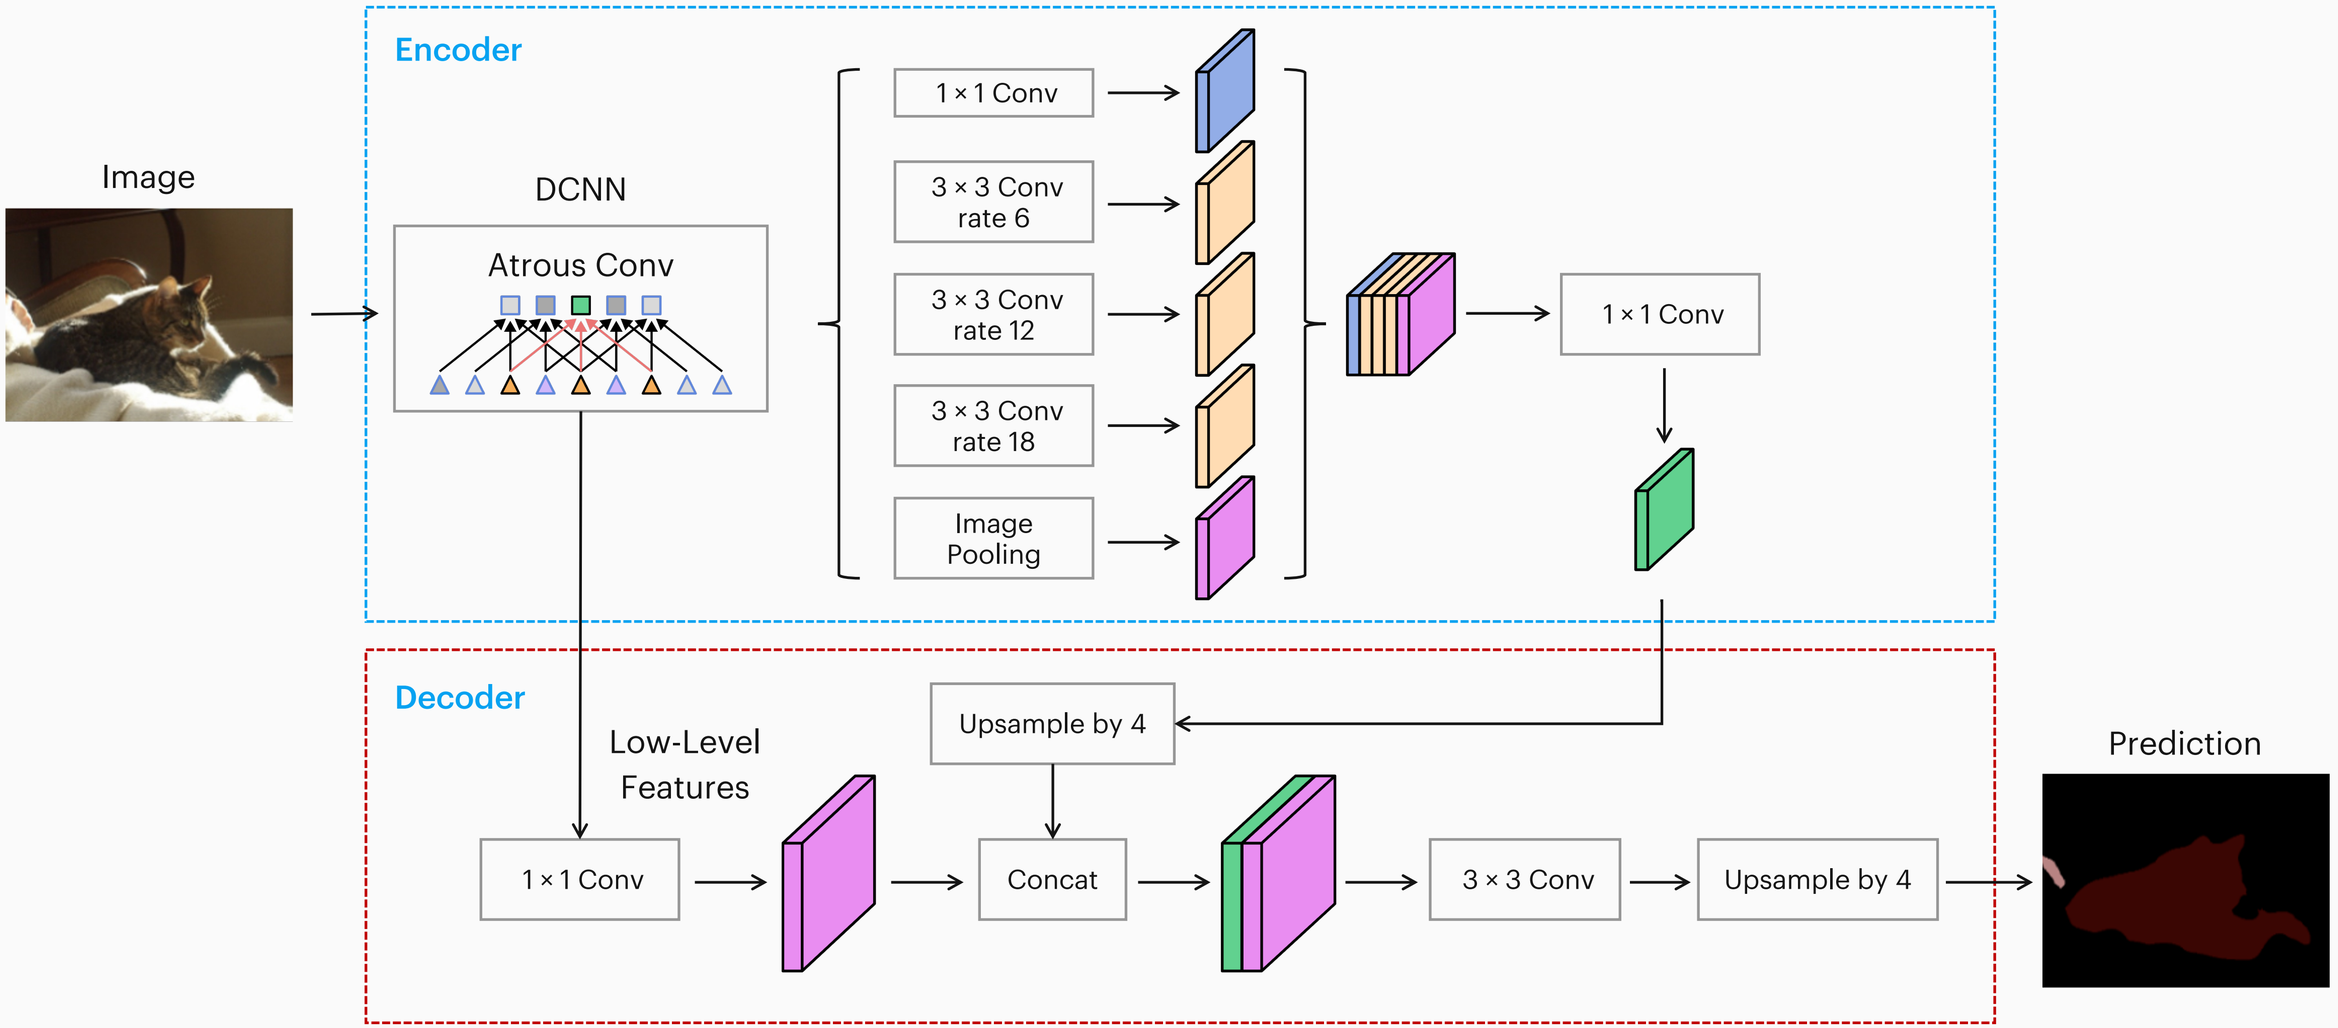

Источник

Feature Pyramid Network (FPN) (CVPR 2017)

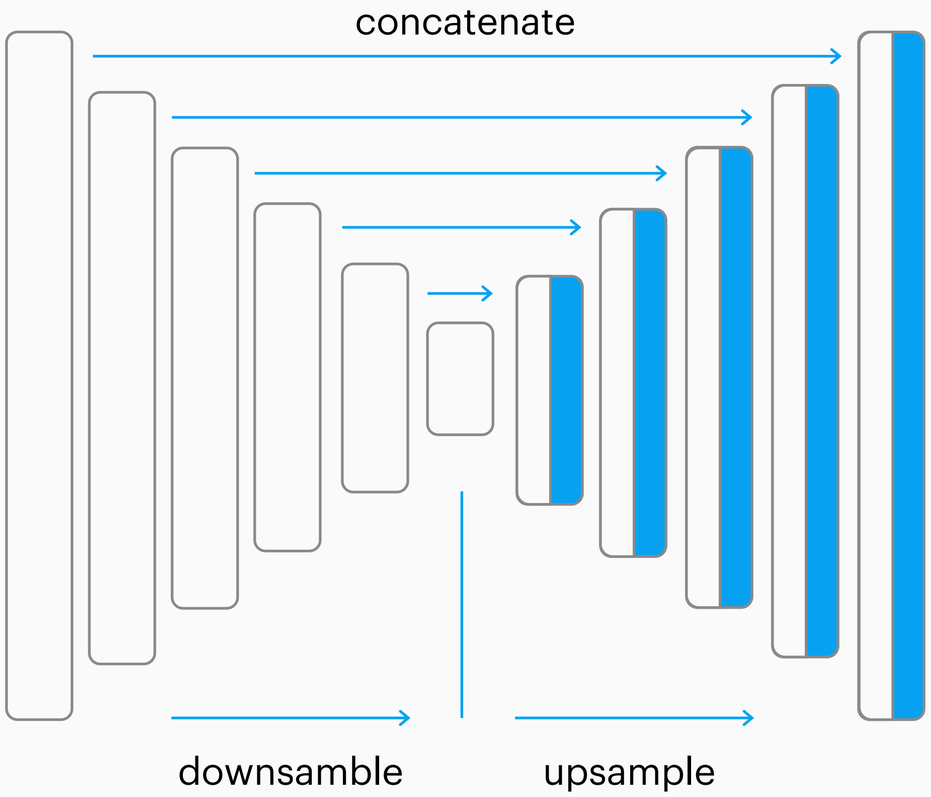

UNet

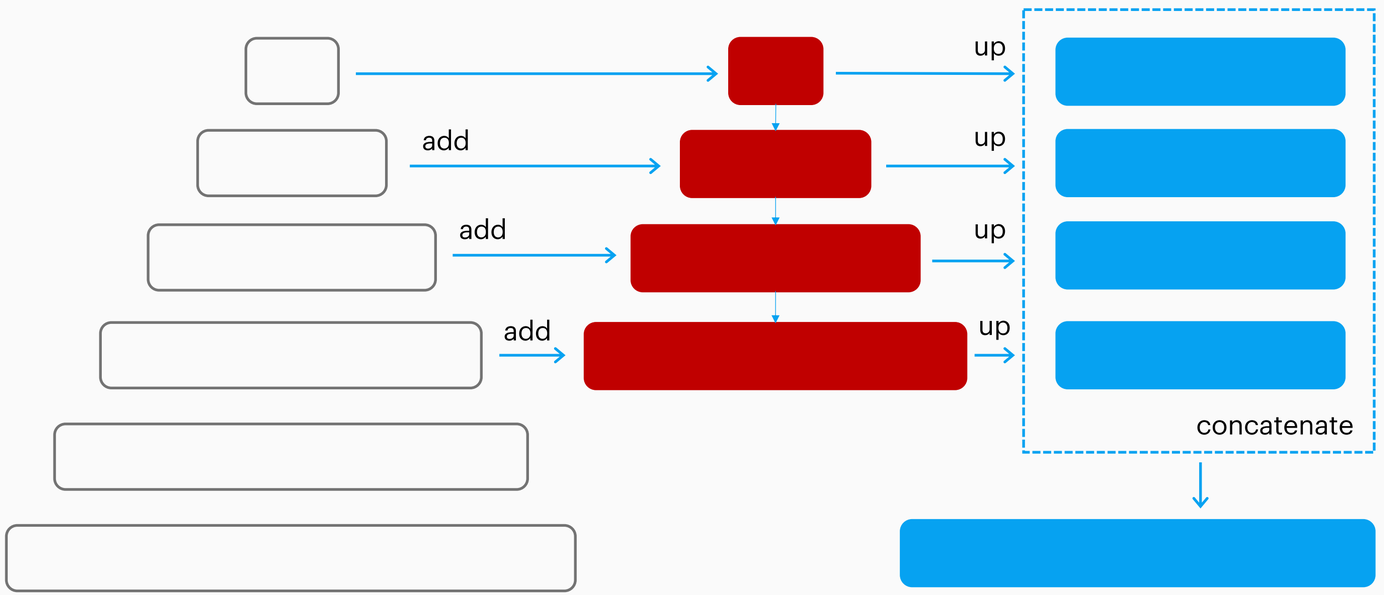

FPN

Источник

HRNet (CVPR 2019)

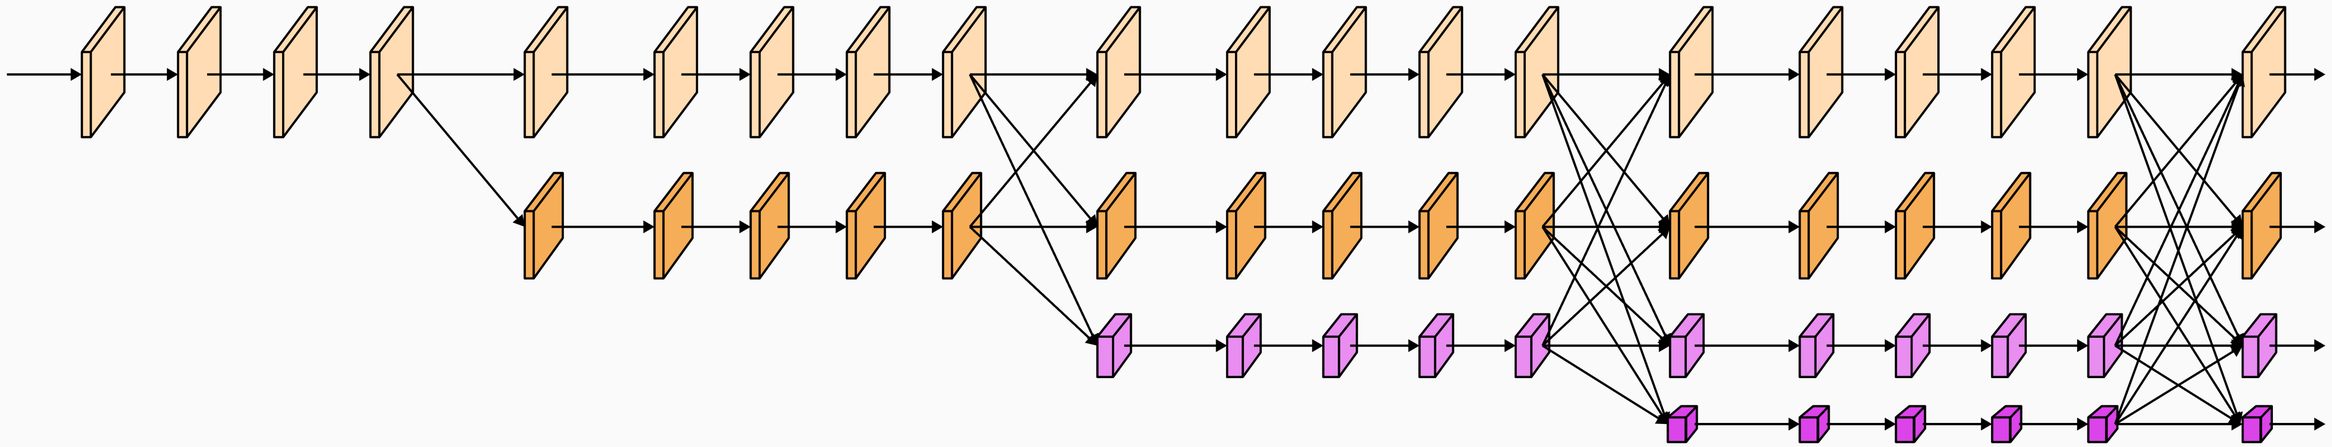

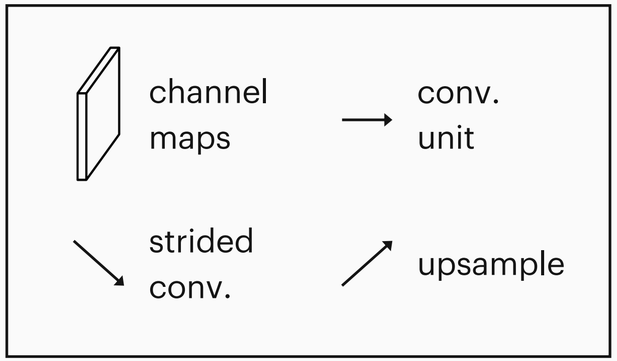

В сегментации отлично прижились и подходы из Heatmap Pose Estimation, потому что требования для этих задач в целом похожи: важен локальный и глобальный контекст, а выход сети – тензор высокого разрешения.

Источник

Резюме

01 По образу и подобию UNet (encoder-decoder) создано довольно много архитектур сегментации, например LinkNet.

02 Одна из основных задач, которую пытаются решить в архитектурах сегментации — извлечение и агрегация признаков с разного масштаба, то есть комбинация локального и глобального контекста.

03 Dilated / Atrous convolutions — это вариант свёртки, который имеет куда больший receptive field за счёт расширения зоны, на которую ядро свёртки смотрит.

04 DeepLab — это отдельное семейство архитектур, где признаки разного масштаба получают с помощью dilated convolutions, экономя ресурсы.

05 UNet++, FPN, HRNet — это более тяжёлые и точные архитектуры, где признаки разных уровней агрегируются друг с другом.

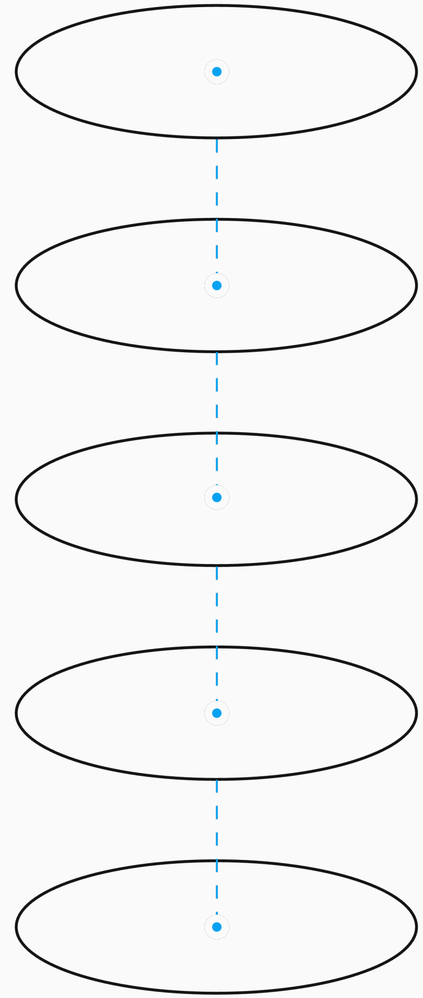

План

01 Введение, датасеты и метрики

02 UNet

03 Кто, если не UNet

04 Трансформерные модели

05 Segment Anything Model (SAM)

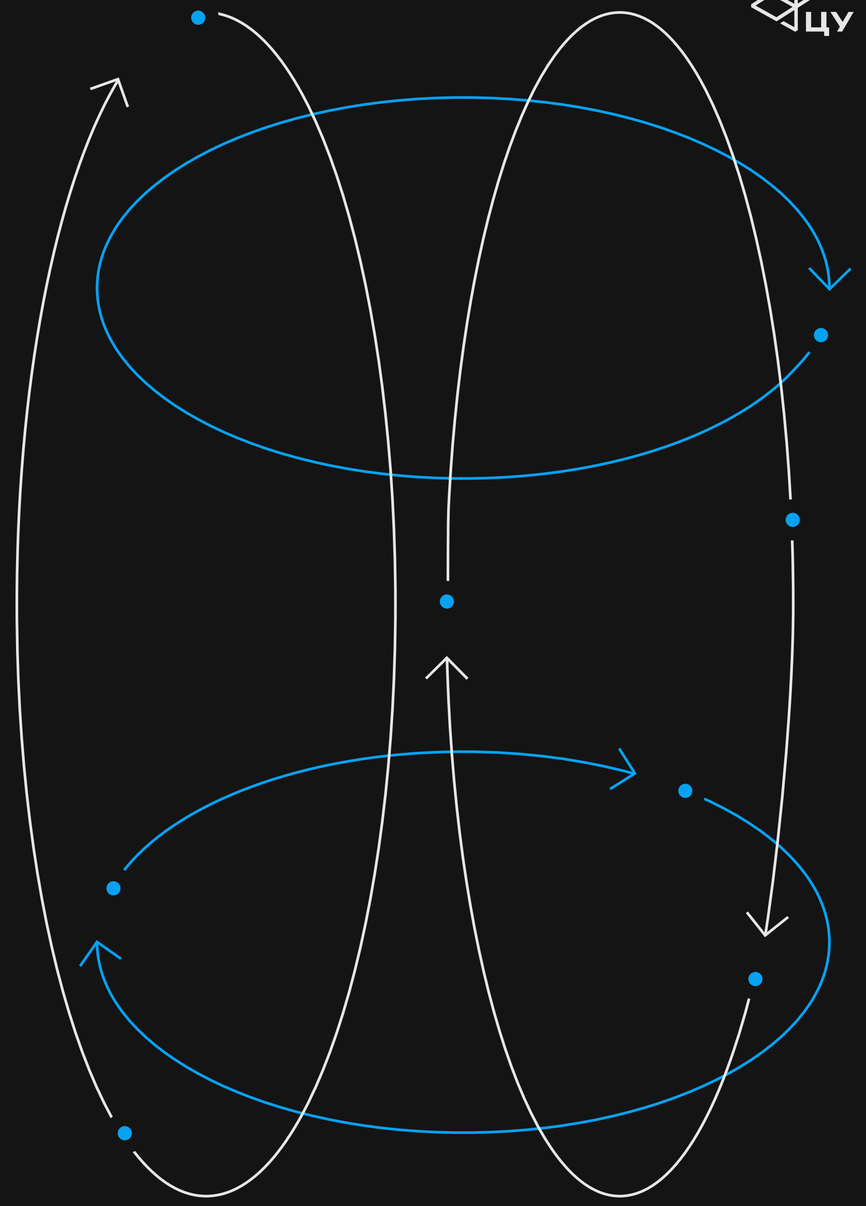

SETR от Fudan University (CVPR 2021)

SETR == Segmentation Transformer

Идея: буквально берем ViT и добавляем декодер для предсказания масок.

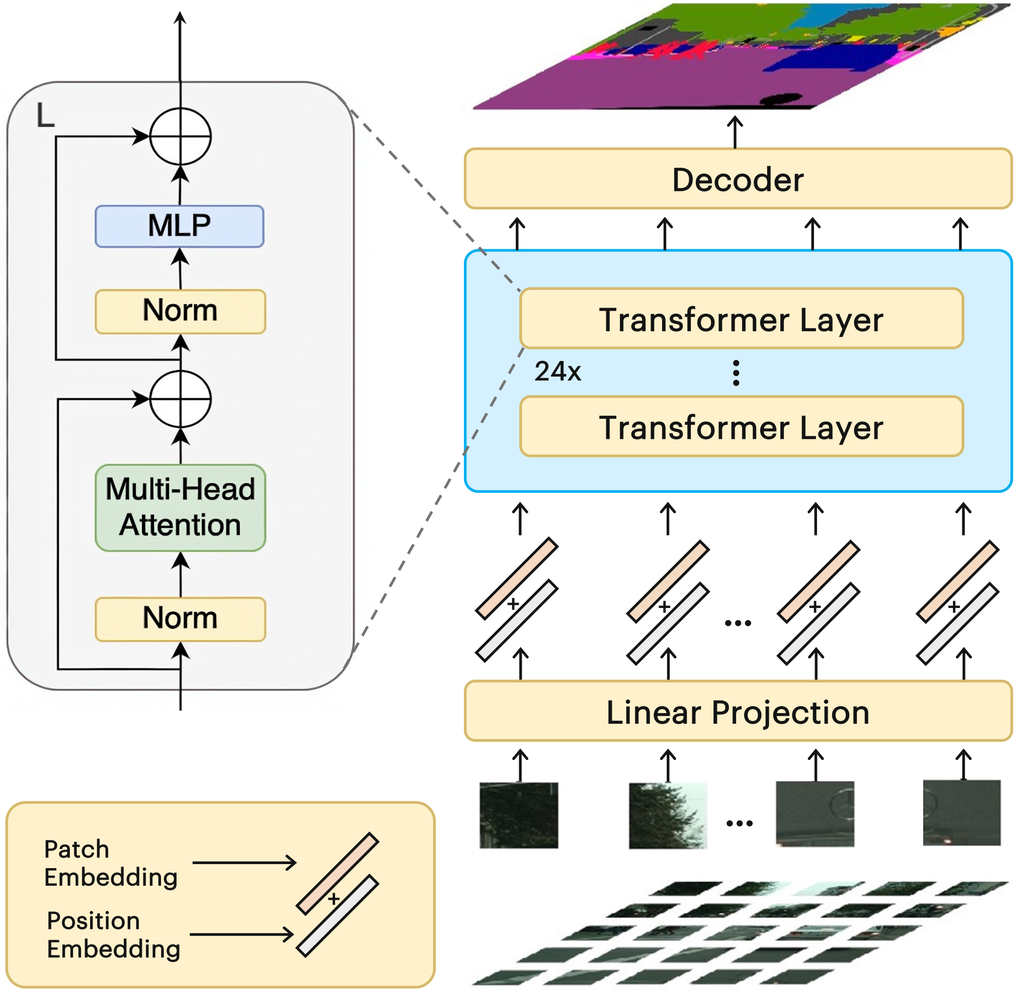

Источник

SETR: варианты декодера

Варианты пробовали разные:

1. **Naive.** Делаем решейп эмбедингов, а потом в один слой upsample до нужного разрешение и сразу предикт.
2. **Progressive Upscaling (PUP).** Делаем решейп эмбеддингов в 3D тензор, а дальше сверточные декодер с апсемплингом как в UNet.
3. **Multi-Level Aggregation (MLA).** Берем эмбеддинги с разных блоков ViT, решейпим и агрегируем с них информацию.

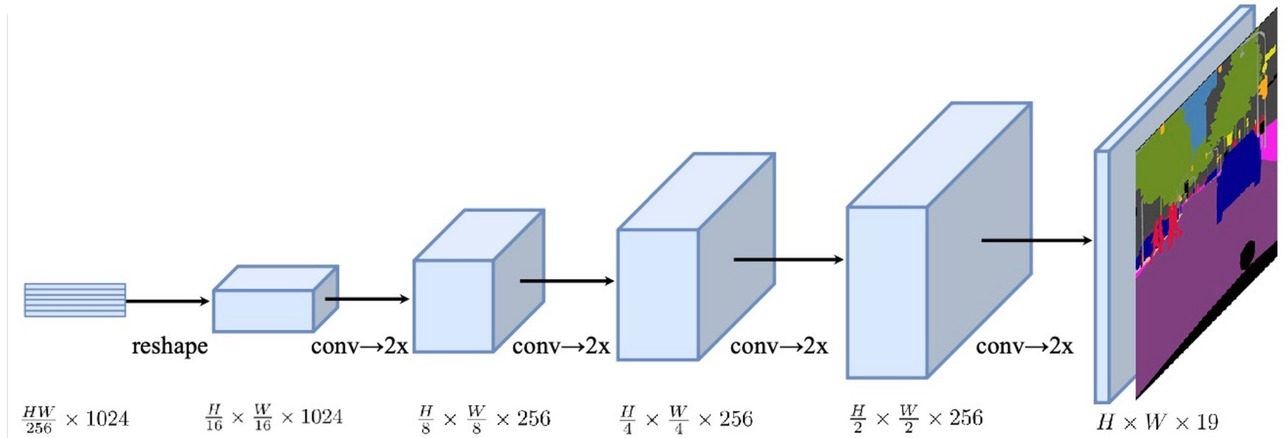

2.

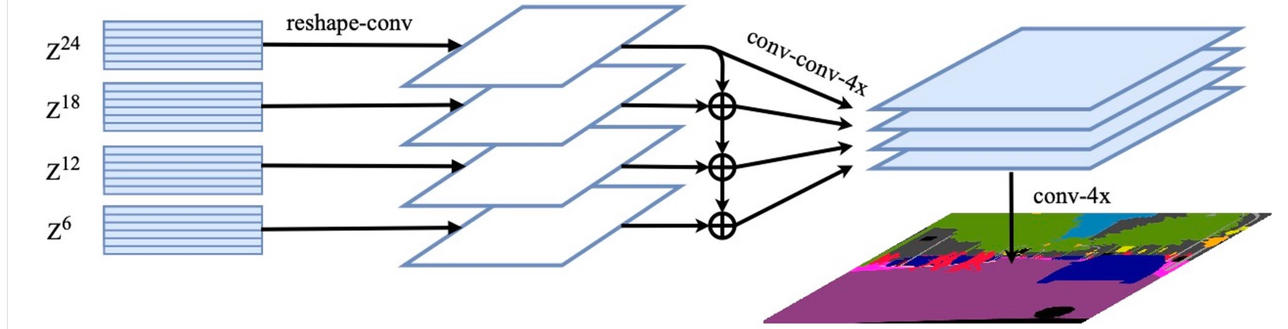

3.

Источник

SETR: результаты

Method	Pre	Backbone	#Params	mIoU
FCN (160k, SS)	1K	ResNet-101	68.59M	39.91
FCN (160k, MS)	1K	ResNet-101	68.59M	41.40
CCNet	1K	ResNet-101	-	45.22
Strip pooling	1K	ResNet-101	-	45.60
DANet	1K	ResNet-101	69.0M	45.30
OCRNet	1K	ResNet-101	71.0M	45.70
UperNet	1K	ResNet-101	86.0M	44.90
Deeplab V3+	1K	ResNet-101	63.0M	46.40
SETR-*Naïve* (160k, SS)	21K	T-Large	305.67M	48.06
SETR-*Naïve* (160k, MS)	21K	T-Large	305.67M	48.80
SETR-*PUP* (160k, SS)	21K	T-Large	318.31M	48.58
SETR-*PUP* (160k, MS)	21K	T-Large	318.31M	50.09
SETR-*MLA* (160k, SS)	21K	T-Large	310.57M	48.64
SETR-*MLA* (160k, MS)	21K	T-Large	310.57M	**50.28**

Результаты на ADE20k,
SS = Single-Scale inference, MS = Multi-Scale Inference

Но других датасетах выигрывал и PUP, да и разница совсем небольшая, так что с декодером не так всё однозначно.

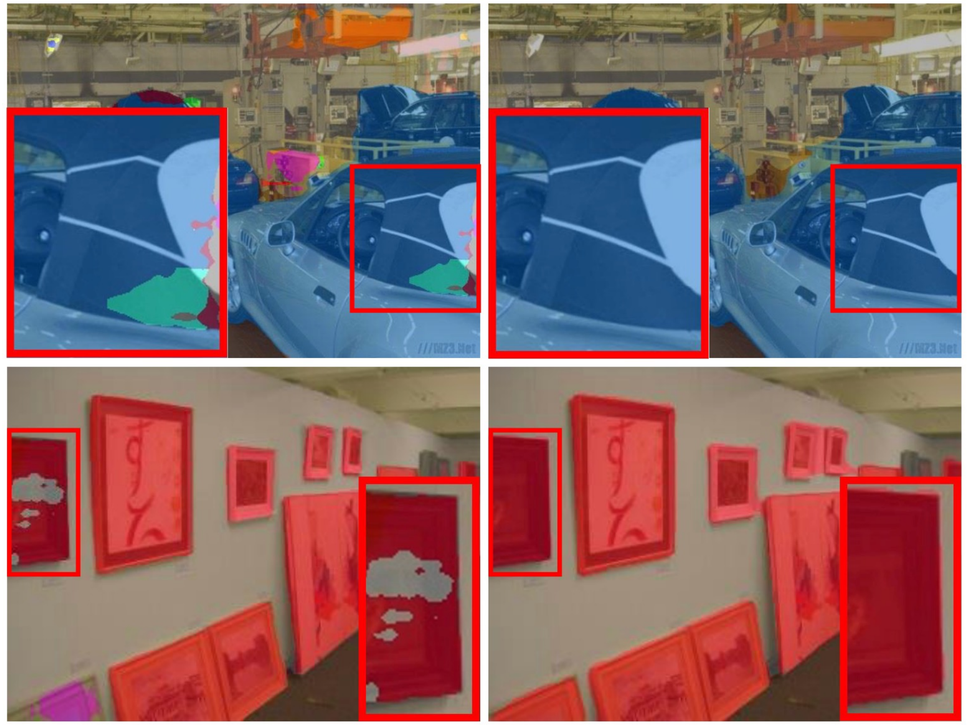

Слева FCN, справа. — SETR

Источник

SegFormer от NVIDIA (NIPS 2021)

Идея: теперь не просто ViT как энкодер для сегментации будем использовать, а возьмем иерархичный энкодер и добавим фишки для эффективности.

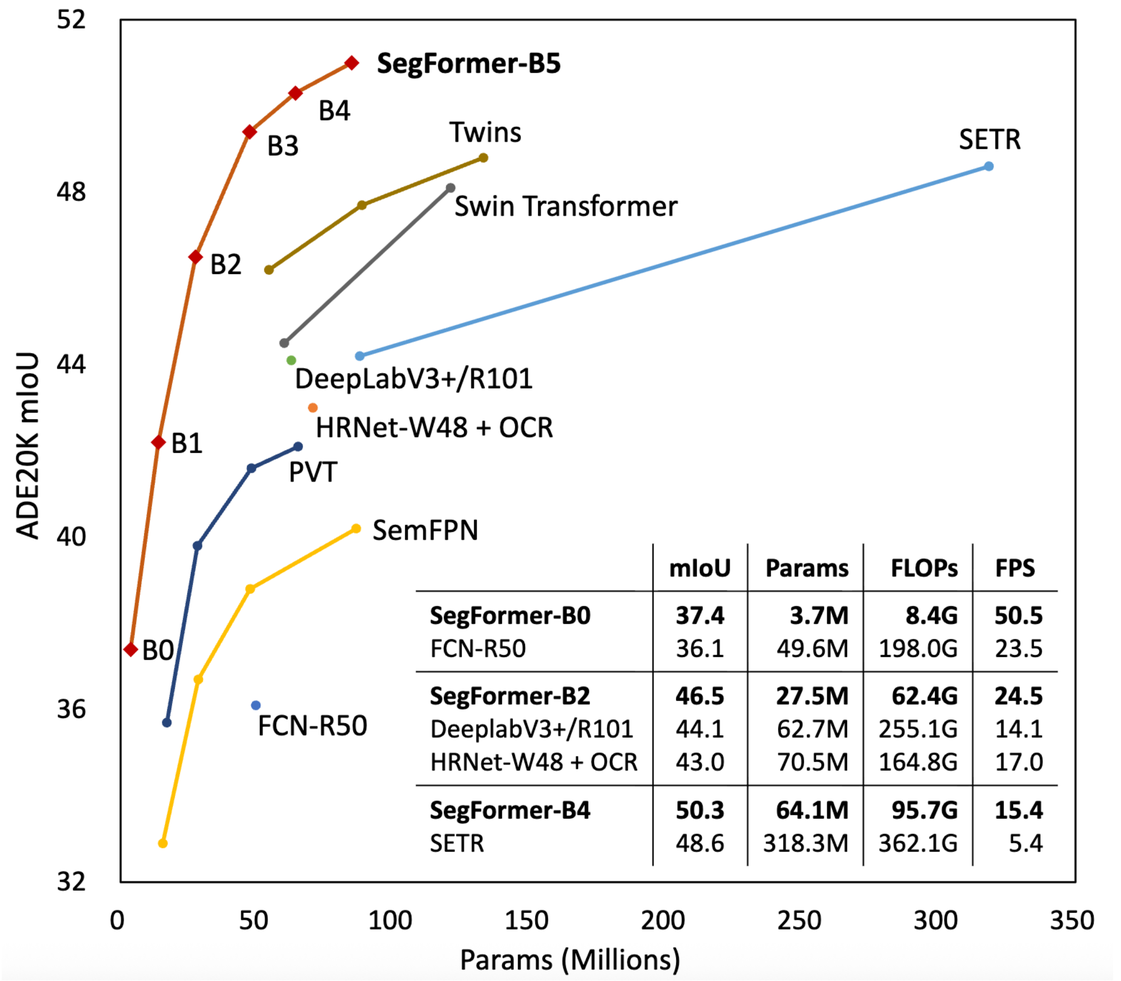

	mIoU	Params	FLOPs	FPS
SegFormer-B0	**37.4**	**3.7M**	**8.4G**	**50.5**
FCN-R50	36.1	49.6M	198.0G	23.5
SegFormer-B2	**46.5**	**27.5M**	**62.4G**	**24.5**
DeeplabV3+/R101	44.1	62.7M	255.1G	14.1
HRNet-W48 + OCR	43.0	70.5M	164.8G	17.0
SegFormer-B4	**50.3**	**64.1M**	**95.7G**	**15.4**
SETR	48.6	318.3M	362.1G	5.4

Источник

SegFormer: архитектура

Энкодер здесь – Mix Transformer (MiT). Может быть в 6 размерах – от b0 до b5.

Будем использовать иерархичный трансформер с возрастающими по размеру патчами.

Более того, патчи тут будем делать с перекрытием в половину их размера.

А декодер берем супер простой.

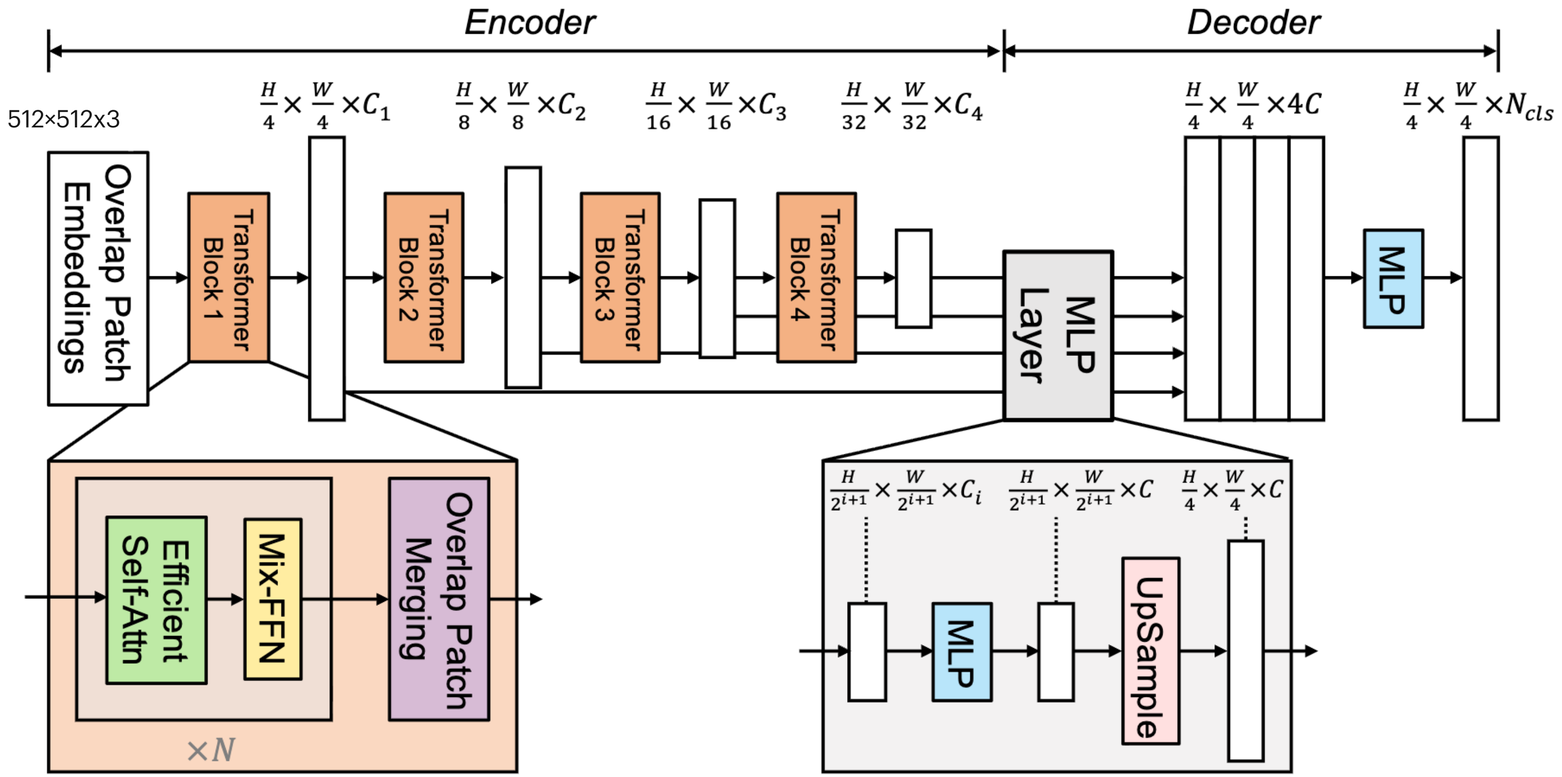

Источник

SegFormer: Efficient MHSA

Чтобы избежать $O(N^2)$ по числу патчей будем делать трюк со снижением размерностей для K и V:

- **Q считаем для всех позиций**, а для K и V сначала уменьшаем фичемапу обучаемой свёрткой – таким образом векторов K и V **будет меньше**;
- Каждый токен смотрит на **всю карту, но в более грубом виде** — внимание остаётся глобальным.
- В примере матрица attention имеет размер **4096×64 вместо 4096×4096**.
- Ответ получаем для каждого исходного токена, поэтому **разрешение выхода сохраняется**.

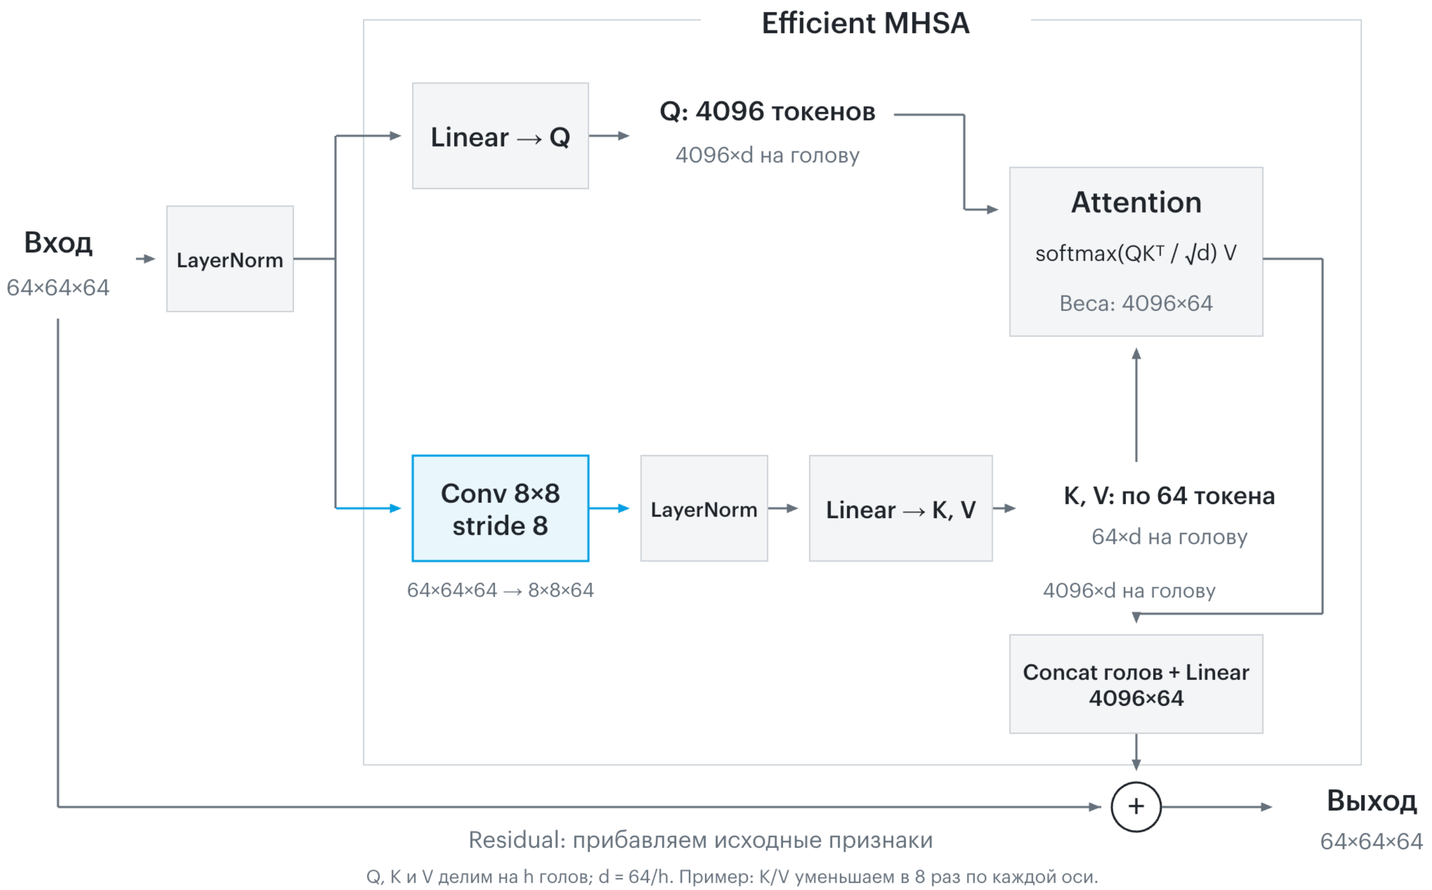

Q, K и V делим на h голов; d = 64/h. Пример: K/V уменьшаем в 8 раз по каждой оси.

Источник

SegFormer: Mix-FFN

В SegFormer авторы отказались от явного Positional Encoding, вместо этого внедрив наши любимые **свёрточные операции** в FFN-блок.

Depth-wise Conv в них агрегирует пространственную информацию между эмбеддингами отдельно в каждом канале эмбеддингов.

А значит мы извлекаем пространственную информацию об их относительном положении.

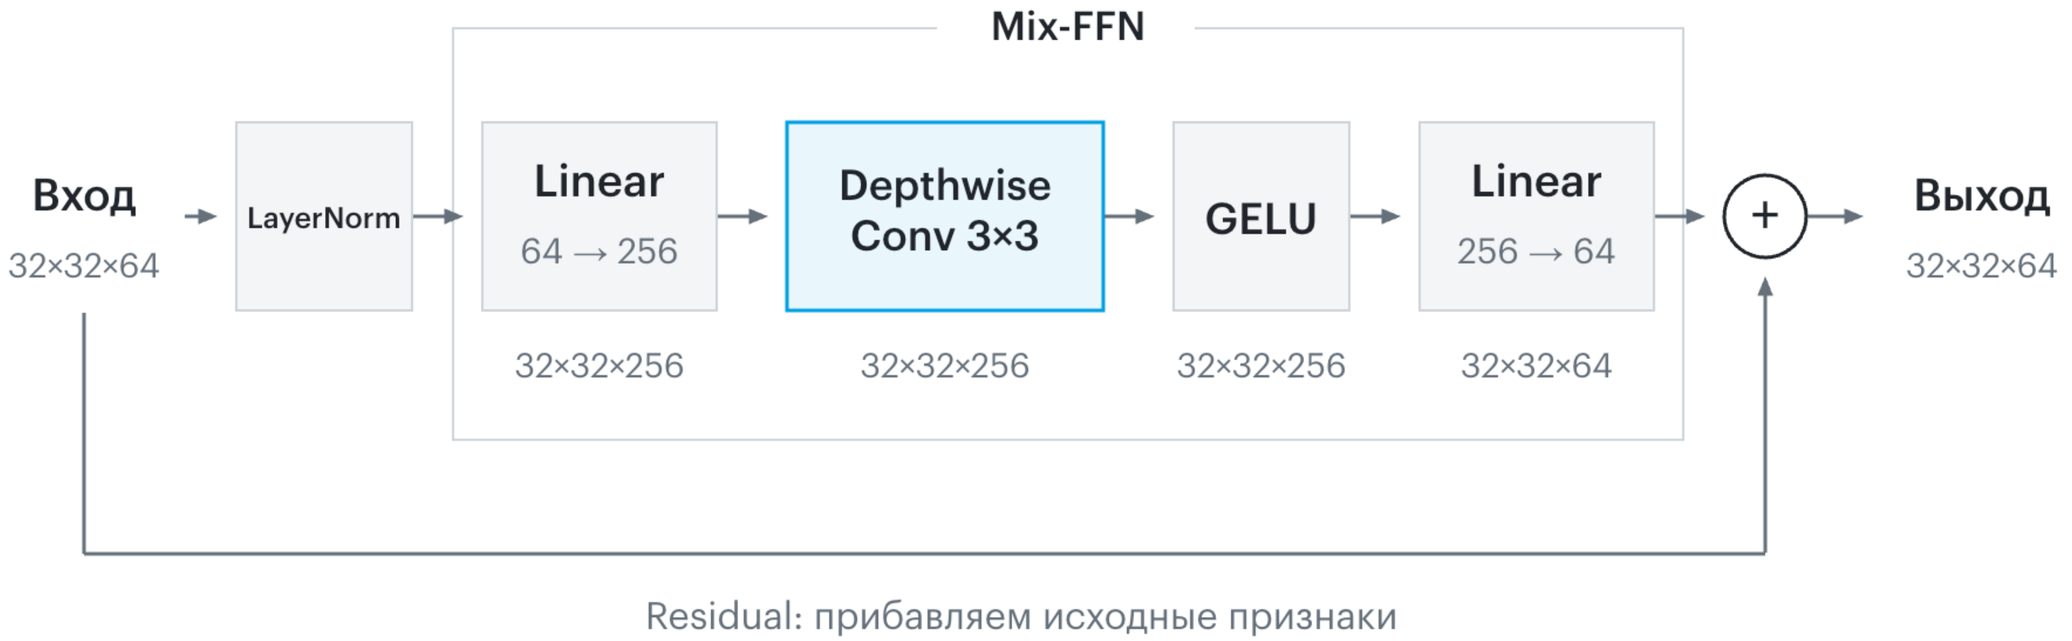

Источник

SegFormer: результаты

По итогу – малым числом параметров и крутым FPS бьём SETR и свёрточные сетки.

	Method	Encoder	Params ↓	ADE20K			Cityscapes		
				Flops ↓	FPS ↑	mIoU ↑	Flops ↓	FPS ↑	mIoU ↑
Real-Time	FCN	MobileNetV2	9.8	39.6	64.4	19.7	317.1	14.2	61.5
	ICNet	-	-	-	-	-	-	30.3	67.7
	PSPNet	MobileNetV2	13.7	52.9	57.7	29.6	423.4	11.2	70.2
	DeepLabV3+	MobileNetV2	15.4	69.4	43.1	34.0	555.4	8.4	75.2
	SegFormer (Ours)	MiT-B0	**3.8**	**8.4**	**50.5**	**37.4**	125.5	15.2	**76.2**
				-	-	-	51.7	26.3	75.3
				-	-	-	31.5	37.1	73.7
				-	-	-	**17.7**	**47.6**	71.9
Non Real-Time	FCN	ResNet-101	68.6	275.7	14.8	41.4	2203.3	1.2	76.6
	EncNet	ResNet-101	**55.1**	218.8	14.9	44.7	1748.0	1.3	76.9
	PSPNet	ResNet-101	68.1	256.4	15.3	44.4	2048.9	1.2	78.5
	CCNet	ResNet-101	68.9	278.4	14.1	45.2	2224.8	1.0	80.2
	DeeplabV3+	ResNet-101	62.7	255.1	14.1	44.1	2032.3	1.2	80.9
	OCRNet	HRNet-W48	70.5	164.8	**17.0**	45.6	1296.8	**4.2**	81.1
	GSCNN	WideResNet38	-	-	-	-	-	-	80.8
	Axial-DeepLab	AxialResNet-XL	-	-	-	-	2446.8	-	81.1
	Dynamic Routing	Dynamic-L33-PSP	-	-	-	-	**270.0**	-	80.7
	Auto-Deeplab	NAS-F48-ASPP	-	-	-	44.0	695.0	-	80.3
	SETR	ViT-Large	318.3	-	5.4	50.2	-	0.5	82.2
	SegFormer (Ours)	MiT-B4	64.1	**95.7**	15.4	51.1	1240.6	3.0	83.8
	SegFormer (Ours)	MiT-B5	84.7	183.3	9.8	**51.8**	1447.6	2.5	**84.0**

Источник

SegFormer: результаты

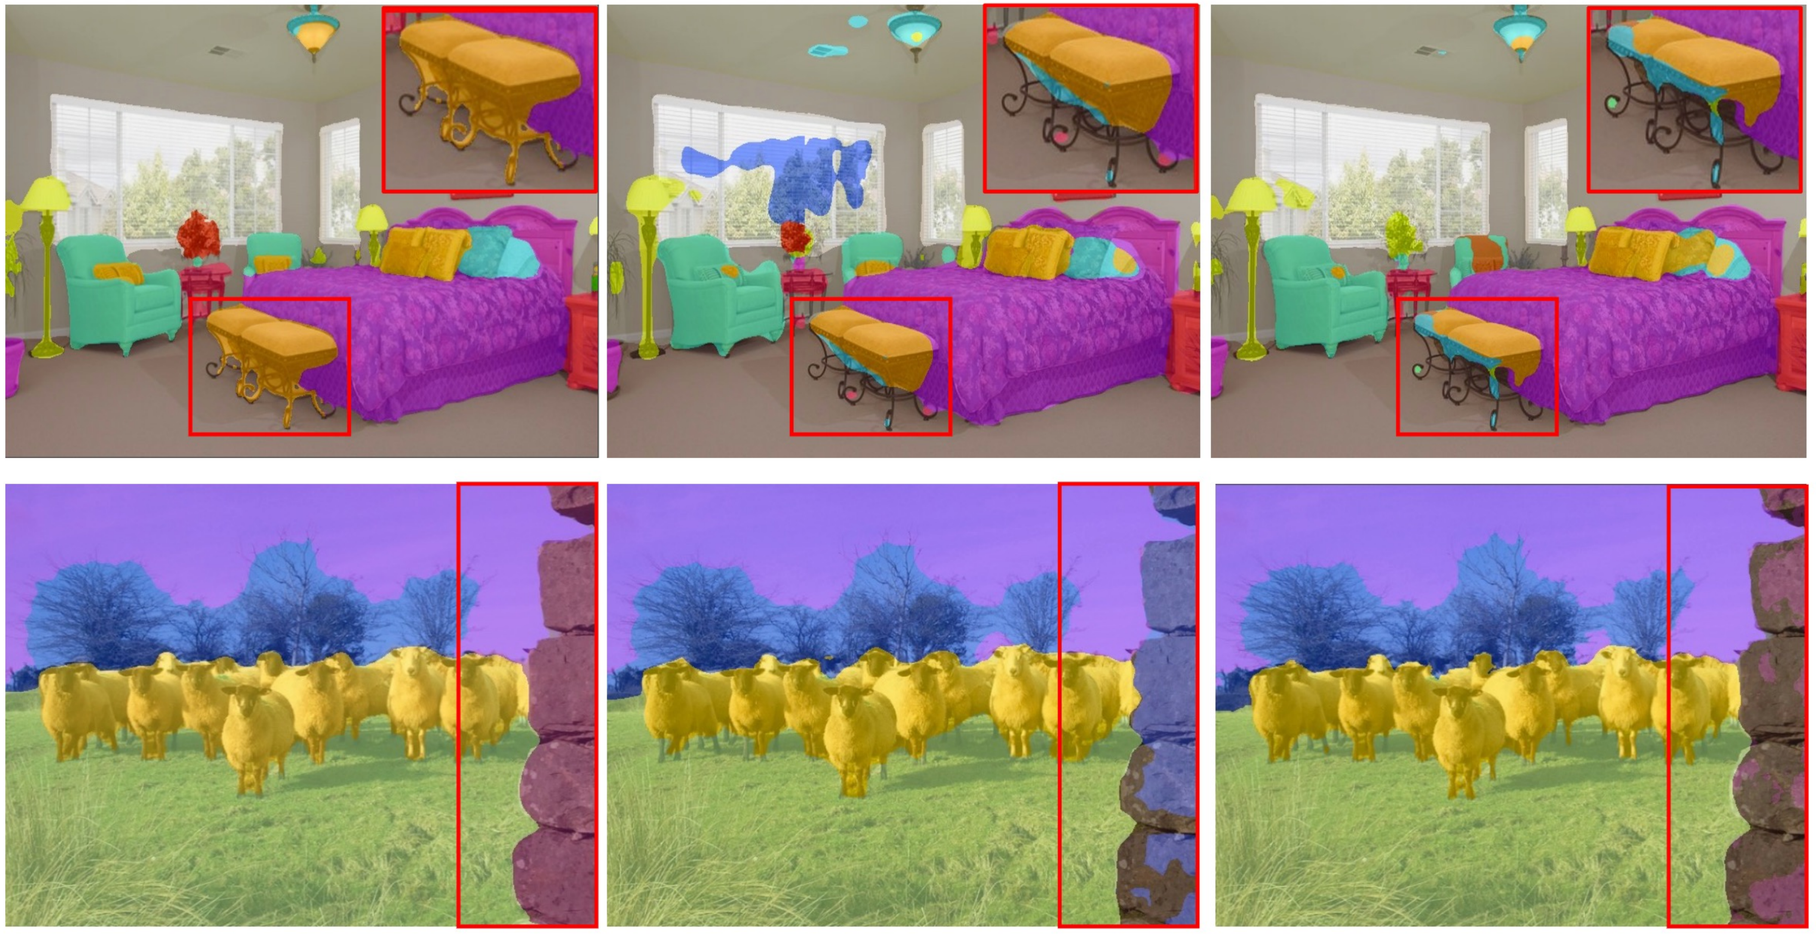

Источник

Резюме

01 SETR — первая гибридная модель сегментации, использует Vision Transformer (ViT) как энкодер и свёрточный декодер для восстановления пространственной структуры. Доказал, что Transformer способен решать задачу семантической сегментации.

02 Проблема SETR — отсутствие иерархии и локальных признаков: ViT работает с фиксированными патчами и теряет детали, что требует неплохого декодера для апсемплинга и ограничивает эффективность.

03 SegFormer — решает проблемы SETR, предлагая Mix Transformer (MiT) с пирамидальной структурой, перекрывающимися патчами и внедрение Conv-операций, которые делают операции MHSA и FFN эффективнее.

04 SegFormer использует энкодер Mix Transformer (MiT): строит пирамиду признаков, формирует патчи с перекрытием и удешевляет глобальный Attention за счёт уменьшения числа токенов K/V. Признаки разных масштабов объединяет простой MLP-декодер.

05 И сегодня SegFormer – это супер выбор для решения задачи сегментации.

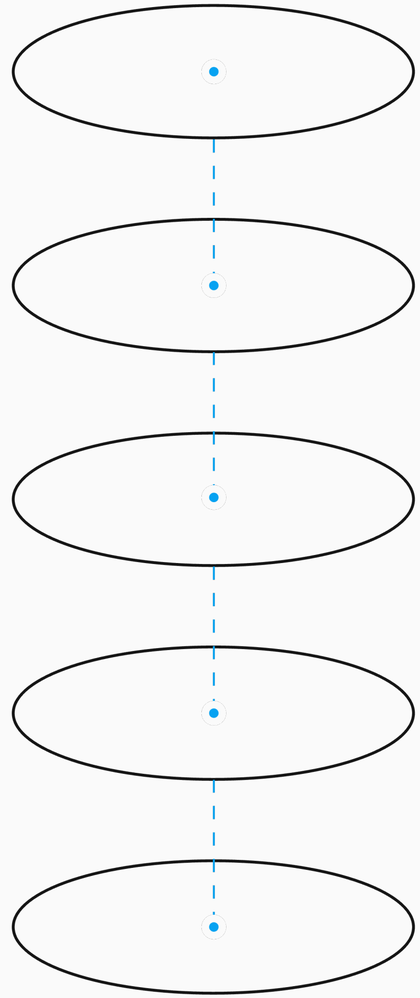

Модели сегментации

Модель	Год / Тип	Основная идея	Архитектура
U-Net	2015 / CNN	Сжимаем изображение для увеличения контекста, вспоминаем локальные признаки через skip-связи	CNN encoder–decoder + skip connections
U-Net++	2018 / CNN	Обрабатываем skip-признаки на промежуточных уровнях перед объединением	CNN encoder–decoder + вложенные плотные skip-связи
DeepLabV3+	2018 / CNN	Создаем пирамиду фичемап с контекстами разного масштаба за счёт dilation	CNN backbone + ASPP + decoder
HRNet	2019 / CNN	Сохраняем подробные карты признаков в нескольких масштабах и обмениваемся информацией между ними	Параллельные CNN-ветви разных разрешений + обмен признаками
SETR	2021 / Hybrid	Используем ViT в качестве энкодера: каждый патч видит все остальные благодаря Attention	ViT encoder + CNN decoder
SegFormer	2021 / Hybrid	Собираем пирамиду признаков в энкодере с глобальными Attention-ами, экономим за счет числа токенов в K и V, позицию понимаем за счет DWConv	Иерархический MiT encoder + MLP decoder

Общая задача: собрать контекст и сохранить детали.

Какие же бэкбоны выбирать?

Model Name	GFLOPs	# Of Params	Train VRAM (4x3x512x512), Mb	TensorRT FP16 Inference Time, ms	Pretrains Available
SegFormer-b0	45,037	3,71	1 770	1,492	ImageNet, ADE20k
UNet++	76,283	6,14	1 856	1,602	ImageNet, ADE20k
DPT	44,572	34,68	2 381	1,810	ImageNet, ADE20k
SegFormer-b2	379,138	27,35	3034	3,218	ImageNet, ADE20k
SegFormer-b4	581,614	63,99	5126	6,382	ImageNet, ADE20k
UPerNet-tiny	351,605	59,24	4502	6,042	ImageNet, ADE20k
UPerNet-small	688,711	80,87	5532	7,1	ImageNet, ADE20k

Small Winner: SegFormer-b0

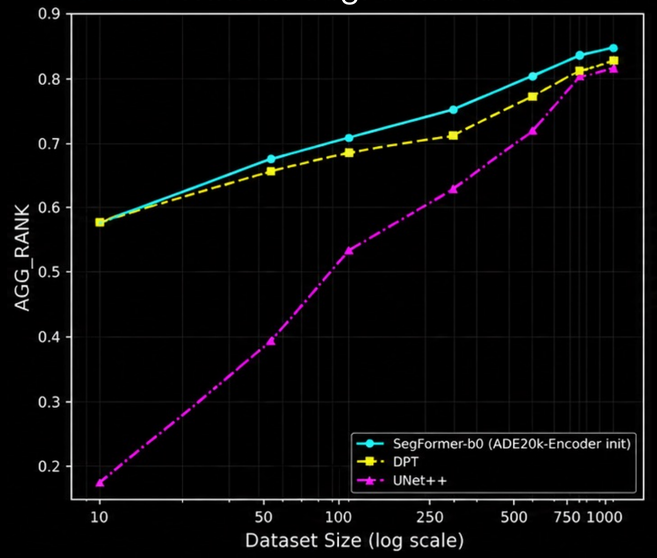

Pretrain Winner: ADE20k-encoder only

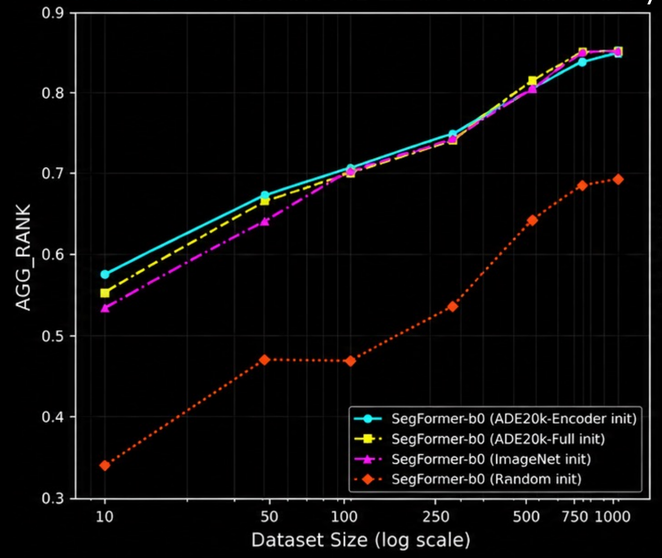

Large Winner: SegFormer-b4

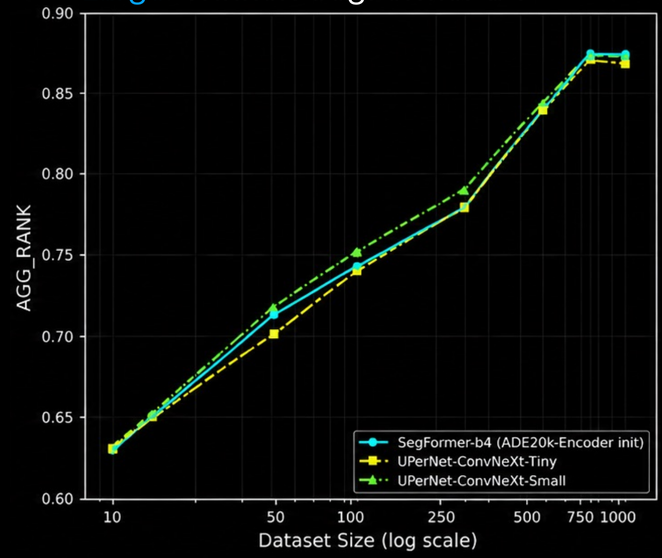

Графики получены исследователями VL на 12 датасетах различных доменов

План

01 Введение, датасеты и метрики

02 UNet

03 Кто, если не UNet

04 Трансформерные модели

05 Segment Anything Model (SAM)

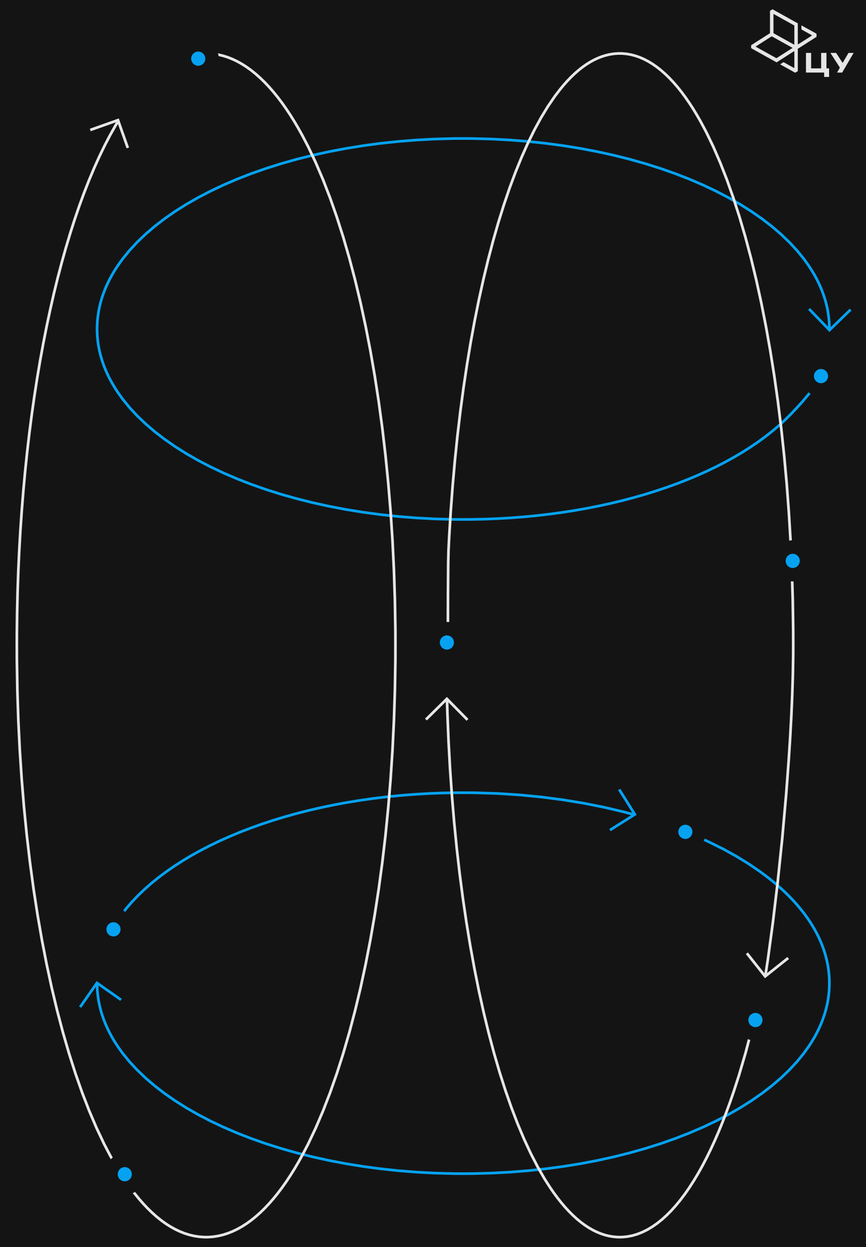

Segment Anything Model от FAIR (ICCV 2023)

Segment Anything Model

Segment Anything Model: возможности

> “Any model that is trained on broad data (generally using self-supervision at scale) that can be adapted (e.g., fine-tuned) to a wide range of downstream tasks.”
>
> On The Opportunities and Risks of Foundation Models

Segment Anything (SAM) — это фундаментальная модель для интерактивной сегментации чего угодно на основании промптов – кликов и боксов.

Prompt it with interactive points and boxes.

Automatically segment everything in an image.

Generate multiple valid masks for ambiguous prompts.

Источник

Segment Anything Model (SAM) — продукт создан и принадлежит компании Meta. Компания Meta Platforms Inc. по решению Тверского районного суда города Москвы от 21.03.2022 признана экстремистской организацией, ее деятельность на территории России запрещена

Segment Anything Model: как это работает

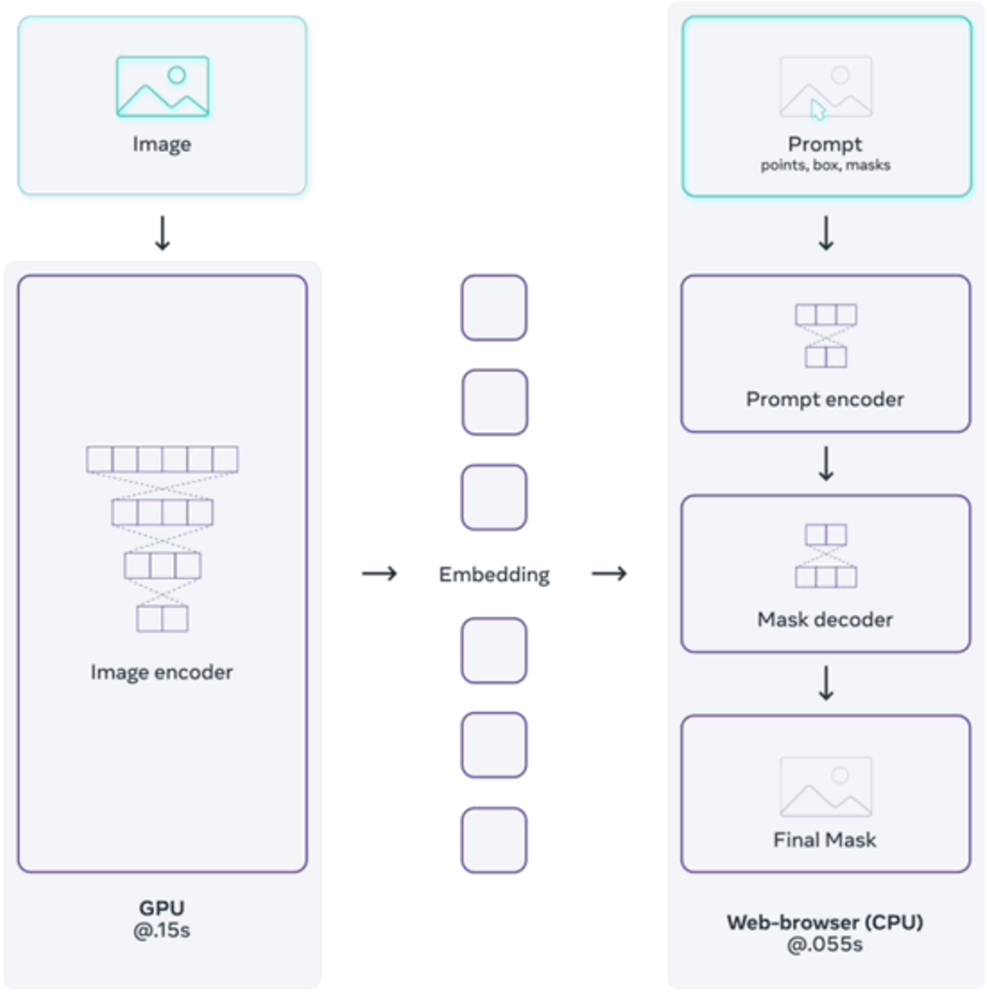

Источник

SAM: как происходит энкодинг

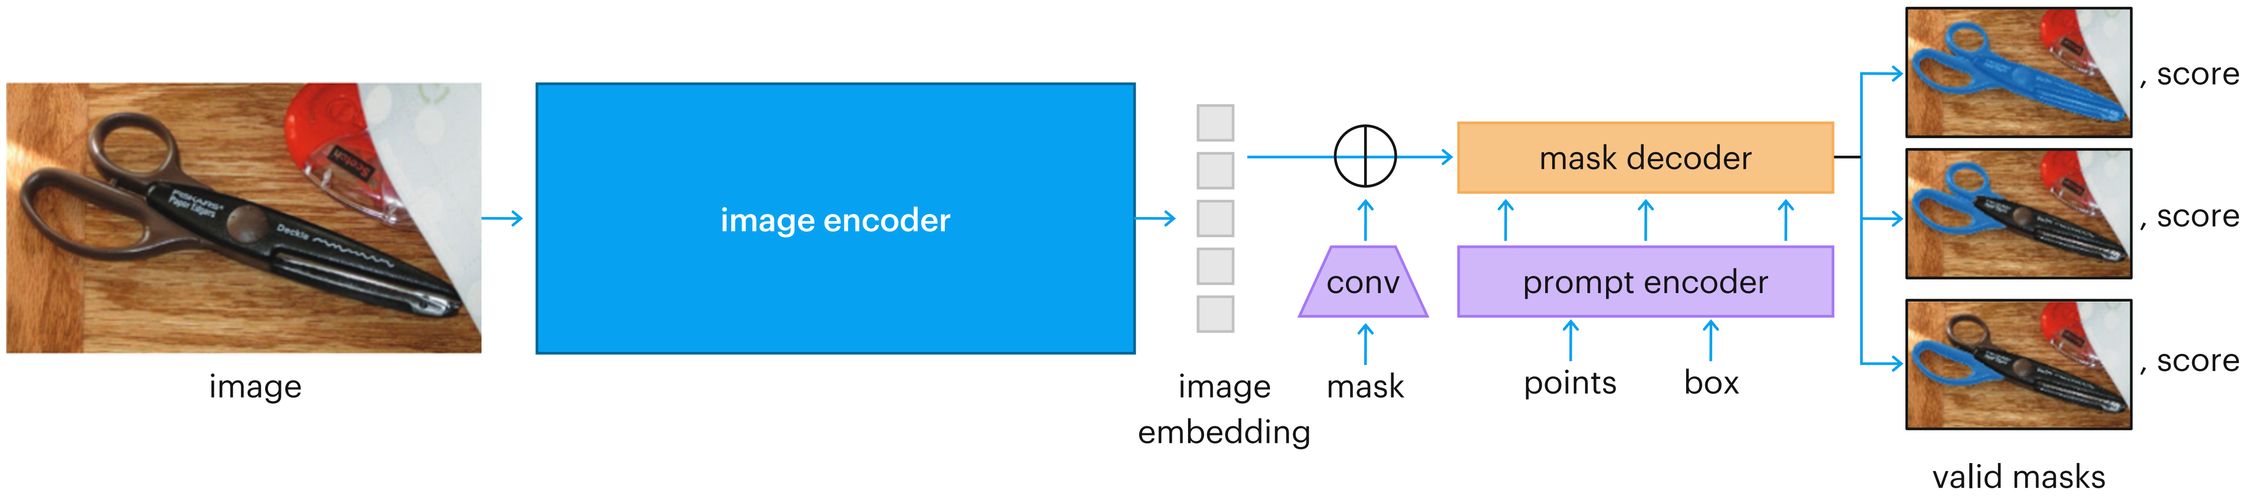

Что участвует в энкодинге:

- Изображение — на нём хотим с помощью интерактивной сегментации что-то выделить;
- Клики — (x, y, is_foreground);
- Боксы — координаты углов (x1, x2, y1, y2);
- Маска с предыдущего шага — прогоняем её через несколько свёрточных слоёв и получаем тензор того же размера, что и эмбеддинг изображения (256x64x64).

Затем эмбеддинги маски и изображения поэлементно складываются. Если это первый прогон — мы данный шаг пропускаем, так как маски ещё нет.

Источник

SAM: как происходит декодинг

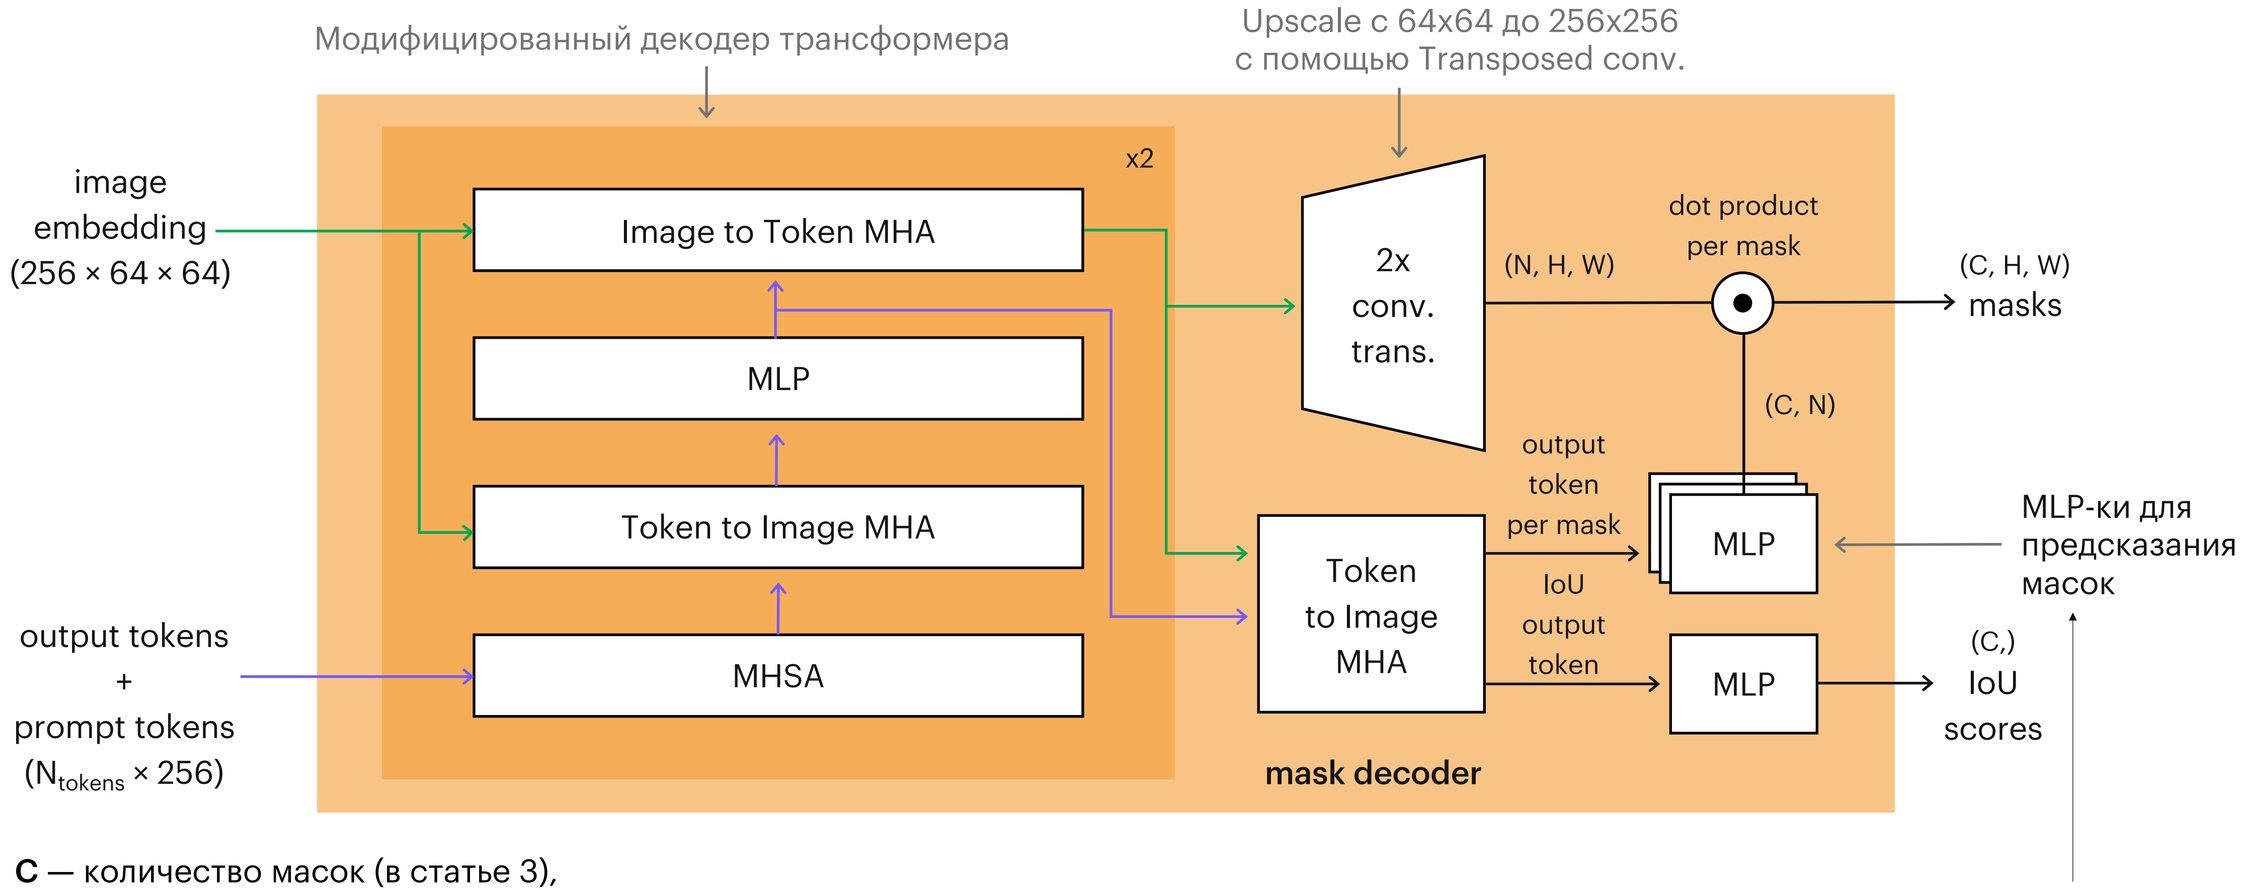

C — количество масок (в статье 3),
N_tokens — число токенов трансформера,
N — количество каналов в пространственном эмбеддинге после upscale,
H и W — высота и ширина исходного изображения.

Каждая выдаёт N весов, которые используются для взвешенной суммы upscaled feature maps, которых тоже N.

Источник

SAM: как учили и получили датасет

Шаг 1. Assisted-manual stage.

- Сеть предсказывает маски с помощью кликов, затем маски вручную исправляются аннотаторами.
- В процессе разметки модель обучается на новых аннотациях.
- Всего на этой стадии модель переучивают 6 раз.
- Среднее число масок на изображении удаётся поднять с 20 до 44, собирают 4,3M масок на 120k фото.

Segment Anything Model (SAM) - продукт создан и принадлежит компании Meta. Компания Meta Platforms Inc. по решению Тверского районного суда города Москвы от 21.03.2022 признана экстремистской организацией, ее деятельность на территории России запрещена

SAM: как учили и получили датасет

Шаг 2. Semi-automatic stage.

- Модель прогоняют на изображении и сохраняют самые уверенные маски, затем аннотаторы добавляют все недостающие маски.
- Также обучили детектор на данных с первой стадии на класс «объект».
- Результат предсказания детектора используется как промпт.
  Модель переучивают **5 раз**.
- Среднее число масок на изображении поднимается до 77, собирают **5,9M** масок **180k** фото.

Segment Anything Model (SAM) - продукт создан и принадлежит компании Meta.
Компания Meta Platforms Inc. по решению Тверского районного суда города Москвы от 21.03.2022 признана экстремистской организацией, ее деятельность на территории России запрещена

SAM: как учили и получили датасет

Итоговая модель переразметила все **11 млн** фото и получила **1,1 млрд** масок.

При этом люди разметили всего **10,2 М** масок (~1% от общего числа).

Шаг 3. Fully automatic stage.

- Качество модели поднялось, теперь можно попробовать исключить из процесса человека.
- Но надо как-то помогать модели в неоднозначных ситуациях. Авторы предложили такой алгоритм:
  1. Режем изображение на сетку 32x32. В центре каждой ячейки ставим по точке, передаём её как промпт в модель;
  2. Для каждого промпта предсказываем три маски и отсекаем маски с низким confidence;
  3. Для оставшихся масок проверяем устойчивость: немного меняем порог бинаризации и смотрим, сильно ли меняется маска. Нестабильные маски удаляем, затем применяем NMS для удаления дубликатов;
  4. Некоторые участки изображения дополнительно прогоняем отдельно для уточнения контуров небольших масок.

Segment Anything Model (SAM) - продукт создан и принадлежит компании Meta. Компания Meta Platforms Inc. по решению Тверского районного суда города Москвы от 21.03.2022 признана экстремистской организацией, ее деятельность на территории России запрещена

SAM: итоговый датасет

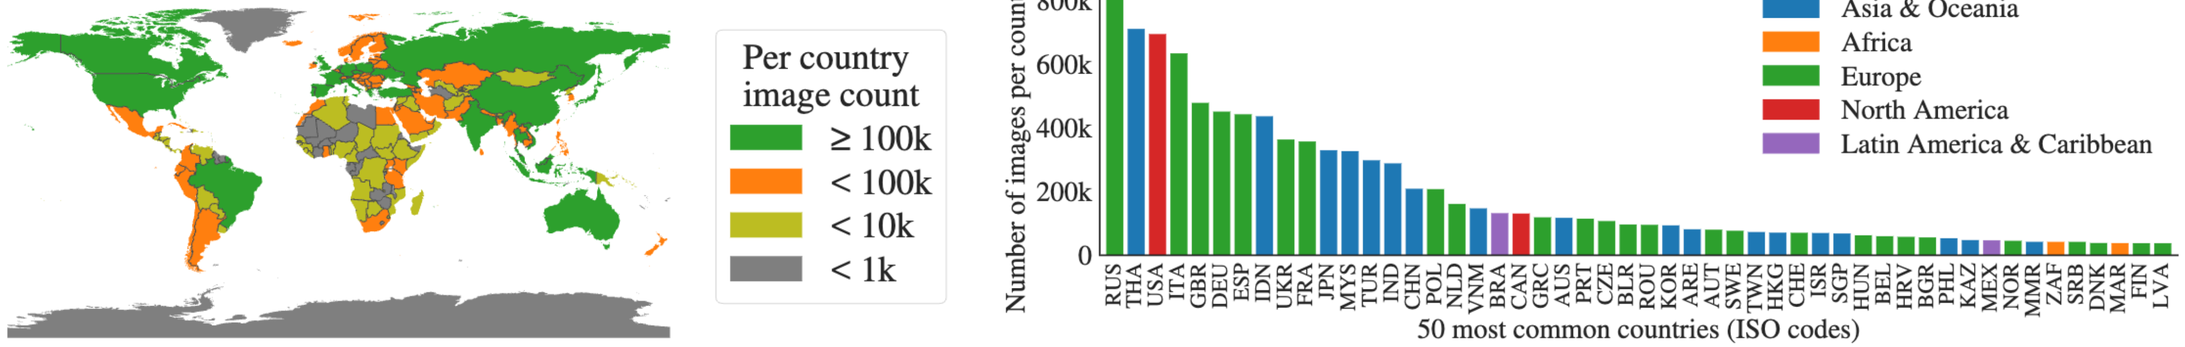

Figure 7: Estimated geographic distribution of SA-1B images. Most of the world's countries have more than 1000 images in SA-1B, and the three countries with the most images are from different parts of the world.

Segment Anything Model (SAM) - продукт создан и принадлежит компании Meta. Компания Meta Platforms Inc. по решению Тверского районного суда города Москвы от 21.03.2022 признана экстремистской организацией, ее деятельность на территории России запрещена

Источник

SAM: итоговый датасет

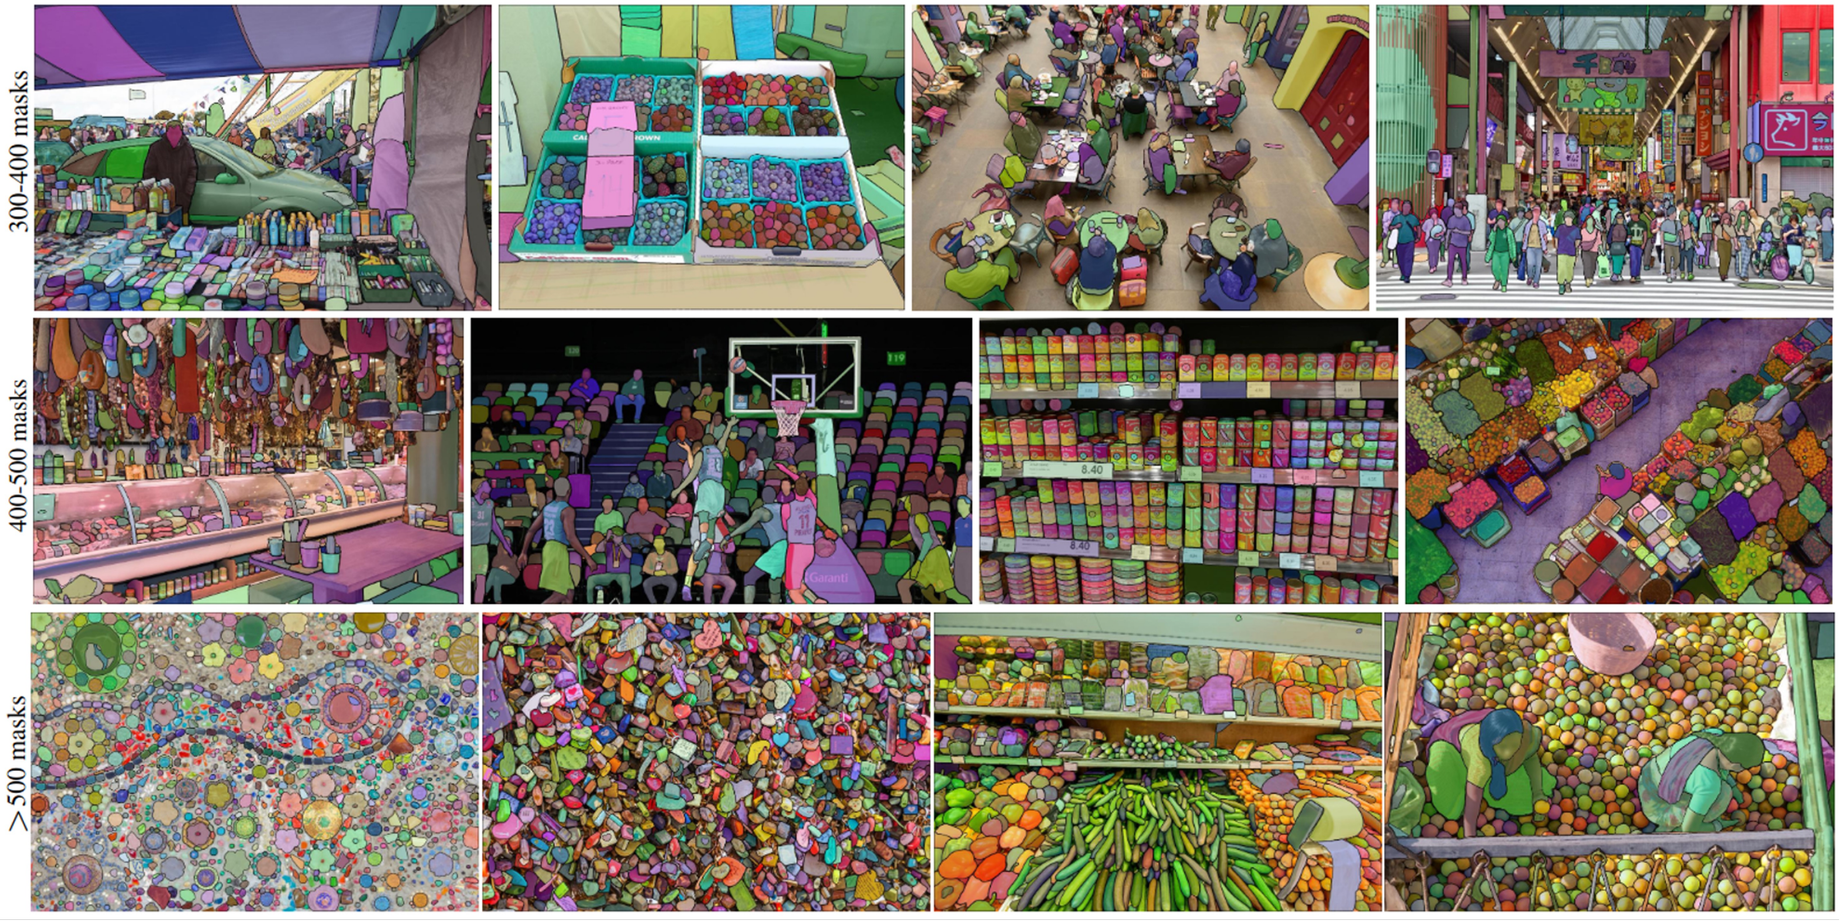

Segment Anything Model (SAM) - продукт создан и принадлежит компании Meta. Компания Meta Platforms Inc. по решению Тверского районного суда города Москвы от 21.03.2022 признана экстремистской организацией, ее деятельность на территории России запрещена

Источник

SAM — модель для zero-shot сегментации

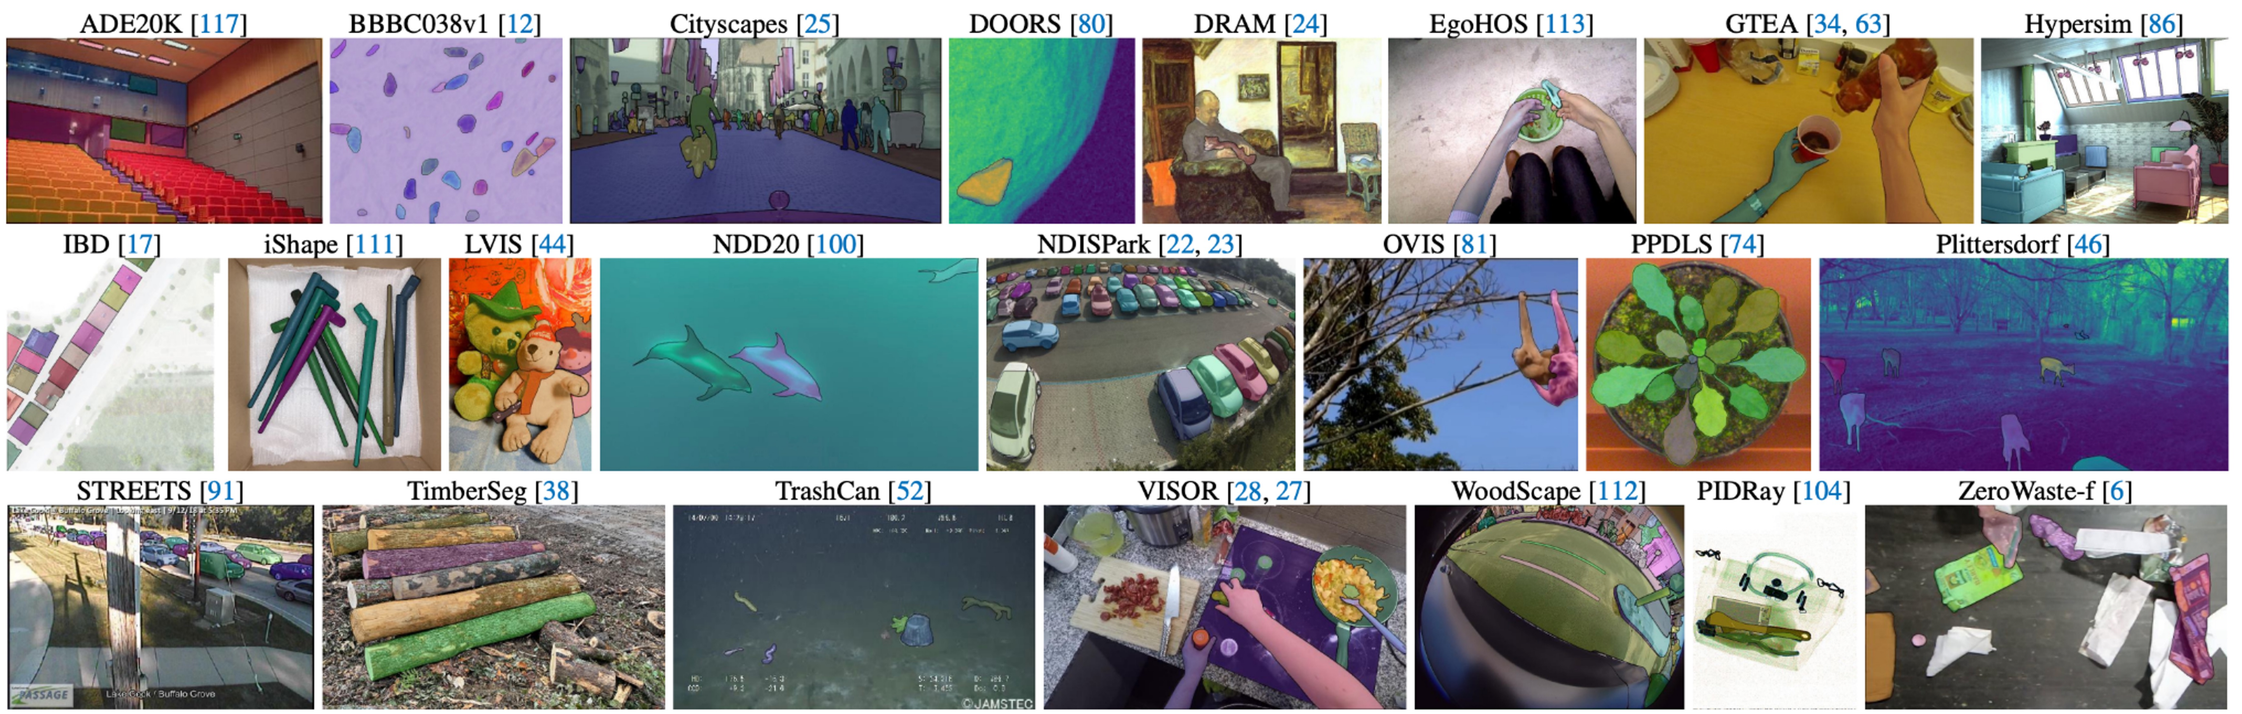

Figure 8: Samples from the 23 diverse segmentation datasets used to evaluate SAM's zero-shot transfer capabilities.

Segment Anything Model (SAM) - продукт создан и принадлежит компании Meta. Компания Meta Platforms Inc. по решению Тверского районного суда города Москвы от 21.03.2022 признана экстремистской организацией, ее деятельность на территории России запрещена

Источник

SAM 2 от FAIR (SIGGRAPH 2024)

SAM 2 — это фундаментальная модель для интерактивной сегментации чего угодно на основании промптов – кликов и боксов, но уже **на видео.**

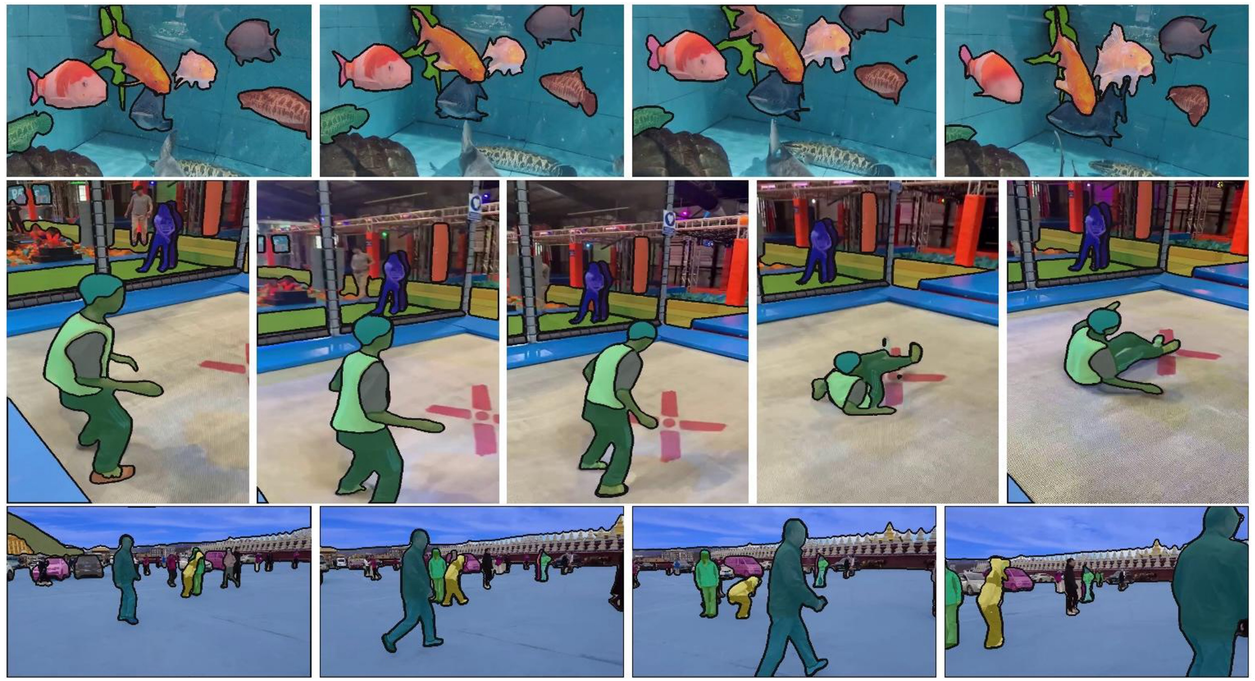

Segment Anything Model (SAM) - продукт создан и принадлежит компании Meta. Компания Meta Platforms Inc. по решению Тверского районного суда города Москвы от 21.03.2022 признана экстремистской организацией, ее деятельность на территории России запрещена

Источник

SAM 2: как происходит взаимодействие

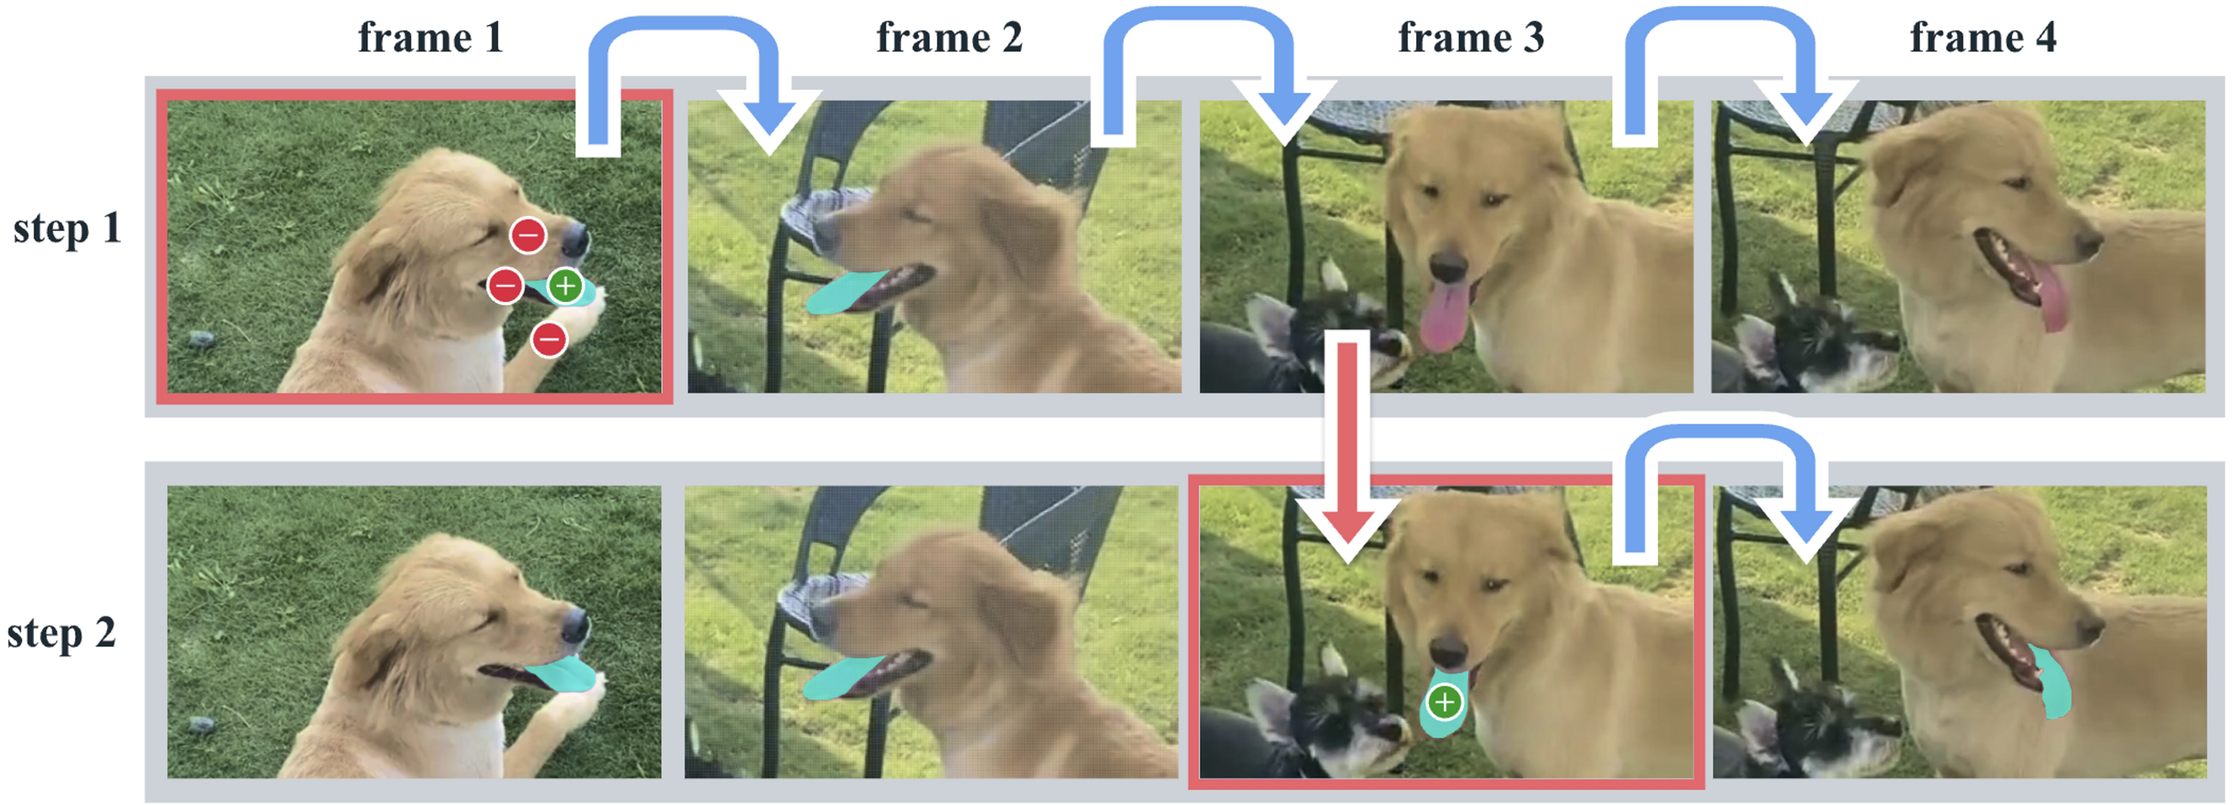

Segment Anything Model (SAM) - продукт создан и принадлежит компании Meta. Компания Meta Platforms Inc. по решению Тверского районного суда города Москвы от 21.03.2022 признана экстремистской организацией, ее деятельность на территории России запрещена

Источник

SAM 2: как происходит взаимодействие

Segment Anything Model (SAM) - продукт создан и принадлежит компании Meta. Компания Meta Platforms Inc. по решению Тверского районного суда города Москвы от 21.03.2022 признана экстремистской организацией, ее деятельность на территории России запрещена

Источник

SAM 2: как устроена

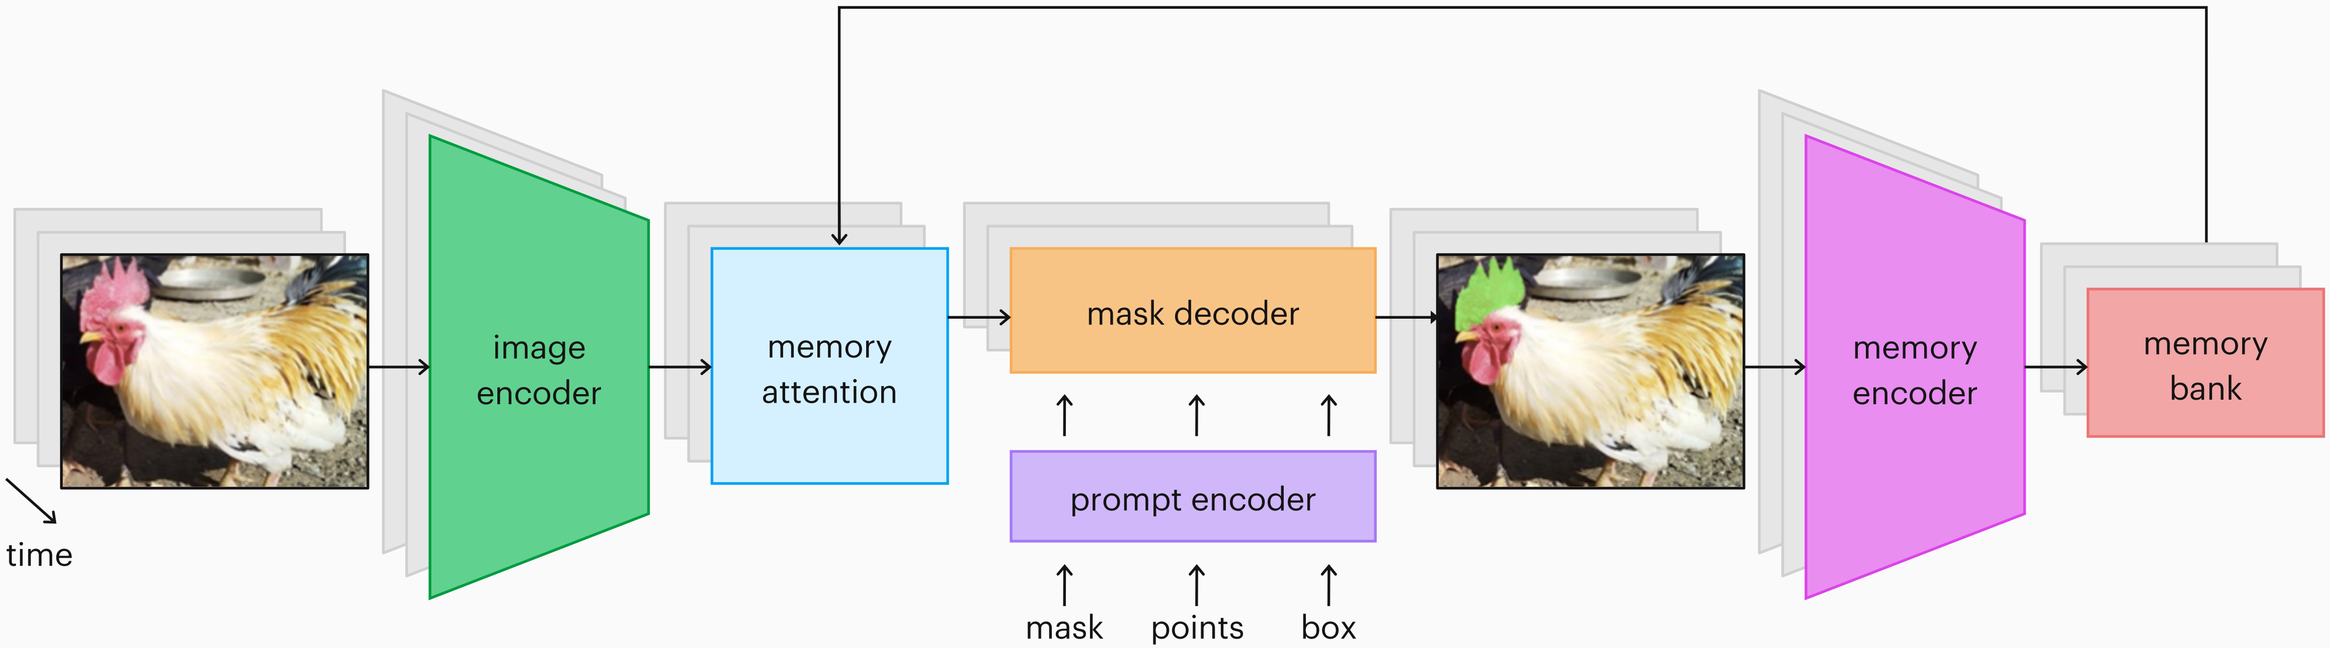

Segment Anything Model (SAM) - продукт создан и принадлежит компании Meta. Компания Meta Platforms Inc. по решению Тверского районного суда города Москвы от 21.03.2022 признана экстремистской организацией, ее деятельность на территории России запрещена

Источник

SAM 2: SA-V датасет

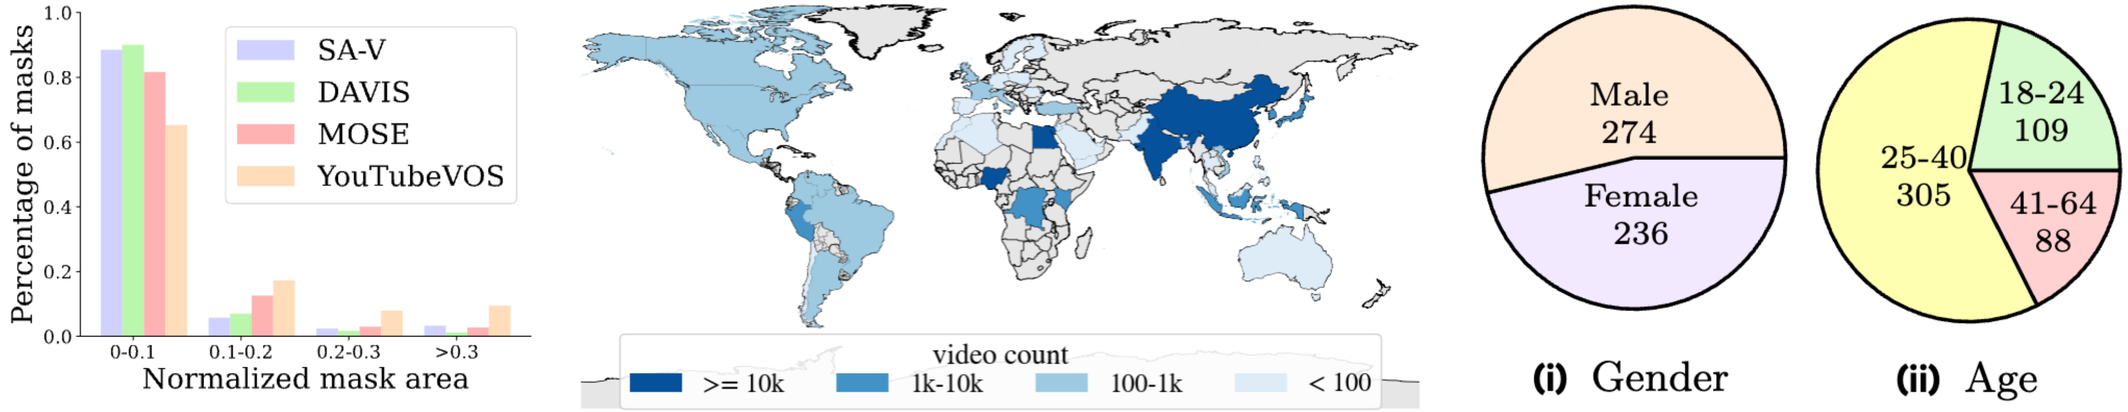

(a) Size **(b)** Geography **(c)** Crowdworker Demographics

Figure 10 Dataset distribution: (a) masklets size distribution (normalized by video resolution), (b) geographic diversity of the videos, and (c) self-reported demographics of the crowdworkers who recorded the videos.

SAM 2: зачем это нужно

Segment Anything Model (SAM) - продукт создан и принадлежит компании Meta. Компания Meta Platforms Inc. по решению Тверского районного суда города Москвы от 21.03.2022 признана экстремистской организацией, ее деятельность на территории России запрещена

Источник

Резюме

01 SAM — это универсальная модель для сегментации чего угодно с помощью промптов.

02 Промптами для SAM могут быть клики (одна точка с классом) или боксы (2 точки).

03 SAM — это модель типа encoder-decoder, где в encoder обрабатываются фото, промпты и предыдущие маски, а в decoder предсказываются новые маски.

04 Датасет для SAM был получен частично с помощью ручной разметки, а 99% данных было размечено самой SAM с помощью разных трюков. В итоге вышел сет из 11 млн фото с 1,1 млрд масок.

05 SAM можно и нужно использовать в своих задачах для бесплатной разметки данных масками (тут нужна смекалочка), а ещё она уже встроена во многие инструменты для разметки.

06 SAM 2 расширяет возможности до работы на видео, где можно интерактивно встраивать сегментационные треки объектов между кадрами.

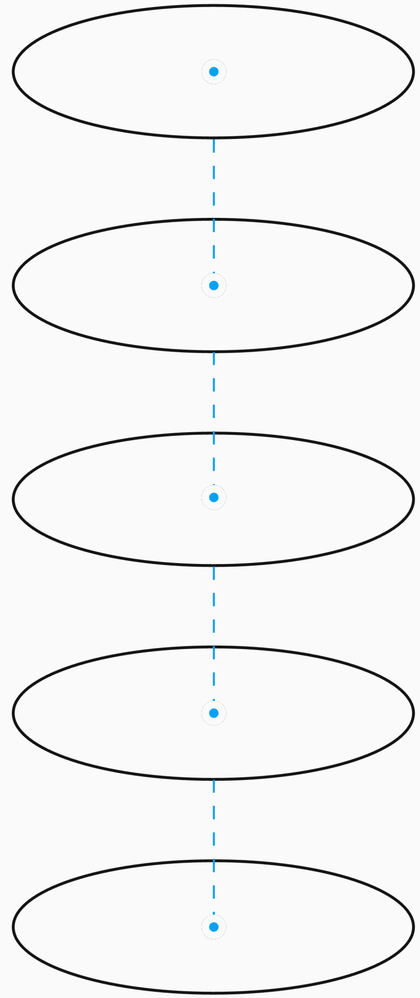

Segment Anything Model (SAM) - продукт создан и принадлежит компании Meta. Компания Meta Platforms Inc. по решению Тверского районного суда города Москвы от 21.03.2022 признана экстремистской организацией, ее деятельность на территории России запрещена

Резюме лекции

01 Узнали, что бывает сегментация разных типов: семантическая, инстанс, паноптик.

02 Узнали, как развивается область семантической сегментации.

03 Узнали, какие есть метрики и лоссы для этой задачи.

04 Вспомнили, что из себя представляет UNet и зачем нужны все её составные элементы.

05 Узнали про архитектуры для сегментации: LinkNet, DeepLab, FPN, HRNet.

06 Познакомолись с трансформерами для сегментации: SETR и SegFormer.

07 Узнали, как устроены и на что способны модели SAM и SAM 2.

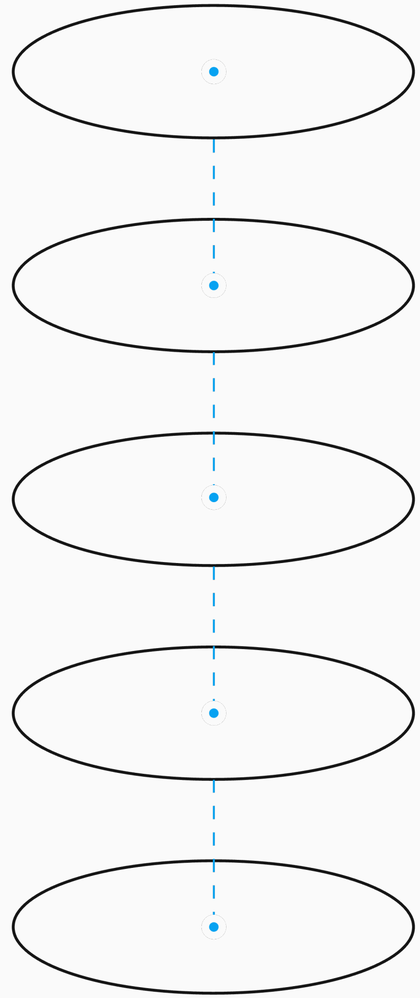

ЦЕНТРАЛЬНЫЙ УНИВЕРСИТЕТ

Вопросы